

**Υπερανάλυση Εικόνας Με Χρήση Βαθιών
Νευρωνικών Δικτύων**

-

**Image Super-Resolution Using Deep
Neural Networks**

Σπηλιόπουλος Σπήλιος

Διπλωματική Εργασία

Επιβλέποντες :

Λυσίμαχος Κόντης

Ιωάννινα, Ιούλιος, 2025



**ΤΜΗΜΑ ΜΗΧ. Η/Υ & ΠΛΗΡΟΦΟΡΙΚΗΣ
ΠΑΝΕΠΙΣΤΗΜΙΟ ΙΩΑΝΝΙΝΩΝ**

**DEPARTMENT OF COMPUTER SCIENCE & ENGINEERING
UNIVERSITY OF IOANNINA**

Ευχαριστίες

Η ολοκλήρωση αυτής της διπλωματικής εργασίας δεν θα ήταν δυνατή χωρίς την πολύτιμη υποστήριξη και συμβολή πολλών ανθρώπων, στους οποίους οφείλω τις πιο θερμές μου ευχαριστίες.

Πρωτίστως, θα ήθελα να εκφράσω την ειλικρινή μου ευγνωμοσύνη στους επιβλέποντες καθηγητές μου, Ευαγγελία Τσιλιγιάννη και Λυσίμαχο Κόντη, για την ακαδημαϊκή καθοδήγηση, την υπομονή και την εμπιστοσύνη που επέδειξε σε όλη τη διάρκεια αυτής της ερευνητικής προσπάθειας. Οι συμβουλές του και η επιστημονική του καθοδήγηση υπήρξαν καθοριστικές για την επιτυχή ολοκλήρωση αυτού του έργου.

Ευχαριστώ επίσης όλα τα μέλη του Τμήματος Μηχανικών Η/Υ & Πληροφορικής του Πανεπιστημίου Ιωαννίνων για το εξαιρετικό ακαδημαϊκό περιβάλλον που δημιούργησαν και για τις γνώσεις που μου μετέδωσαν κατά τη διάρκεια των σπουδών μου.

Ιδιαίτερη ευγνωμοσύνη νιώθω για την οικογένειά μου, οι οποίοι με στήριξαν ψυχολογικά και υλικά σε όλη αυτή την απαιτητική περίοδο. Η κατανόηση, η υπομονή και η ανεκτίμητη υποστήριξή τους αποτέλεσαν τον ακρογωνιαίο λίθο της επιτυχίας μου. Χωρίς την αγάπη και την εμπιστοσύνη τους, αυτό το ταξίδι δεν θα είχε την ίδια αξία.

Θα ήθελα επίσης να ευχαριστήσω τους φίλους μου, οι οποίοι έδειξαν απεριόριστη κατανόηση για τις απουσίες μου και τη μειωμένη διαθεσιμότητά μου κατά τη διάρκεια αυτής της απαιτητικής περιόδου. Η φιλία και η ηθική υποστήριξή τους αποτέλεσαν πηγή δύναμης και κινήτρου για να συνεχίσω όταν οι προκλήσεις φαίνονταν ανυπέρβλητες.

Τέλος, θα ήθελα να ευχαριστήσω όλους όσους συνέβαλαν άμεσα ή έμμεσα στην πραγματοποίηση αυτής της εργασίας. Κάθε συζήτηση, κάθε συμβουλή και κάθε στιγμή ενθάρρυνσης είχαν τη δική τους αξία στο τελικό αποτέλεσμα.

Αυτή η διπλωματική εργασία αφιερώνεται σε όλους εσάς που πιστέψατε σε μένα, ακόμη και όταν εγώ αμφέβαλλα για τις δυνατότητές μου.

Σπηλιόπουλος Σπήλιος

Ιωάννινα, Ιούλιος 2025

Περίληψη

Η παρούσα διπλωματική εργασία αντιμετωπίζει το πρόβλημα της υπερανάλυσης ιατρικών εικόνων μαγνητικής τομογραφίας (MRI) πολλαπλών τύπων μέσω μιας καινοτόμου προσέγγισης που συνδυάζει τη θεωρία των αραιών αναπαραστάσεων με τεχνικές βαθιάς αναδίπλωσης. Αναπτύχθηκε το σύστημα Learned Multimodal Convolutional Sparse Coding (LMCSC), μια διπλού-κλάδου αρχιτεκτονική που αξιοποιεί τη συμπληρωματική πληροφορία από διαφορετικές MRI sequences για την παραγωγή εικόνων υψηλής ανάλυσης διατηρώντας παράλληλα την ερμηνευσιμότητα των αποτελεσμάτων. Το σύστημα ενσωματώνει τον καινοτόμο LeSITA αλγόριθμο μέσω του παραδείγματος της βαθιάς αναδίπλωσης, επιτρέποντας την αποδοτική μεταφορά πληροφοριών μεταξύ των εικόνων. Η επικύρωση πραγματοποιήθηκε στο σύνολο δεδομένων MS-MRI για τετραπλάσια υπερανάλυση εικόνων T2-σταθμισμένων χρησιμοποιώντας εικόνες T1-σταθμισμένες ως βοηθητική πληροφορία. Τα αποτελέσματα επιδεικνύουν ανταγωνιστική απόδοση με PSNR 41.77 dB, ξεπερνώντας την προηγούμενη κατάσταση τέχνης κατά **+0.83 dB**, ενώ παράλληλα επιτυγχάνεται εξαιρετική ταχύτητα σύγκλισης σε μόλις 40 εποχές εκπαίδευσης. Η εργασία συνεισφέρει στην ανάπτυξη ερμηνεύσιμων λύσεων τεχνητής νοημοσύνης στην ιατρική απεικόνιση, προσφέροντας μια ισορροπημένη προσέγγιση μεταξύ υψηλής απόδοσης και κλινικής εφαρμοσιμότητας.

Λέξεις Κλειδιά: <Υπερανάλυση Εικόνων>, <Ιατρική Απεικόνιση>, <Αραιές Αναπαραστάσεις>, <Βαθιά Αναδίπλωση>, <Συνελικτική Αραιή Κωδικοποίηση>, <Βοηθητική Πληροφορία>, <Τύποι Εικόνας>, <Ερμηνεύσιμη Τεχνητή Νοημοσύνη>, <Νευρωνικά Δίκτυα>, <Μηχανική Μάθηση>, <MRI>

Abstract

This thesis addresses the problem of super-resolution in magnetic resonance imaging (MRI) through an innovative multimodal approach that combines sparse representation theory with deep unfolding techniques. The Learned Multimodal Convolutional Sparse Coding (LMCSC) system was developed a dual-branch architecture that leverages complementary information from different MRI sequences to generate high-resolution images while maintaining interpretability of results. The system incorporates the novel LeSITA algorithm through the deep unfolding paradigm, enabling efficient information transfer between modalities. Validation was performed on the MS-MRI dataset for 4× super-resolution of T2-weighted images using T1-weighted images as lateral guidance information. Results demonstrate competitive performance with PSNR of 41.77 dB, surpassing the previous state-of-the-art by **+0.83 dB**, while achieving exceptional convergence speed in just 40 training epochs. This work contributes to the development of interpretable artificial intelligence solutions in medical imaging, offering a balanced approach between high performance and clinical applicability.

Keywords: <Image Super-Resolution>, <Multimodal Medical Imaging>, <Sparse Representations>, <Deep Unfolding>, <Convolutional Sparse Coding>, <Side Information>, <Multiple Modalities - Mutlimodal > <Interpretable Artificial Intelligence>, <Neural Networks>, <Machine Learning>, <MRI>

Table of Contents

Κεφάλαιο 1: Περιγραφή Του Προβλήματος.....	1
1.1 Εισαγωγή & Μαθηματική Διατύπωση.....	2
1.1.1 Υπερανάλυση Σε Ιατρικές Εικόνες MRI.....	2
1.1.2 Μαθηματική Διατύπωση Του Προβλήματος.....	3
1.1.3 Προκλήσεις Του Αόριστου (ill-posed) Προβλήματος.....	3
1.1.4 Ιδιαιτερότητες της Ιατρικής Απεικόνισης.....	4
1.2 Χρήση Πολλαπλών MRI Εικόνων Στο Πρόβλημα Της Υπερανάλυσης.....	4
1.2.1 Πλεονεκτήματα.....	4
1.2.2 Μεταφορά Πληροφορίας Με Πολλούς Τύπους Εικόνων.....	5
1.2.3 Το Δίλημμα: Ερμηνευσιμότητα vs Απόδοση.....	5
1.2.4 Κλινική Ανάγκη και Ερμηνευσιμότητα.....	5
1.3 Προτεινόμενη Λύση και Συνεισφορές.....	6
1.3.1 Κύριες Συνεισφορές.....	6
1.4 Δομή της Εργασίας & Προσδοκίες.....	7
1.4.1 Οργάνωση Κεφαλαίων.....	7
1.4.2 Προσδοκίες & Αντίκτυπος.....	7
Κεφάλαιο 2: Θεωρητικό Υπόβαθρο.....	9
2.1 Γραμμικά Αντίστροφα Προβλήματα στην Επεξεργασία Εικόνας.....	9
2.1.1 Μαθηματική Διατύπωση.....	9
2.1.2 Αόριστα (Ill-posed) Χαρακτηριστικά & Ανάγκη Για Κανονικοποίηση.....	10
2.1.3 Στρατηγικές Κανονικοποίησης.....	11
2.1.4 Εφαρμογές Στην Ιατρική Απεικόνιση.....	11
2.2 Αραιές Αναπαραστάσεις.....	12
2.2.1 Θεωρητικά Θεμέλια.....	12
2.2.2 Προβλήματα Βελτιστοποίησης & Αραιές Αναπαραστάσεις.....	13
2.2.3 Iterative Soft Thresholding Algorithm (ISTA).....	14
2.2.4 Θεωρητικές Εγγυήσεις.....	14
2.3 Συνελκτικές Αραιές Αναπαραστάσεις (Convolutional Sparse Coding).....	15
2.3.1 Εφαρμογή Σε Ολόκληρη Την Εικόνα.....	15

2.3.2 Μαθηματική Διατύπωση Της Συνελικτικής Αραιής Κωδικοποίησης (Convolutional Sparse Coding)	16
2.4 Πλαίσιο Βαθιάς Αναδίπλωσης.....	17
2.4.1 Αρχές Βαθιάς Αναδίπλωσης.....	17
2.4.2 Από ISTA σε LISTA:.....	18
2.4.3 Συνελικτικές Επεκτάσεις.....	20
2.4.4 Υπολογιστικά Πλεονεκτήματα & Αποδοτικότητα.....	21
2.4.5 Εκπαίδευση & Αρχικοποίηση	22
Κεφάλαιο 3: Περιγραφή Της Λύσης που Υλοποιήθηκε.....	23
3.1 Θεωρητικά Θεμέλια Της Λύσης.....	23
3.1.1 Βοηθητική Πληροφορία (Side Information) στην Αραιή Κωδικοποίηση.....	24
3.1.2 Θεωρία Του LeSITA Αλγορίθμου.....	25
3.1.3 Ενσωμάτωση Πολλών Τύπων Εικόνων στην Ιατρική Απεικόνιση	27
3.2 Αρχιτεκτονική του Συστήματος	28
3.2.1 Γενική Δομή και Σχεδιασμός.....	28
3.2.2 Προσέγγιση Διπλού Κλάδου (Dual-Branch).....	30
3.2.3 Υλοποίηση Βαθιάς Αναδίπλωσης	31
3.3 Υλοποίηση Των Κύριων Δομοστοιχείων	32
3.3.1 ACSC Module (Approximate Convolutional Sparse Coding).....	32
3.3.2 LMCSC Module (Learned Multimodal Convolutional Sparse Coding)	33
3.3.3 Επανακατασκευή (Reconstruction).....	35
3.4 Θεωρητικές Εγγυήσεις & Επεκτάσεις	36
3.4.1 Θεωρητικές Εγγυήσεις & Στρατηγικές εκπαίδευσης	37
3.4.2 LMCSC vs Co-evolving LMCSC.....	38
Κεφάλαιο 4: Πειράματα	41
4.1 Πειραματική Διάταξη	41
4.1.1 Υπολογιστικό Περιβάλλον	41
4.1.2 Αρχιτεκτονικές Παράμετροι.....	42
4.1.3 Παράμετροι Εκπαίδευσης.....	44
4.2 Dataset & Προεπεξεργασία	47
4.2.1 Σύνολο Δεδομένων MS-MRI	47

4.2.2 Διαδικασία Υποδειγματοληψίας (<i>Downsampling Process</i>)	48
4.2.3 Δομή & Οργάνωση Δεδομένων	49
4.2.4 Ροή Προεπεξεργασίας (<i>Preprocessing Pipeline</i>).....	50
4.3 Μεθοδολογία Αξιολόγησης	52
4.3.1 Μέτρα Αξιολόγησης	52
4.3.2 Συγκρινόμενες Προσεγγίσεις & Σύγκριση με Βιβλιογραφία	53
4.3.3 Πρωτόκολλο Αξιολόγησης	54
4.3.4 Κλινική Επικύρωση	54
4.4 Ποσοτικά Αποτελέσματα Πειραμάτων.....	54
4.4.1 Ποσοτικά Αποτελέσματα & Σύγκριση με τη Βιβλιογραφία	55
4.4.2 Επίδραση Τεχνικών Βελτιστοποίησης	56
4.4.3 Ανάλυση Γενίκευσης.....	56
4.5 Οπτική Αξιολόγηση	57
4.5.1 Επεξεργασία Εισόδου	58
4.5.2 Αραιές Αναπαραστάσεις (<i>LMCSC/ACSC Modules</i>).....	59
4.5.3 Αποτελέσματα Ανακατασκευής (<i>Reconstruction Module</i>).....	60
4.5.4 Χάρτες Σφαλμάτων (<i>Error Maps</i>).....	61
4.5.5 Οπτικές Συγκρίσεις μεταξύ μεθόδων	63
4.5.6 Άλλες Οπτικοποιήσεις.....	69
Κεφάλαιο 5: Συμπεράσματα.....	73
5.1 Συνοπτική Παρουσίαση Αποτελεσμάτων.....	73
5.2 Κύριες Συνεισφορές	74
5.3 Περιορισμοί & Μαθημένα Διδάγματα.....	74
5.4 Μελλοντικές Κατευθύνσεις & Επεκτάσεις.....	75
5.5 Κλινικός Αντίκτυπος & Προοπτικές.....	76
5.6 Επιστημονικά Συμπεράσματα & Φιλοσοφικές Σκέψεις.....	77
Βιβλιογραφία	78

Κεφάλαιο 1: Περιγραφή Του

Προβλήματος

Η μαγνητική τομογραφία αντιμετωπίζει ένα θεμελιώδες δίλημμα στην κλινική πράξη: την αντίστροφα ανάλογη σχέση μεταξύ διαγνωστικής ποιότητας και χρόνου εξέτασης. Οι εικόνες σταθμισμένες σε χρόνο χαλάρωσης, κρίσιμες για την ανίχνευση απομυελινωτικών βλαβών σε παθήσεις όπως η Σκλήρυνση κατά Πλάκας, απαιτούν εκτεταμένους χρόνους σάρωσης για την απόκτηση υψηλής ανάλυσης, δημιουργώντας προβλήματα κίνησης του ασθενούς, αυξημένο κόστος και περιορισμένη διαθεσιμότητα εξοπλισμού.

Το κεντρικό πρόβλημα που αντιμετωπίζει αυτή η εργασία είναι η **ανάκτηση διαγνωστικής ποιότητας εικόνων από δεδομένα χαμηλής ανάλυσης**, αξιοποιώντας την ταυτόχρονη διαθεσιμότητα εικόνων καθοδήγησης υψηλής ανάλυσης που αποκτώνται ταχύτερα. Οι υπάρχουσες μέθοδοι υπερανάλυσης αδυνατούν να εκμεταλλευτούν τη συμπληρωματική δομική πληροφορία από μια εικόνα καθοδήγησης, ενώ οι υπάρχουσες προσεγγίσεις βαθιάς μάθησης λειτουργούν ως "μαύρα κουτιά" χωρίς ερμηνευσιμότητα - κρίσιμη απαίτηση για ιατρικές εφαρμογές.

Αυτή η εργασία προτείνει μια **ερμηνεύσιμη μέθοδο υπερανάλυσης με εικόνες διαφορετικών τύπων (multimodal)** που βασίζεται στη θεωρία της αραιής κωδικοποίησης με πληροφορία επικουρίας, υλοποιημένη μέσω βαθιάς αναδίπλωσης αλγορίθμου σε συνελικτική αρχιτεκτονική. Η προτεινόμενη μέθοδος συνελικτικής αραιής κωδικοποίησης με ενσωμάτωση πολλών εικόνων επιτρέπει την ανακατασκευή εικόνων υψηλής ποιότητας χρησιμοποιώντας τροπικότητα καθοδήγησης, διατηρώντας παράλληλα πλήρη ερμηνευσιμότητα της διαδικασίας μάθησης και θεωρητικές εγγυήσεις σύγκλισης.

1.1 Εισαγωγή & Μαθηματική Διατύπωση


Η μαγνητική τομογραφία (Magnetic Resonance Imaging - MRI) αποτελεί ένα από τα σημαντικότερα διαγνωστικά εργαλεία της σύγχρονης ιατρικής [GRE2009], παρέχοντας, παρέχοντας λεπτομερείς εικόνες των εσωτερικών δομών του ανθρωπίνου σώματος χωρίς τη χρήση ιονίζουσας ακτινοβολίας. Παρά τις τεχνολογικές εξελίξεις, η ποιότητα των MRI εικόνων περιορίζεται από φυσικούς και πρακτικούς παράγοντες που επηρεάζουν άμεσα τη διαγνωστική αποτελεσματικότητα.

Οι περιορισμοί που οφείλονται τόσο στο υλικό (hardware limitations) όσο και στο χρόνο εξέτασης (scanning time constraints) αποτελούν τις κύριες αιτίες υποβάθμισης της χωρικής ανάλυσης. Η απόκτηση εικόνων υψηλής ανάλυσης απαιτεί σημαντικά μεγαλύτερους χρόνους σάρωσης, γεγονός που δημιουργεί πρακτικά προβλήματα στην κλινική ρουτίνα, αυξάνει την πιθανότητα κίνησης του ασθενούς και επιβαρύνει το κόστος εξέτασης.

1.1.1 Υπερανάλυση Σε Ιατρικές Εικόνες MRI

Η υπερανάλυση εικόνων (Image Super-Resolution - SR) αποτελεί μια υποσχόμενη λύση για την αντιμετώπιση αυτών των περιορισμών. Μέσω της υπολογιστικής ανακατασκευής εικόνων υψηλής ανάλυσης από αντίστοιχες χαμηλής ανάλυσης, η υπερανάλυση προσφέρει τη δυνατότητα βελτίωσης της διαγνωστικής ακρίβειας χωρίς αύξηση του χρόνου εξέτασης.


Εικόνα 1.1 : Εγκεφαλογράφημα MRI



Εικόνα 1.2

β) Εγκεφαλογράφημα MRI

Χαμηλής Ανάλυσης (LR)



Εικόνα 1.1

α) Εγκεφαλογράφημα MRI

Υψηλής Ανάλυσης (HR)

1.1.2 Μαθηματική Διατύπωση Του Προβλήματος

Για την κατανόηση της φύσης του προβλήματος απαιτείται η μαθηματική του διατύπωση. Το πρόβλημα της υπερανάλυσης σε ιατρικές εικόνες μοντελοποιείται ως ένα Γραμμικά Αντίστροφο Πρόβλημα (Linear Inverse Problem) [RSC2008] όπου η παρατηρούμενη εικόνα χαμηλής ανάλυσης (LR - Low Resolution) αποτελεί υποβαθμισμένη έκδοση της πραγματικής εικόνας υψηλής ανάλυσης (HR - High Resolution):

$$y = Lx + \eta \quad \text{εξ. (1.1)}$$

όπου:

- x : άγνωστη HR εικόνα που επιθυμούμε να ανακατασκευάσουμε
- y : παρατηρούμενη LR εικόνα
- L : αντιπροσωπεύει τον τελεστή υποβάθμισης
- η : θόρυβος της εικόνας

1.1.3 Προκλήσεις Του Αόριστου (ill-posed) Προβλήματος

Τα προβλήματα της μορφής της **εξίσωσης (1.1)** είναι εγγενώς αόριστα ή αλλιώς «κακώς τιθέμενα (ill-posed)», καθώς πολλαπλές εικόνες υψηλής ανάλυσης μπορούν να παράγουν την ίδια εικόνα χαμηλής ανάλυσης. Οι κύριες προκλήσεις περιλαμβάνουν:

- **Απώλεια πληροφορίας:** Η υποδειγματοληψία (downsampling) προκαλεί απώλεια σημαντικών συνιστωσών
- **Μη-μοναδικότητα λύσης:** Ύπαρξη άπειρων δυνητικών λύσεων
- **Ενίσχυση θορύβου:** Η αντιστροφή του τελεστή υποβάθμισης (degradation) ενισχύει τον θόρυβο

Αυτές οι προκλήσεις οδήγησαν στη χρήση βαθιών νευρωνικών δικτύων για την επίλυση αντιστροφών προβλημάτων στην απεικόνιση [LIM2018].

1.1.4 Ιδιαιτερότητες της Ιατρικής Απεικόνισης

Η εφαρμογή της υπερανάλυσης στην ιατρική απεικόνιση παρουσιάζει μοναδικές προκλήσεις:

Διαγνωστική Ακρίβεια: Η ανακατασκευή πρέπει να διατηρεί τη διαγνωστική αξία χωρίς εισαγωγή παραπλανητικών χαρακτηριστικών που θα μπορούσαν να οδηγήσουν σε λανθασμένες διαγνώσεις.

Ανατομική Συνέπεια: Τα ανακατασκευασμένα χαρακτηριστικά πρέπει να σέβονται τη βιολογική δομή και να είναι ανατομικά ρεαλιστικά.

Ποσοτική Διατήρηση: Πολλές ιατρικές εικόνες περιέχουν ποσοτικές πληροφορίες που πρέπει να διατηρούνται με ακρίβεια για σωστές κλινικές μετρήσεις.

1.2 Χρήση Πολλαπλών MRI Εικόνων Στο

Πρόβλημα Της Υπερανάλυσης

Αυτή η ενότητα εξετάζει τα πλεονεκτήματα της χρήσης πολλαπλών MRI εικόνων στο πρόβλημα της υπερανάλυσης και αναλύει το θεμελιώδες δίλημμα μεταξύ υπολογιστικής απόδοσης και ερμηνευσιμότητας που χαρακτηρίζει τις σύγχρονες προσεγγίσεις. Εστιάζει στην κλινική αναγκαιότητα για ερμηνεύσιμα (interpretable) συστήματα στην ιατρική απεικόνιση και τις ιδιαίτερες απαιτήσεις που προκύπτουν από αυτή την ανάγκη.

1.2.1 Πλεονεκτήματα

Μια σημαντική ιδιαιτερότητα της MRI απεικόνισης είναι η δυνατότητα απόκτησης πολλαπλών ακολουθιών μιας εικόνας του ίδιου ανατομικού περιεχομένου κατά τη διάρκεια μίας εξέτασης. Οι διαφορετικές MRI ακολουθίες παρέχουν συμπληρωματική πληροφορία:

- **T1-weighted:** Εξαιρετική ανατομική λεπτομέρεια και δομική πληροφορία

- **T2-weighted:** Βέλτιστη για ανίχνευση παθολογίας και οπτικοποίησης του Γκρι υγρού
- **FLAIR:** Υψηλή αντίθεση για βλάβες με καταστολή CSF signal

1.2.2 Μεταφορά Πληροφορίας Με Πολλούς Τύπους Εικόνων

Η προσέγγιση αυτή αξιοποιεί τη συσχέτιση μεταξύ διαφορετικών MRI ακολουθιών, χρησιμοποιώντας πληροφορίες από έναν τύπο εικόνας ως βοηθητική πληροφορία (Side Information) για τη βελτίωση μιας άλλης. Αυτή η στρατηγική προσφέρει:

- **Δομική Καθοδήγηση:** Η διατήρηση ανατομικών ορίων και δομών
- **Συνοδευτική Πληροφορία:** Αντιστάθμιση απώλειας πληροφορίας από την υποδειγματοληψία
- **Κανονικοποίηση Περιορισμών:** Μείωση του εύρους λύσεων του μη-κανονικοποιημένου προβλήματος

1.2.3 Το Δίλημμα: Ερμηνευσιμότητα vs Απόδοση

Οι σύγχρονες προσεγγίσεις υπερανάλυσης διαίρονται σε δύο κατηγορίες με διαφορετικά χαρακτηριστικά:

Παραδοσιακές Μέθοδοι Αραιών Αναπαραστάσεων: Προσφέρουν θεωρητική βάση και ερμηνευσιμότητα αλλά υστερούν σε υπολογιστική αποδοτικότητα και δεν είναι εύκολα επεκτάσιμες.

Μέθοδοι Βαθιάς Μάθησης (Deep Learning): Επιτυγχάνουν εξαιρετική απόδοση αλλά λειτουργούν ως μαύρα-κουτιά (black-box systems) που δεν παρέχουν την απαραίτητη ερμηνευσιμότητα για κλινικές εφαρμογές.

1.2.4 Κλινική Ανάγκη και Ερμηνευσιμότητα

Στο ιατρικό περιβάλλον, η ερμηνευσιμότητα δεν είναι απλώς επιθυμητή αλλά απαραίτητη. Οι κλινικοί ειδικοί πρέπει να κατανοούν πώς και γιατί ένα σύστημα λαμβάνει συγκεκριμένες αποφάσεις, ιδιαίτερα όταν αυτές επηρεάζουν τη διάγνωση και τη θεραπεία. Επιπλέον, οι ρυθμιστικές αρχές απαιτούν εξηγήσιμα/ερμηνεύσιμα συστήματα Τεχνητής Νοημοσύνης για ιατρικές συσκευές.

1.3 Προτεινόμενη Λύση και Συνεισφορές

Η ενότητα αυτή παρουσιάζει τη βασική προσέγγιση της εργασίας που βασίζεται στο παράδειγμα Βαθιάς Αναδίπλωσης (Deep Unfolding paradigm) και το καινοτόμο LMCSC μοντέλο. Περιγράφει πώς η προτεινόμενη μέθοδος αντιμετωπίζει το δίλημμα ερμηνευσιμότητας-απόδοσης μέσω της ενσωμάτωσης θεωρητικών αρχών των αραιών αναπαραστάσεων (sparse representations) σε σύγχρονες αρχιτεκτονικές Συνελικτικών Νευρωνικών Δικτύων (CNN) , ενώ παράλληλα επικεντρώνεται στην κλινικά σημαντική εφαρμογή της διάγνωσης Σκλήρυνσης Κατά Πλάκας (MS).

Η προτεινόμενη λύση βασίζεται στο παράδειγμα βαθιάς αναδίπλωσης (deep unfolding paradigm) [TMZ2021], το οποίο μετατρέπει επαναληπτικούς αλγορίθμους βελτιστοποίησης σε ένα συνελκτικό νευρωνικό δίκτυο. Αυτή η προσέγγιση διατηρεί τη θεωρητική βάση των αραιών αναπαραστάσεων ενώ παράλληλα αξιοποιεί την υπολογιστική αποδοτικότητα των τεχνικών Βαθιάς Μάθησης (Deep Learning).

Η επικύρωση του προτεινόμενου συστήματος LMCSC πραγματοποιείται στο σύνολο δεδομένων MS-MRI [LGK2018], όπου ο στόχος είναι η τετραπλάσια ($\times 4$) υπερανάλυση εικόνων T2-σταθμισμένων (T2W) χαμηλής ανάλυσης, με τη χρήση εικόνων T1-σταθμισμένων (T1W) υψηλής ανάλυσης ως βοηθητική πληροφορία καθοδήγησης. Οι εικόνες T2W είναι καθοριστικής σημασίας για την ακριβή ανίχνευση και χαρτογράφηση αποτυελινωτικών βλαβών στη Σκλήρυνση κατά Πλάκας, καθιστώντας τη βελτίωση της χωρικής τους ανάλυσης μέσω υπολογιστικών μεθόδων κλινικά κρίσιμη για τη διαγνωστική ακρίβεια και την παρακολούθηση της νόσου.

1.3.1 Κύριες Συνεισφορές

Θεωρητική Επέκταση: Ανάπτυξη του πλαισίου LMCSC που γεφυρώνει την παραδοσιακή θεωρία αραιής κωδικοποίησης [ELA2010] με τις σύγχρονες συνελκτικές αρχιτεκτονικές.

Αρχιτεκτονική Καινοτομία: Σχεδιασμός διπλού-κλάδου αρχιτεκτονικής με μαθησιακούς (learnable) μηχανισμούς σύζευξης για αποδοτική μεταφορά πληροφοριών μεταξύ των εικόνων.

Κλινική Επικύρωση: Εκτεταμένη επικύρωση σε πραγματικά δεδομένα MRI.

Πλαίσιο Υλοποίησης: Ανάπτυξη ολοκληρωμένου πλαισίου εκπαίδευσης και αξιολόγησης με βελτιωμένες δυνατότητες οπτικοποίησης [TMZ2021].

1.4 Δομή της Εργασίας & Προσδοκίες

Αυτή η τελική ενότητα παρέχει έναν οδηγό για την οργάνωση και τη δομή ολόκληρης της διπλωματικής εργασίας, περιγράφοντας το περιεχόμενο κάθε κεφαλαίου και τον τρόπο που συνδέονται μεταξύ τους. Επιπλέον, διατυπώνει τις προσδοκίες για τα αποτελέσματα της έρευνας και τον αναμενόμενο επιστημονικό και κλινικό αντίκτυπο της προτεινόμενης προσέγγισης στο πεδίο της ιατρικής απεικόνισης.

1.4.1 Οργάνωση Κεφαλαίων

Η εργασία οργανώνεται σε πέντε κεφάλαια:

Κεφάλαιο 1: Περιγραφή Του Προβλήματος Παρουσίαση του προβλήματος της υπερανάλυσης ιατρικών εικόνων MRI, της αναγκαιότητας για ερμηνεύσιμες λύσεις, και της προτεινόμενης προσέγγισης με χρήση τεχνικών βαθιάς αναδίπλωσης (deep-unfolding).

Κεφάλαιο 2: Θεωρητικό Υπόβαθρο Παρουσίαση της θεωρητικής βάσης των αραιών αναπαραστάσεων (sparse representations), της συνελκτικής αραιής κωδικοποίησης (convolutional sparse coding), των γραμμικών αντίστροφων προβλημάτων (linear inverse problems) και του παραδείγματος βαθιάς αναδίπλωσης (deep unfolding paradigm).

Κεφάλαιο 3: Μεθοδολογία Λεπτομερής περιγραφή της προτεινόμενης αρχιτεκτονικής LMCS, μαθηματική διατύπωση του αλγορίθμου, λεπτομέρειες υλοποίησης (implementation details) και στρατηγικές εκπαίδευσης (training strategies).

Κεφάλαιο 4: Πειραματική Αξιολόγηση Περιγραφή των συνόλων δεδομένων (datasets), πειραματικής διάταξης (experimental setup), ποσοτικών, ποιοτικών-οπτικών αποτελεσμάτων, σύγκρισης με υπάρχουσες μεθόδους (existing methods) και κλινικών επιπτώσεων (clinical implications).

Κεφάλαιο 5: Συμπεράσματα & Μελλοντικές Κατευθύνσεις Σύνοψη και ερμηνεία των αποτελεσμάτων, παρουσίαση των κύριων συνεισφορών της εργασίας, αναγνώριση των περιορισμών της προτεινόμενης προσέγγισης, και προτάσεις για μελλοντικές ερευνητικές κατευθύνσεις στον τομέα της ερμηνεύσιμης υπερανάλυσης με πολλούς τύπους ιατρικών εικόνων.

1.4.2 Προσδοκίες & Αντίκτυπος

Η επιτυχής υλοποίηση της προτεινόμενης προσέγγισης αναμένεται να παράσχει μια γενικεύσιμη (robust) και κλινικά εφαρμόσιμη λύση για την Υπερανάλυση Ιατρικών

Εικόνων MRI. Τα αναμενόμενα αποτελέσματα περιλαμβάνουν επίτευξη ανταγωνιστικής απόδοσης State-Of-The-Art (41.74dB PSNR) ενώ παράλληλα διατηρείται και αποδεικνύεται η ικανότητα ερμηνείας των αποτελεσμάτων, καθιστώντας ικανή την λύση για κλινικές εφαρμογές.

Η εργασία συνεισφέρει στην ανάπτυξη του πεδίου που σχετίζεται με την ερμηνευσιμότητα της Τεχνητής Νοημοσύνης στο χώρο της Ιατρικής Απεικόνισης, προσφέροντας μια ισορροπημένη λύση μεταξύ υψηλής απόδοσης και κλινικής εφαρμοσιμότητας που μπορεί να αποτελέσει το θεμέλιο για μελλοντικές εξελίξεις στην ιατρική απεικόνιση. Τα αποτελέσματα αναμένεται να συμβάλουν στην ανάπτυξη αξιόπιστων εργαλείων βαθιάς μάθησης για βίο-ιατρικές εφαρμογές [YCH2020].

Κεφάλαιο 2: Θεωρητικό Υπόβαθρο

Το παρόν κεφάλαιο παρουσιάζει τη θεωρητική βάση που υποστηρίζει την ανάπτυξη της προτεινόμενης προσέγγισης. Η ανάλυση ξεκινά από τα θεμελιώδη στοιχεία των αραιών αναπαραστάσεων και προχωρά σταδιακά στις προηγμένες τεχνικές βαθιάς αναδίπλωσης και μάθησης με πολλές τροπικότητες. Η λεπτομερής παρουσίαση αυτών των θεωρητικών εργαλείων είναι απαραίτητη για την πλήρη κατανόηση της αρχιτεκτονικής και της λειτουργίας του συστήματος που αναπτύχθηκε. Κάθε ενότητα παρέχει τόσο τη μαθηματική διατύπωση όσο και την θεωρητική εξήγηση των εννοιών, δημιουργώντας έναν ολοκληρωμένο οδηγό από τις βασικές αρχές έως τις σύγχρονες εφαρμογές στην ιατρική απεικόνιση.

2.1 Γραμμικά Αντίστροφα Προβλήματα στην

Επεξεργασία Εικόνas

Η επεξεργασία ιατρικών εικόνων συχνά περιλαμβάνει την επίλυση αντίστροφων προβλημάτων, όπου στόχος αποτελεί η ανάκτηση μιας άγνωστης εικόνας υψηλής ποιότητας από υποβαθμισμένες παρατηρήσεις. Τα γραμμικά αντίστροφα προβλήματα παρουσιάζουν ιδιαίτερο ενδιαφέρον λόγω της μαθηματικής φύσης τους και της ευρείας εφαρμογής τους σε κλινικές εφαρμογές όπως η υπερανάλυση εικόνων μαγνητικής τομογραφίας.

2.1.1 Μαθηματική Διατύπωση

Τα γραμμικά αντίστροφα προβλήματα αποτελούν θεμελιώδη κατηγορία στην επεξεργασία εικόνας [RSC2008] και χαρακτηρίζονται από τη σχέση:

$$y = Lx + \eta \quad \text{εξ. (2.1)}$$

όπου:


- $x \in R^k$ αντιπροσωπεύει τη διανυσματική μορφή της άγνωστης πηγαίας εικόνας υψηλής ανάλυσης
- $y \in R^n$ περιέχει τις υποβαθμισμένες παρατηρήσεις (θολωμένες, υποδειγματοληπτικές)
- $\eta \in R^n$ εκφράζει τον προσθετικό θόρυβο
- $L \in R^{n \times k}$ με $n < k$ αποτελεί τον γραμμικό τελεστή παρατήρησης

Στο πλαίσιο της υπερανάλυσης εικόνων (image super-resolution), ο γραμμικός τελεστής L εκφράζεται ως το γινόμενο δύο λειτουργιών:

- $L = EH$

όπου E αντιπροσωπεύει τον τελεστή υποδειγματοληψίας (downsampling operator) και H το φίλτρο θολώματος (blurring filter). Η **εξίσωση (2.1)** εμφανίζεται σε ποικίλες εφαρμογές επεξεργασίας εικόνας, συμπεριλαμβανομένων της αποκατάστασης εικόνας (image restoration), της συμπλήρωσης εικόνας (image inpainting) και της αφαίρεσης θορύβου (denoising).

Εικόνα 2.1.1



Εικόνα 2.1.1
α) Αρχικό Σήμα Πληροφορίας

Εικόνα 2.1.1
β) Αραιή Αναπαράσταση Σήματος

2.1.2 Αόριστα (Ill-posed) Χαρακτηριστικά & Ανάγκη Για Κανονικοποίηση

Από την φύση του το πρόβλημα είναι μη καλά ορισμένο και απαιτούνται τεχνικές κανονικοποίησης για τη σταθεροποίηση της λύσης [TSW2010]. Ακόμη και όταν ο γραμμικός τελεστής παρατήρησης L είναι γνωστός, το πρόβλημα της μορφής **(2.1)** χαρακτηρίζεται ως κακώς-τιθέμενο και απαιτεί επιπρόσθετη κανονικοποίηση (regularization) για την επίλυσή του. Αυτό προκύπτει από τρεις κύριους παράγοντες:

Μη-μοναδικότητα λύσης: Η συνθήκη $n < k$ σημαίνει ότι υπάρχουν περισσότεροι άγνωστοι από εξισώσεις, οδηγώντας σε υποορισμένο σύστημα με άπειρες δυνατές λύσεις.

Ευαισθησία στον θόρυβο: Μικρές διαταραχές στις παρατηρήσεις y μπορούν να οδηγήσουν σε δραστικά διαφορετικές λύσεις x , καθιστώντας το πρόβλημα ασταθές.

Απώλεια πληροφορίας: Η διαδικασία υποδειγματοληψίας και θολώματος αφαιρεί μη-αναστρέψιμες πληροφορίες από την αρχική εικόνα.

2.1.3 Στρατηγικές Κανονικοποίησης

Για την αντιμετώπιση των προκλήσεων αυτών των προβλημάτων, η ερευνητική κοινότητα αναπτύσσει διάφορες στρατηγικές κανονικοποίησης που εισάγουν επιπρόσθετες υποθέσεις ή προτιμήσεις για τη λύση. Οι κυριότερες προσεγγίσεις περιλαμβάνουν:

Tikhonov Κανονικοποίηση: Εισάγει έναν όρο ομαλότητας της μορφής $|x|_2^2$, επιβάλλοντας λύσεις με μικρή ενέργεια.

Total Variation (TV) Κανονικοποίηση: Προωθεί λύσεις με περιορισμένη διακύμανση, διατηρώντας έντονες ακμές ενώ εξομαλύνει ομογενείς περιοχές.

Sparsity-based Κανονικοποίηση: Αξιοποιεί την παρατήρηση ότι φυσικές εικόνες παρουσιάζουν αραιή δομή σε κατάλληλους χώρους μετασχηματισμού, όπως θα αναλυθεί λεπτομερώς στην επόμενη ενότητα.

Η αραιότητα (sparsity) έχει αναδειχθεί ως ιδιαίτερα αποτελεσματική μορφή κανονικοποίησης για προβλήματα υπερανάλυσης εικόνων, καθώς εκμεταλλεύεται την εγγενή δομή των φυσικών εικόνων. Αυτή η παρατήρηση αποτελεί τη βάση για την ανάπτυξη των αραιών αναπαραστάσεων που θα εξεταστούν στη συνέχεια.

2.1.4 Εφαρμογές Στην Ιατρική Απεικόνιση

Στον τομέα της ιατρικής απεικόνισης, τα γραμμικά αντίστροφα προβλήματα εμφανίζονται σε διάφορες κλινικές εφαρμογές:

Μαγνητική Τομογραφία (MRI): Η ανακατασκευή εικόνων από μετρήσεις συμπιεσμένης ανίχνευσης (compressed sensing measurements), η υπερανάλυση εικόνων χαμηλής ανάλυσης και η σύντηξη διαφορετικών εικόνων (multimodal fusion).

Υπολογιστική Τομογραφία (CT): Η ανακατασκευή από αραιές προβολές (sparse-view projections) και η αφαίρεση παραμορφώσεων (artifact removal).

Υπερηχογραφία: Η βελτίωση της ανάλυσης και του λόγου σήματος προς θόρυβο μέσω προηγμένων τεχνικών ανακατασκευής.

Η επιτυχής επίλυση αυτών των προβλημάτων απαιτεί την ανάπτυξη εξειδικευμένων αλγορίθμων που να αξιοποιούν τα ιδιαίτερα χαρακτηριστικά των ιατρικών εικόνων, όπως η χωρική συνέχεια των ανατομικών δομών και η συσχέτιση μεταξύ διαφορετικών

τύπων απεικόνισης. Αυτές οι παρατηρήσεις οδηγούν φυσικά στην εξέταση των αραιών αναπαραστάσεων ως μέσου αποτελεσματικής κανονικοποίησης.

2.2 Αραιές Αναπαραστάσεις

Οι αραιές αναπαραστάσεις (sparse representations) αποτελούν ισχυρό εργαλείο για την αντιμετώπιση των αόριστων προβλημάτων που παρουσιάστηκαν στην προηγούμενη ενότητα. Η κεντρική ιδέα βασίζεται στην παρατήρηση ότι πολλά φυσικά σήματα και εικόνες μπορούν να εκφραστούν αποδοτικά χρησιμοποιώντας έναν μικρό αριθμό συντελεστών από ένα κατάλληλα σχεδιασμένο λεξικό. Αυτή η εγγενής αραιότητα παρέχει έναν φυσικό μηχανισμό κανονικοποίησης που διατηρεί τα σημαντικά χαρακτηριστικά του σήματος ενώ απορρίπτει τον θόρυβο και τις περιττές πληροφορίες.

2.2.1 Θεωρητικά Θεμέλια

Ένα διάνυσμα $u \in R^m$ θεωρείται αραιό όταν περιέχει λίγα μη-μηδενικά στοιχεία. Η αραιότητα ποσοτικοποιείται μέσω της ψευδο-νόρμας l_0 :

$$|u|_0 = |\{i: u_i \neq 0\}|$$

που μετρά τον αριθμό των μη-μηδενικών στοιχείων του διανύσματος. Για αραιά διανύσματα ισχύει η σχέση $|u|_0 = s \ll m$, όπου s αντιπροσωπεύει το επίπεδο αραιότητας.

Βασική Διατύπωση

Έστω ένα σήμα $x \in R^n$ που αναπαρίσταται ως γραμμικός συνδυασμός των στηλών ενός λεξικού $\Psi \in R^{n \times m}$:

$$x = \Psi u \quad \text{εξ. (2.2)}$$

όπου $\Psi = [\psi_1, \psi_2, \dots, \psi_m]$ και κάθε $\psi_i \in R^n$ αποτελεί ένα άτομο (atom) του λεξικού. Το διάνυσμα συντελεστών $u \in R^m$ περιέχει τα βάρη για κάθε άτομο όπως φαίνεται και στην **εξίσωση (2.2)**.

Υπερπλήρη Λεξικά (Overcomplete Dictionaries)

Όταν $m > n$, το λεξικό Ψ χαρακτηρίζεται ως υπερπλήρες (overcomplete), παρέχοντας περισσότερα άτομα από τις διαστάσεις του σήματος. Λεξικά με αυτήν την ιδιότητα προσφέρουν μεγαλύτερη ευελιξία στην αναπαράσταση, επιτρέποντας την καλύτερη προσαρμογή στα χαρακτηριστικά του σήματος. Ωστόσο, ταυτόχρονα δημιουργείται το πρόβλημα της μη-μοναδικότητας της λύσης, καθώς υπάρχουν άπειρες δυνατές αναπαραστάσεις για το ίδιο σήμα.

Φυσική Αιτιολόγηση της Αραιότητας

Η αραιότητα παρατηρείται ευρέως στη φύση και τα ψηφιακά σήματα:

- **Εικόνες:** Παρουσιάζουν αραιότητα σε μετασχηματισμούς όπως το Διακριτός Μετασχηματισμός Συνημίτονου (Discrete Cosine Transform – DCT)
- **Ηχητικά σήματα:** Εμφανίζουν αραιή δομή στο πεδίο της συχνότητας μέσω του Fourier μετασχηματισμού
- **Βιολογικά σήματα:** Η αραιή ενεργοποίηση των νευρώνων του εγκεφάλου και η αραιή κωδικοποίηση στο οπτικό σύστημα
- **Φυσικά φαινόμενα:** Πολλά περιγράφονται από λίγες βασικές συνιστώσες

2.2.2 Προβλήματα Βελτιστοποίησης & Αραιές Αναπαραστάσεις

Το Πρόβλημα l_0 Ελαχιστοποίησης

Η εύρεση της αραιότερης αναπαράστασης ενός σήματος διατυπώνεται ως το πρόβλημα βελτιστοποίησης:

$$\min_u \|u\|_0 \quad \text{υπό τον περιορισμό} \quad x = \Psi u \quad \text{εξ. (2.3)}$$

Αυτό το πρόβλημα αναζητά την αναπαράσταση με τον ελάχιστο αριθμό μη-μηδενικών συντελεστών που αναπαράγει ακριβώς το δεδομένο σήμα. Δυστυχώς, το πρόβλημα της **εξίσωσης (2.3)** είναι υπολογιστικά δύσκολο (NP-hard), καθιστώντας την εξαντλητική αναζήτηση υπολογιστικά ανέφικτη για πρακτικές εφαρμογές μεγάλης κλίμακας.

Η l_1 -κυρτή Χαλάρωση (Convex Relaxation)

Για την αντιμετώπιση του υπολογιστικού προβλήματος της l_0 ελαχιστοποίησης. Στην **εξίσωση (2.4)** αναπτύσσεται η κυρτή χαλάρωση μέσω της αντικατάστασης της l_0 ψευδο-νόρμας με την l_1 νόρμα:

$$\min_u \|u\|_1 \quad \text{υπό τον περιορισμό} \quad x = \Psi u \quad \text{εξ. (2.4)}$$

όπου $\|u\|_1 = \sum_i |u_i|$. Αυτή η προσέγγιση οδηγεί σε κυρτό πρόβλημα βελτιστοποίησης με πολυωνυμική υπολογιστική πολυπλοκότητα.

Προσεγγιστική Διατύπωση (LASSO)

Στην πράξη, λόγω της παρουσίας θορύβου και ανακρίβειών, χρησιμοποιείται η χαλαρωμένη μορφή που εισάγει έναν όρο απόστασης από τα δεδομένα:

$$\min_u \frac{1}{2} \|x - \Psi u\|_2^2 + \lambda \|u\|_1 \quad \text{εξ. (2.5)}$$

όπου $\lambda > 0$ αποτελεί την παράμετρο κανονικοποίησης που ελέγχει την αντιστάθμιση μεταξύ της ακρίβειας αναπαράστασης και της αραιότητας, σύμφωνα με την **εξίσωση**

(2.5). Αυτή η διατύπωση είναι γνωστή ως LASSO (Least Absolute Shrinkage and Selection Operator).

Για την επίλυση του προβλήματος αντίστροφης εικόνας με αραιή κανονικοποίηση, συνδυάζουμε τις *εξισώσεις (2.1), (2.2), (2.5)* για να λάβουμε την *εξίσωση (2.6)*:

$$\min_u \frac{1}{2} \|y - L\Psi u\|_2^2 + \lambda \|u\|_1 \quad \text{εξ. (2.6)}$$

Θέτοντας $D = L\Psi$, το πρόβλημα απλοποιείται στη μορφή της *εξίσωσης (2.7)*:

$$\min_u \frac{1}{2} \|y - Du\|_2^2 + \lambda \|u\|_1 \quad \text{εξ. (2.7)}$$

2.2.3 Iterative Soft Thresholding Algorithm (ISTA)

Για την αποδοτική επίλυση του προβλήματος της *εξίσωσης (2.7)*, αναπτύχθηκε ο *Iterative Soft Thresholding Algorithm - ISTA*. Η t -οστή επανάληψη του ISTA περιγράφεται από την *εξίσωση (2.8)*:

$$u^{(t)} = \phi_\gamma \left(u^{(t-1)} - \frac{1}{L} D^T (Du^{(t-1)} - y) \right) \quad \text{εξ. (2.8)}$$

όπου L αποτελεί τη σταθερά Lipschitz της βαθμίδας $\nabla f(u) = D^T(Du - y)$, και ϕ_γ είναι ο τελεστής (soft thresholding) που ορίζεται ως:

$$\phi_\gamma(u_i) = \text{sign}(u_i) = \max(0, |u_i| - \gamma) \quad \text{εξ. (2.9)}$$

όπου $\gamma = \lambda/L$ και $\text{sign}(\cdot)$ η συνάρτηση πρόσημου.

Ο αλγόριθμος ISTA αποτελεί κλασική μέθοδο για την επίλυση αραιών προβλημάτων βελτιστοποίησης [DDM2004], ενώ παραλλαγές όπως ο *FISTA* παρέχουν ταχύτερη σύγκλιση [BTE2009].

Ερμηνεία του Soft Thresholding

Ο τελεστής εκτελεί δύο λειτουργίες ταυτόχρονα:

- **Συρρίκνωση (Shrinkage):** Μειώνει το μέγεθος όλων των συντελεστών κατά γ
- **Επιλογή (Selection):** Θέτει σε μηδέν τους συντελεστές με απόλυτη τιμή μικρότερη από γ

Αυτή η συμπεριφορά προωθεί την αραιότητα καθώς μικροί συντελεστές που πιθανότατα αντιστοιχούν σε θόρυβο εξαλείφονται, ενώ οι σημαντικοί συντελεστές διατηρούνται αλλά μειώνονται ελαφρώς.

2.2.4 Θεωρητικές Εγγυήσεις

Ιδιότητα Περιορισμένης Ισομετρίας (Restricted Isometry Property - RIP)

Η ιδιότητα περιορισμένης ισομετρίας παρέχει συνθήκες υπό τις οποίες η l_1 ελαχιστοποίηση εγγυάται την ανάκτηση της αραιής λύσης. Ένας πίνακας \mathbf{D} ικανοποιεί την RIP τάξης s με σταθερά δ_s αν:

$$(1 - \delta_s)\|u\|_2^2 \leq \|\mathbf{D}u\|_2^2 \leq (1 + \delta_s)\|u\|_2^2$$

για όλα τα s -αραιά διανύσματα u .

Αμοιβαία Συνοχή (Mutual Coherence)

Η αμοιβαία συνοχή μετρά τη μέγιστη συσχέτιση μεταξύ διαφορετικών στηλών του λεξικού:

$$\mu(\mathbf{D}) = \max_{i \neq j} \frac{|d_i^T d_j|}{\|d_i\|_2 \|d_j\|_2}$$

Χαμηλή τιμή υποδηλώνει ότι τα άτομα του λεξικού είναι "σχεδόν ορθογώνια", βελτιώνοντας τις συνθήκες για ακριβή αραιή ανάκτηση.

Εγγυήσεις Ανάκτησης

Υπό κατάλληλες συνθήκες η l_1 ελαχιστοποίηση εγγυάται:

- **Ακριβή αποκατάσταση** για επαρκώς αραιά σήματα χωρίς θόρυβο
- **Σταθερή προσέγγιση** για μετρίως αραιά σήματα ή παρουσία θορύβου

Αυτές οι θεωρητικές εγγυήσεις παρέχουν τη μαθηματική βάση για την αξιοπιστία των αραιών αναπαραστάσεων στις εφαρμογές επεξεργασίας εικόνας. Ωστόσο, η εφαρμογή των παραδοσιακών μεθόδων σε εικόνες παρουσιάζει πρακτικούς περιορισμούς που οδηγούν στην ανάπτυξη των συνελκτικών επεκτάσεων που θα εξεταστούν στην επόμενη ενότητα. (denoising).

2.3 Συνελκτικές Αραιές Αναπαραστάσεις (Convolutional Sparse Coding)

Η εφαρμογή των παραδοσιακών αραιών αναπαραστάσεων σε εικόνες μεγάλου μεγέθους αντιμετωπίζει σημαντικές πρακτικές προκλήσεις. Οι συνελκτικές αραιές αναπαραστάσεις (Convolutional Sparse Coding - CSC) αναπτύχθηκαν για να ξεπεράσουν αυτούς τους περιορισμούς, επιτρέποντας την άμεση επεξεργασία ολόκληρων εικόνων διατηρώντας παράλληλα τη χωρική συνέχεια και την υπολογιστική αποδοτικότητα.

2.3.1 Εφαρμογή Σε Ολόκληρη Την Εικόνα

Εφαρμογή Σε Τμήματα Της Εικόνας

Οι παραδοσιακές εφαρμογές των αραιών αναπαραστάσεων σε εικόνες ακολουθούν την προσέγγιση επεξεργασίας τμημάτων (patches), όπου η εικόνα διαιρείται σε μικρότερα επικαλυπτόμενα τμήματα που την επεξεργάζονται ανεξάρτητα. Αυτή η προσέγγιση παρουσιάζει ουσιώδεις περιορισμούς:

Συνοριακά Τεχνουργήματα: Η ανεξάρτητη επεξεργασία γειτονικών τμημάτων οδηγεί σε ασυνέχειες στα όρια των τμημάτων της εικόνας, καθώς δεν λαμβάνεται υπόψη η συνοχή των εικονοστοιχείων σε επικαλυπτόμενες περιοχές.

Υπολογιστικό Κόστος: Η επικάλυψη των τμημάτων αυτών απαιτεί πολλαπλές επεξεργασίες για την ίδια περιοχή της εικόνας, αυξάνοντας δραματικά το υπολογιστικό κόστος.

Απώλεια Ολικής Δομής: Οι τοπικές μέθοδοι δεν μπορούν να αξιοποιήσουν ολικές δομές της εικόνας που εκτείνονται πέρα από τα όρια ενός μεμονωμένου τμήματος.

Κίνητρα για Συνελικτικές Επεκτάσεις

Η ανάγκη για άμεση εφαρμογή σε ολόκληρες εικόνες, διατηρώντας παράλληλα τη χωρική συνέχεια, οδήγησε στην ανάπτυξη των μεθόδων συνελικτικής αραιής κωδικοποίησης. Αυτές οι μέθοδοι αντικαθιστούν τον πολλαπλασιασμό πινάκων με συνελικτικές λειτουργίες, επιτρέποντας την επεξεργασία εικόνων οποιουδήποτε μεγέθους χωρίς τους περιορισμούς των παραδοσιακών προσεγγίσεων.

2.3.2 Μαθηματική Διατύπωση Της Συνελικτικής Αραιής Κωδικοποίησης (Convolutional Sparse Coding)

Βασική Αναπαράσταση

Έστω μια εικόνα $Y \in R^{n_1 \times n_2}$ και ένα συνελικτικό λεξικό $\mathbf{D} \in R^{p_1 \times p_2 \times k}$ με k άτομα $\mathbf{D}_i \in R^{p_1 \times p_2}$, όπου $i = 1, \dots, k$. Η εικόνα αναπαρίσταται ως γραμμικός συνδυασμός των συνελίξεων των ατόμων του λεξικού με τους αντίστοιχους αραιούς χάρτες χαρακτηριστικών:

$$Y = \sum_{i=1}^k \mathbf{D}_i * U_i$$

όπου $U_i \in R^{n_1 \times n_2}$ είναι οι αραιοί χάρτες χαρακτηριστικών (sparse feature maps) και $*$ συμβολίζει την πράξη της συνέλιξης.

Μαθηματική Ανάλυση της Συνέλιξης

Η πράξη της συνέλιξης μεταξύ ενός φίλτρου $\mathbf{D} \in R^{p_1 \times p_2}$ και ενός χάρτη χαρακτηριστικών $U \in R^{n_1 \times n_3}$ ορίζεται ως:

$$(D * U)[i, j] = \sum_{m=0}^{p_1-1} \sum_{n=0}^{p_2-1} \mathbf{D}[m, n] \cdot U[i + m, j + n]$$

όπου i, j αντιπροσωπεύουν τις χωρικές συντεταγμένες στην εικόνα εξόδου. Η συνέλιξη υπολογίζει το εσωτερικό γινόμενο μεταξύ του φίλτρου και κάθε τοπικής περιοχής της εικόνας, επιτρέποντας την εξαγωγή συγκεκριμένων χαρακτηριστικών και μοτίβων (patterns).

Πρόβλημα Βελτιστοποίησης Συνελικτικής Αραιής Κωδικοποίησης

Το πρόβλημα βελτιστοποίησης της συνελικτικής αραιής κωδικοποίησης διατυπώνεται αρχικά στην αυστηρή του μορφή ως ελαχιστοποίηση της συνολικής αραιότητας:

$$\min_{U_i} \sum_i i = 1^k |U_i|_1 \quad \text{υπό τον περιορισμό} \quad Y = \sum_i i = 1^k \mathbf{D}_i * U_i$$

Στην πράξη, λόγω της παρουσίας θορύβου και ανακρίβειών, χρησιμοποιείται η χαλαρωμένη μορφή που εισάγει έναν τον όρο κανονικοποίησης της l_1 νόρμας :

$$\min_{D, U} \frac{1}{2} \|Y - \sum_{i=1}^k D_i * U_i\|_F^2 + \lambda \sum_{i=1}^k \|U_i\|_1,$$

όπου $\|A\|_F = \sqrt{\sum_i \sum_j |a_{ij}|^2}$ είναι η νόρμα Frobenius, $\mathbf{D}_i \in R^{p_1 \times p_2}, i = 1, \dots, k$, είναι τα άτομα ενός συνελικτικού λεξικού $\mathbf{D} \in R^{p_1 \times p_2 \times k}$, και $U_i \in R^{n_1 \times n_2}, i = 1, \dots, k$, είναι οι αραιοί χάρτες χαρακτηριστικών ως προς το \mathbf{D} . Η l_1 -νόρμα υπολογίζει το άθροισμα των απόλυτων τιμών των στοιχείων του U_i (σαν να το U_i είναι ανεπτυγμένο ως διάνυσμα).

Η παράμετρος κανονικοποίησης $\lambda > 0$ ελέγχει την αντιστάθμιση μεταξύ της ακρίβειας αναπαράστασης και της αραιότητας.

2.4 Πλαίσιο Βαθιάς Αναδίπλωσης

Η Βαθιά Αναδίπλωση (deep unfolding) αποτελεί καινοτόμα προσέγγιση που γεφυρώνει τη θεωρία των επαναληπτικών αλγορίθμων βελτιστοποίησης με τα σύγχρονα βαθιά νευρωνικά δίκτυα. Αντί του συνήθους διλήμματος μεταξύ ερμηνευσιμότητας και υπολογιστικής αποδοτικότητας, η βαθιά αναδίπλωση προσφέρει μια ισορροπημένη λύση που διατηρεί την ερμηνευσιμότητα των παραδοσιακών μεθόδων ενώ αξιοποιεί τα πλεονεκτήματα της μηχανικής μάθησης.

2.4.1 Αρχές Βαθιάς Αναδίπλωσης

Η βαθιά αναδίπλωση αποτελεί παράδειγμα που συνδυάζει τη θεωρητική βάση των επαναληπτικών αλγορίθμων με τη μαθησιακή ισχύ των νευρωνικών δικτύων [HRW2014].

Θεμελιώδης Ιδέα

Η βασική αρχή της βαθιάς αναδίπλωσης εδράζεται στη συνειδητοποίηση ότι οι επαναληπτικοί αλγόριθμοι βελτιστοποίησης εκτελούν μια σειρά καθορισμένων μαθηματικών λειτουργιών που δύνανται να αναπαρασταθούν ως στρώματα νευρωνικού δικτύου. Κάθε επανάληψη αντιστοιχεί σε ένα στρώμα, ενώ οι παράμετροι του αλγορίθμου μετατρέπονται σε μαθησιακές παραμέτρους του δικτύου.

Έστω ένας επαναληπτικός αλγόριθμος της μορφής:

$$\mathbf{x}^{(t+1)} = f(\mathbf{x}^{(t)}, \mathbf{y}; \theta)$$

όπου $\mathbf{x}^{(t)}$ αντιπροσωπεύει την εκτίμηση στην επανάληψη t , \mathbf{y} τα παρατηρημένα δεδομένα και θ τις παραμέτρους του αλγορίθμου. Στη βαθιά αναδίπλωση, αυτός μετατρέπεται σε:

$$\mathbf{x}^{(t+1)} = f(\mathbf{x}^{(t)}, \mathbf{y}; \boldsymbol{\theta}^{(t)})$$

όπου $\boldsymbol{\theta}^{(t)}$ αντιπροσωπεύουν μαθησιακές παραμέτρους που δύνανται να διαφέρουν σε κάθε στρώμα.

Πλεονεκτήματα της Βαθιάς Αναδίπλωσης

Η προσέγγιση αυτή προσφέρει σημαντικά πλεονεκτήματα σε σχέση με τις παραδοσιακές μεθόδους:

Ερμηνευσιμότητα: Κάθε στρώμα διαθέτει σαφή φυσική σημασία, αντιστοιχώντας σε μία επανάληψη του αλγορίθμου βελτιστοποίησης. Αυτό επιτρέπει την κατανόηση του τι μαθαίνει το δίκτυο σε κάθε στάδιο.

Σταθερό Υπολογιστικό Κόστος: Αντί για μεταβλητό αριθμό επαναλήψεων μέχρι τη σύγκλιση, το αναδιπλωμένο δίκτυο εκτελεί σταθερό αριθμό λειτουργιών, καθιστώντας το κατάλληλο για εφαρμογές πραγματικού χρόνου.

Μαθησιακές Παράμετροι: Οι παράμετροι που παραδοσιακά επιλέγονται μαθεύονται πλέον από τα δεδομένα, βελτιώνοντας την απόδοση.

Πλήρως Μαθησιακή Εκπαίδευση: Ολόκληρο το σύστημα δύναται να εκπαιδευτεί από με βάση τις γνωστές μεθόδους κλίσεων για την ελαχιστοποίηση της αντικειμενικής συνάρτησης, στην οποία περιέχεται και η συνάρτηση σφάλματος.

2.4.2 Από ISTA σε LISTA:

Ανασκόπηση του ISTA

Όπως παρουσιάστηκε στην ενότητα 2.2.3 Iterative Soft Thresholding Algorithm (ISTA), για την επίλυση του προβλήματος της **εξίσωσης (2.7)** ο αλγόριθμος ISTA εκτελεί επαναλήψεις της μορφής της **(εξίσωσης 2.8)**:

$$\mathbf{u}^{(t)} = \phi_{\gamma} \left(\mathbf{u}^{(t-1)} - \frac{1}{L} \mathbf{D}^T (\mathbf{D} \mathbf{u}^{(t-1)} - \mathbf{y}) \right)$$

Μετασχηματισμός σε LISTA

Το LISTA (Learned ISTA) μετατρέπει τον ISTA σε νευρωνικό δίκτυο αναπαριστώντας κάθε επανάληψη ως στρώμα. Η βασική ιδέα βρίσκεται στην αναδιατύπωση της **εξίσωσης (2.8)**, σε μορφή νευρωνικού δικτύου με την **(εξίσωση 2.10)** ως:

$$\mathbf{u}^{(t)} = \phi_{\gamma} (\mathbf{S} \mathbf{u}^{(t-1)} + \mathbf{W} \mathbf{y}) \quad \text{εξ. (2.10)}$$


όπου:

- $\mathbf{S} = \mathbf{I} - \frac{1}{L} \mathbf{D}^T \mathbf{D}$ αποτελεί πίνακα βαρών που μαθαίνεται από τα δεδομένα
- $\mathbf{W} = \frac{1}{L} \mathbf{D}^T$ είναι μετασχηματισμός εισόδου
- $\gamma > 0$ παράμετρος κατωφλίου

Όλες οι παράμετροι αυτοί μαθαίνονται από τα δεδομένα

Στο σχήμα της **Εικόνας 2.4.2** παρουσιάζεται αναλυτικά τρόπος λειτουργίας του νευρωνικού δικτύου που προκύπτει από τον Αλγόριθμο ISTA. Παρατηρούμε πως σε κάθε στάδιο αναδίπλωσης εξαρτάται άμεσα τόσο από την εικόνα εισόδου όσο και από την αραιή αναπαράσταση του προηγούμενου σταδίου όπως παρουσιάζεται και στην ερευνητική εργασία.

Εικόνα 2.4.2: Σχηματική Απεικόνιση του Αλγορίθμου LISTA



Η μετατροπή του ISTA σε LISTA αποτέλεσε πρωτοποριακή εργασία στο χώρο της βαθιάς αναδίπλωσης [GLE2010], επιτρέποντας την εκμάθηση των παραμέτρων που παραδοσιακά επιλέγονταν ευρετικά.

Βασικές Καινοτομίες του LISTA

Οι κύριες καινοτομίες του LISTA περιλαμβάνουν:

Παράμετροι Εκμάθησης: Αντί των σταθερών τιμών που προκύπτουν από τη θεωρία, οι παράμετροι \mathbf{S} , \mathbf{W} , και γ μαθαίνονται από τα δεδομένα.

Παράμετροι Ανά Στρώμα: Κάθε στρώμα μπορεί να έχει ειδικές παραμέτρους $\mathbf{S}^{(t)}$, $\mathbf{W}^{(t)}$, $\gamma^{(t)}$, επιτρέποντας μεγαλύτερη ευελιξία.

Σταθερός Αριθμός Στρωμάτων: Χρησιμοποιείται σταθερός αριθμός στρωμάτων (συνήθως 2 έως 4), αντί επαναλήψεων μέχρι σύγκλιση.

2.4.3 Συνελικτικές Επεκτάσεις

Κίνητρα για Συνελικτικό LISTA

Η άμεση εφαρμογή του LISTA σε εικόνες ακολουθούσε αρχικά την patch-based προσέγγιση με τους περιορισμούς που αναφέρθηκαν στην ενότητα 2.3.1 [Πλήρων Εικόνων](#). Για την αντιμετώπιση αυτών των περιορισμών, αναπτύχθηκε η συνελικτική εκδοχή του LISTA που επιτρέπει την επεξεργασία ολόκληρων εικόνων.

Μαθηματική Διατύπωση του ACSC

Το Approximate Convolutional Sparse Coding (ACSC) επεκτείνει τη διατύπωση του LISTA στο συνελικτικό πεδίο. Η t -οστή επανάληψη του ACSC υπολογίζεται από την **εξίσωση (2.11)**:

$$U^{(t)} = \phi_{\gamma}(U^{(t-1)} - T * V * U^{(t-1)} + G * Y) \quad \text{εξ. (2.11)}$$

όπου:

- $U^{(t)} \in \mathbb{R}^{n_1 \times n_2 \times k}$ είναι οι αραιοί χάρτες χαρακτηριστικών στην επανάληψη t ,
- T, V, G είναι συνελικτικά φίλτρα και αντιπροσωπεύουν τις στρώσεις του δικτύου,
- $Y \in \mathbb{R}^{n_1 \times n_2}$ η εικόνα εισόδου
- ϕ_{γ} ο τελεστής soft-thresholding

Η επέκταση του LISTA στο συνελικτικό πεδίο με το ACSC [SRG2018] επέτρεψε την επεξεργασία πλήρων εικόνων έναντι τμημάτων, βελτιώνοντας σημαντικά την αποδοτικότητα.

Ερμηνεία των Συνελικτικών Τελεστών

Οι συνελικτικοί τελεστές στην **εξίσωση (2.11)** έχουν ειδική σημασία:

$G * Y$: Αντιστοιχεί στον όρο $\mathbf{W}\mathbf{y}$ της **εξίσωσης (2.10)** του LISTA, υπολογίζοντας την αρχική εκτίμηση από την εικόνα εισόδου.

$T * V * U^{(t-1)}$: Αντιστοιχεί στον όρο $Su^{(t-1)}$ εξίσωσης (2.10) του ISTA, υπολογίζοντας το βήμα της κλίσης (gradient step).

Συνέλιξη Αντιμετάθεσης (Transposed Convolution)

Στην πρακτική υλοποίηση, ο όρος $T * V * U^{(t-1)}$ συχνά υλοποιείται ως:

$$T^T * (V * U^{(t-1)})$$

όπου T^T αντιπροσωπεύει την αντιμετάθεση (transposed convolution), που αντιστοιχεί στην αντιμεταθετική λειτουργία στο συνελικτικό πεδίο.

2.4.4 Υπολογιστικά Πλεονεκτήματα & Αποδοτικότητα

Σύγκριση Υπολογιστικής Πολυπλοκότητας

Η σύγκριση της υπολογιστικής πολυπλοκότητας μεταξύ παραδοσιακών επαναληπτικών μεθόδων και βαθιάς αναδίπλωσης δείχνει σημαντικά πλεονεκτήματα:

Παραδοσιακές Μέθοδοι: $O(T \cdot M)$ όπου T ο (μεταβλητός) αριθμός επαναλήψεων για σύγκλιση και M το κόστος κάθε επανάληψης.

Deep Unfolding:

Training Phase: $O(b \cdot l \cdot c \cdot e)$

- b : batch size
- l : σταθερός αριθμός στρωμάτων ($L = 3$ στην περίπτωση σας)
- c : κόστος κάθε στρώματος
- e : αριθμός εποχών

Inference Phase: $O(L \cdot M) = O(3 \cdot M)$

- Σταθερό κόστος 3 στρωμάτων για ACSC και LMCSC modules

Παράλληλη επεξεργασία και Βελτιστοποίηση με Κάρτα Γραφικών (GPU)

Αυτά τα δίκτυα επωφελούνται σημαντικά από:

Επεξεργασία Παρτίδας: Παράλληλη επεξεργασία πολλαπλών εικόνων.

GPU Acceleration: Βελτιστοποιημένες CUDA πυρήνες για συνελικτικές λειτουργίες.

Αποδοτικότητα Μνήμης: Καλύτερη διαχείριση μνήμης μέσω αποθήκευσης σημείων για την ανάκτηση των κλίσεων της εκπαίδευσης από την τελευταία εποχή που πραγματοποιήθηκε (gradient checkpoints).

Η αποδοτικότητα των προσεγγίσεων βαθιάς αναδίπλωσης έχει αποδειχθεί σε διάφορες εφαρμογές αντίστροφων προβλημάτων [BSR2017], καθιστώντας τες ελκυστικές για εφαρμογές πραγματικού χρόνου.

2.4.5 Εκπαίδευση & Αρχικοποίηση

Στρατηγικές Αρχικοποίησης

Η αρχικοποίηση των παραμέτρων σε δίκτυα βαθιάς αναδίπλωσης μπορεί να γίνει με δύο τρόπους:

Θεωρητική Αρχικοποίηση: Οι παράμετροι S, W , αρχικοποιούνται με τις θεωρητικές τιμές από τον αντίστοιχο επαναληπτικό αλγόριθμο.

Τυχαία Αρχικοποίηση: Τυχαία αρχικοποίηση που επιτρέπει στο δίκτυο να μαθαίνει εντελώς νέες παραμέτρους.

Συνάρτηση Σφάλματος (Loss Functions) και Εκπαίδευση

Η εκπαίδευση των δικτύων βαθιάς αναδίπλωσης συνήθως χρησιμοποιεί συναρτήσεις σφάλματος της μορφής που περιγράφεται από την **εξίσωση (2.12)**:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N \|y_i - \hat{y}_i\|_2^2 + \alpha \mathcal{R}(\theta) \quad \text{εξ. (2.12)}$$

όπου y_i : η i -οστή πραγματική εικόνα, \hat{y}_i : η i -οστή ανακατασκευασμένη εικόνα από το μοντέλο, i : δείκτης που τρέχει από 1 έως N για κάθε δείγμα και $\mathcal{R}(\theta)$ ο όρος κανονικοποίησης για τις παραμέτρους του δικτύου.

Η επιτυχής εφαρμογή του deep unfolding στο convolutional sparse coding δημιουργεί τη βάση για την ενσωμάτωση πρόσθετων πληροφοριών από διαφορετικούς τύπους εικόνων (side information), οδηγώντας στην ανάπτυξη των προσεγγίσεων με εικόνα καθοδήγησης που θα εξεταστούν στην επόμενη ενότητα.

Κεφάλαιο 3: Περιγραφή Της Λύσης που Υλοποιήθηκε

Το παρόν κεφάλαιο παρουσιάζει τη μετάβαση από τη θεωρητική βάση που αναπτύχθηκε στο Κεφάλαιο 2, στην πρακτική υλοποίηση του προτεινόμενου συστήματος υπερανάλυσης με είσοδο δύο διαφορετικού τύπου εικόνων. Η ανάπτυξη της λύσης βασίζεται στην καινοτόμα ενσωμάτωση του LeSITA αλγορίθμου στο πλαίσιο της βαθιάς αναδίπλωσης, δημιουργώντας ένα σύστημα που συνδυάζει τη θεωρητική βάση των αραιών αναπαραστάσεων με την υπολογιστική αποδοτικότητα των σύγχρονων νευρωνικών δικτύων.

Η παρουσίαση οργανώνεται σε πέντε κύριες ενότητες που καλύπτουν το φάσμα από τα θεωρητικά θεμέλια έως τις λεπτομέρειες υλοποίησης. Αρχικά εξετάζονται οι θεωρητικές αρχές που διέπουν τη χρήση βοηθητικής πληροφορίας στην αραιή κωδικοποίηση και παρουσιάζεται ο LeSITA Αλγόριθμος. Στη συνέχεια περιγράφεται η συνολική αρχιτεκτονική του συστήματος και η προσέγγιση διπλού κλάδου (dual-branch) που επιτρέπει την αποδοτική αξιοποίηση πολλαπλών ακολουθιών MRI. Ακολουθεί λεπτομερής ανάλυση των επιμέρους δομοστοιχείων (modules) (ACSC, LMCSC, Reconstruction) και των μηχανισμών αλληλεπίδρασής τους.

3.1 Θεωρητικά Θεμέλια Της Λύσης

Το παρόν κεφάλαιο παρουσιάζει τη λεπτομερή περιγραφή της λύσης που αναπτύχθηκε για την αντιμετώπιση του προβλήματος της υπερανάλυσης ιατρικών εικόνων MRI διαφορετικών τύπων. Η προτεινόμενη προσέγγιση στηρίζεται στη θεωρητική βάση των αραιών αναπαραστάσεων με βοηθητική πληροφορία (side information) και υλοποιείται μέσω του παραδείγματος της βαθιάς αναδίπλωσης. Πριν από την παρουσίαση των τεχνικών λεπτομερειών της υλοποίησης, είναι απαραίτητη η κατανόηση των θεωρητικών θεμελίων που διέπουν τη λειτουργία του συστήματος.

3.1.1 Βοηθητική Πληροφορία (Side Information) στην Αραιή Κωδικοποίηση

Η ενσωμάτωση βοηθητικής πληροφορίας στα προβλήματα αραιής κωδικοποίησης αποτελεί τη θεμελιώδη καινοτομία της προτεινόμενης λύσης. Η βασική υπόθεση της εργασίας βασίζεται στην παρατήρηση ότι διαφορετικές τροπικότητες (modalities) απεικόνισης της ίδιας ανατομικής περιοχής τείνουν να έχουν παρόμοιες αραιές αναπαραστάσεις κάτω από κατάλληλα λεξικά.

Μαθηματική Διατύπωση της Θεωρίας Συζευγμένων Αναπαραστάσεων

Έστω δύο συσχετισμένα σήματα: το σήμα-στόχος $y \in R^n$ που επιθυμείται να ανακατασκευαστεί και το σήμα καθοδήγησης $\omega \in R^d$ που διατίθεται ως πληροφορία επικουρίας. Υποθέτοντας ότι τα σήματα αυτά έχουν παρόμοιες αραιές αναπαραστάσεις $u \in R^m$ και $z \in R^m$ κάτω από τα αντίστοιχα λεξικά $D_y \in R^{n \times m}$ και $D_\omega \in R^{d \times m}$ με $n \leq m, d \leq m$, η αραιή αναπαράσταση u του σήματος-στόχου προκύπτει ως λύση του $l_1 - l_1$ προβλήματος βελτιστοποίησης:

$$\min_u \frac{1}{2} \|y - D_y u\|_2^2 + \lambda (\|u\|_1 + \|u - z\|_1) \quad (\text{εξ. 3.1})$$

Η **εξίσωση (3.1)** επεκτείνει το κλασικό πρόβλημα αραιής κωδικοποίησης της **εξίσωσης (2.7)** του **Κεφαλαίου 2**, εισάγοντας τον επιπλέον όρο $\|u - z\|_1$ που λειτουργεί ως όρος σύζευξης (coupling term) μεταξύ των αραιών αναπαραστάσεων των δύο τύπων της εικόνας.

Η θεωρητική βάση για την ενσωμάτωση βοηθητικής πληροφορίας στην αραιή κωδικοποίηση αναπτύχθηκε αρχικά από τους ερευνητές «E. Tsiligianni» και «N. Deligiannis» [TDL2019], οι οποίοι εισήγαγαν τη μαθηματική διατύπωση των συζευγμένων αραιών αναπαραστάσεων (coupled sparse representations).

Ερμηνεία του Όρου Σύζευξης

Ο όρος $\|u - z\|_1$ εκτελεί τρεις βασικές λειτουργίες:

Προώθηση Ομοιότητας: Ενθαρρύνει την αραιή αναπαράσταση u να είναι παρόμοια με την αναπαράσταση καθοδήγησης z , αξιοποιώντας την πληροφορία υψηλής ανάλυσης που διατίθεται από την εικόνα-σήμα καθοδήγησης (guidance modality).

Διατήρηση Αραιότητας: Η l_1 νόρμα κανονικοποίησης διατηρεί την αραιή δομή αμφοτέρων των αναπαραστάσεων, εξασφαλίζοντας ότι η ενσωμάτωση της βοηθητικής πληροφορίας δεν παραβιάζει τη θεμελιώδη υπόθεση της αραιότητας.

Επιτρέπει Ευελιξία: Δεν επιβάλλει άκαμπτη εξίσωση μεταξύ των αναπαραστάσεων αλλά παρέχει ομαλή καθοδήγηση, επιτρέποντας την προσαρμογή στα ιδιαίτερα χαρακτηριστικά κάθε τροπικότητας.

3.1.2 Θεωρία Του LeSITA Αλγορίθμου

Η πρακτική επίλυση του προβλήματος της *εξίσωσης (3.1)* απαιτεί την ανάπτυξη ειδικών αλγοριθμικών εργαλείων που μπορούν να αντιμετωπίζουν την πολυπλοκότητα της ενσωμάτωσης βοηθητικής πληροφορίας. Για τον σκοπό αυτό αναπτύχθηκε ο LeSITA (Learned Side Information Thresholding Algorithm), ένας καινοτόμος Αλγόριθμος που επεκτείνει τις αρχές του κλασικού ISTA Αλγορίθμου για να χειριστεί δεδομένα διαφορετικών τύπων εικόνων .

Ο Ρόλος του Προσεγγιστικού Τελεστή (Proximal Operator):

Το κλειδί για την κατανόηση του LeSITA βρίσκεται στον τρόπο που αντιμετωπίζει τον πολύπλοκο όρο κανονικοποίησης $|u|_1 + |u - z|_1$ της *εξίσωσης (3.1)*. Αντί για την εξαντλητική επίλυση του πλήρους προβλήματος σε κάθε επανάληψη, ο LeSITA υπολογίζει έναν ειδικό προσεγγιστικό τελεστή που επιλύει το υπό-πρόβλημα της *εξίσωσης (3.2)*:

$$u^t = \xi_\mu \left(\left(\mathbf{I} - \frac{1}{L} \mathbf{D}_y^T \mathbf{D}_y \right) u^{t-1} + \frac{1}{L} \mathbf{D}_y^T y; z \right), \quad u^0 = 0 \quad \text{εξ. (3.2)}$$

Η ιδιαιτερότητα αυτού του τελεστή έγκειται στο γεγονός ότι η λύση του προκύπτει αναλυτικά για κάθε στοιχείο ξεχωριστά, επιτρέποντας αποδοτικούς υπολογισμούς.

Ο LeSITA αλγόριθμος (Learned Side Information Thresholding Algorithm) αποτελεί καινοτόμα επέκταση του κλασικού LISTA [GLE2010] που αναπτύχθηκε ειδικά για την αντιμετώπιση τέτοιων προβλημάτων [TDL2019].

Προσαρμοστική Συμπεριφορά του LeSITA

Ο τελεστής LeSITA $\xi_\mu(v_i; z_i)$ εμφανίζει έξυπνη προσαρμοστική συμπεριφορά που εξαρτάται από τη σχέση μεταξύ της τρέχουσας τιμής v_i και της αντίστοιχης τιμής z_i της πληροφορίας επικουρίας. Η συμπεριφορά αυτή διαφοροποιείται ανάλογα με το πρόσημο της z_i :

Για $z_i \geq 0$:

$$\xi_{\mu}(u_i; z_i) = \begin{cases} u_i + 2\mu, & u_i < -2\mu \\ 0, & -2\mu \leq u_i \leq 0 \\ u_i, & 0 < u_i < z_i \\ z_i, & z_i \leq u_i \leq z_i + 2\mu \\ u_i - 2\mu, & u_i \geq z_i + 2\mu \end{cases} \quad \text{εξ. (3.3)}$$

Για $z_i < 0$:

$$\xi_{\mu}(u_i; z_i) = \begin{cases} u_i + 2\mu, & u_i < z_i - 2\mu \\ z_i, & z_i - 2\mu \leq u_i \leq z_i \\ u_i, & z_i < u_i < 0 \\ 0, & 0 \leq u_i \leq 2\mu \\ u_i - 2\mu, & u_i \geq 2\mu \end{cases} \quad \text{εξ. (3.4)}$$

όπου μ αποτελεί την παράμετρο σύζευξης που ελέγχει την ένταση της ομοιότητας των αραιών αναπαραστάσεων μεταξύ των διαφορετικών τύπων εικόνων.

Ο μαθηματικός τύπος του ειδικού τελεστή LeSITA παρέχει αναλυτική λύση για την ενσωμάτωση βοηθητικής πληροφορίας στη διαδικασία απαλού κατωφλίας, σύμφωνα με την εργασία [TDL2019] όπου και παρουσιάστηκε για πρώτη φορά.

Λειτουργικότητα και Φυσική Ερμηνεία

Ο LeSITA τελεστής δεν είναι απλώς ένας μαθηματικός τύπος, αλλά αντανακλά μια βαθύτερη κατανόηση του τρόπου που οι διαφορετικές τροπικότητες αλληλοεπιδρούν. Η λειτουργία του μπορεί να κατανοηθεί μέσω τριών βασικών μηχανισμών:

Μηχανισμός Έλξης: Όταν η τρέχουσα εκτίμηση v_i βρίσκεται κοντά στην τιμή της πληροφορίας επικουρίας z_i , ο τελεστής "έλκει" την u_i προς την z_i . Αυτό αντανακλά την εμπιστοσύνη στην καθοδήγηση που παρέχει η τροπικότητα καθοδήγησης.

Διατήρηση Ανεξαρτησίας: Όταν η απόσταση μεταξύ u_i και z_i είναι μεγάλη, ο τελεστής εφαρμόζει παραδοσιακό soft thresholding, επιτρέποντας στην τροπικότητα εισόδου να διατηρήσει τα δικά της χαρακτηριστικά.

Προσαρμοστική Ενίσχυση: Η παράμετρος μ ρυθμίζει την ένταση της αλληλεπίδρασης μεταξύ των εικόνων, παρέχοντας ευελιξία στην προσαρμογή σε διαφορετικούς τύπους δεδομένων και εφαρμογών.

Αυτή η φυσική ερμηνεία καθιστά τον LeSITA όχι μόνο μαθηματικά σωστό αλλά και διαισθητικά κατανοητό, επιτρέποντας την αποτελεσματική ρύθμιση και εφαρμογή του σε πραγματικά προβλήματα ιατρικής απεικόνισης.

3.1.3 Επεξεργασία Πολλαπλών Τύπων Εικόνων Στην Ιατρική Απεικόνιση

Η εφαρμογή των αρχών της αραιής κωδικοποίησης με πολλούς τύπους εικόνων στην ιατρική απεικόνιση παρουσιάζει μοναδικές προκλήσεις και ευκαιρίες που διαμορφώνουν τη σχεδίαση της προτεινόμενης λύσης.

Ιδιαιτερότητες των MRI Εξετάσεων

Μια σημαντική ιδιαιτερότητα της μαγνητικής τομογραφίας είναι η δυνατότητα απόκτησης πολλαπλών ακολουθιών εικόνων του ίδιου ανατομικού περιεχομένου κατά τη διάρκεια μίας εξέτασης. Οι διαφορετικές ακολουθίες MRI παρέχουν συμπληρωματική πληροφορία που μπορεί να αξιοποιηθεί αποδοτικά:

T1-weighted: Παρέχουν εξαιρετική ανατομική λεπτομέρεια και structural information, καθιστώντας τις ιδανικές για guidance modality.

T2-weighted: Εμφανίζουν βέλτιστη αντίθεση για την ανίχνευση παθολογίας και fluid visualization, αποτελώντας συχνά την target modality για υπερανάλυση.

FLAIR: Προσφέρουν υψηλή αντίθεση για βλάβες με καταστολή CSF signal, παρέχοντας πρόσθετη διαγνωστική πληροφορία.

Μεταφορά Πληροφορίας Μεταξύ Διαφορετικών Τύπων Εικόνων

Η προσέγγιση αξιοποιεί τη συσχέτιση μεταξύ διαφορετικών ακολουθιών MRI μέσω της χρήσης πληροφοριών από μια τροπικότητα ως βοηθητική πληροφορία από εικόνα υψηλής ανάλυσης, για τη βελτίωση της τροπικότητας της εικόνας εισόδου χαμηλής ανάλυσης. Αυτή η στρατηγική προσφέρει αρκετά πλεονεκτήματα:

Δομική Καθοδήγηση: Η διατήρηση ανατομικών ορίων και δομών που είναι σαφώς ορισμένα στην τροπικότητα καθοδήγησης αλλά λιγότερο εμφανή στην τροπικότητα εισόδου.

Συμπληρωματική Πληροφορία: Αντιστάθμιση της απώλειας πληροφορίας από τη διαδικασία υποδειγματοληψίας (downsampling) μέσω της εκμετάλλευσης πρόσθετων πληροφοριών από άλλη τροπικότητα.

Κανονικοποίηση Περιορισμών: Μείωση του χώρου λύσεων του αόριστου προβλήματος της υπερανάλυσης μέσω της εισαγωγής πρόσθετων περιορισμών από την βοηθητική πληροφορία.

Κλινική Αναγκαιότητα και Εφαρμοσιμότητα

Στο κλινικό περιβάλλον, αυτή η προσέγγιση απαντά σε πραγματικές ανάγκες:

Βελτιστοποίηση Χρόνου Εξέτασης: Επιτρέπει την απόκτηση μίας τροπικότητας σε υψηλή ανάλυση και άλλων σε χαμηλότερη, μειώνοντας τον συνολικό χρόνο εξέτασης.

Ενίσχυση Διαγνωστικής Ακρίβειας: Η συνδυασμένη αξιοποίηση πληροφοριών από πολλαπλές τροπικότητες βελτιώνει την ποιότητα των εικόνων για διαγνωστικούς σκοπούς.

Γενίκευση Ανακατασκευής: Η εξάρτηση από πολλαπλές πηγές πληροφορίας καθιστά την ανακατασκευή λιγότερο ευαίσθητη σε τεχνουργήματα/τεχνάσματα (artifacts) και θόρυβο που μπορεί να επηρεάσουν μία μεμονωμένη τροπικότητα.

Η θεωρητική βάση που παρουσιάστηκε σε αυτή την ενότητα παρέχει το απαραίτητο υπόβαθρο για την κατανόηση της αρχιτεκτονικής και των τεχνικών επιλογών που θα παρουσιαστούν στις επόμενες ενότητες. Η μετάβαση από τη θεωρία των συζευγμένων αραιών αναπαραστάσεων στην πρακτική υλοποίηση μέσω βαθιών νευρωνικών δικτύων αποτελεί το επόμενο βήμα της ανάλυσης.

3.2 Αρχιτεκτονική του Συστήματος

Η μετάβαση από τη θεωρητική διατύπωση του LeSITA αλγορίθμου στην πρακτική υλοποίηση απαιτεί τη σχεδίαση μιας κατάλληλης αρχιτεκτονικής που να αξιοποιεί τα πλεονεκτήματα των σύγχρονων τεχνικών βαθιάς μάθησης. Η προτεινόμενη λύση βασίζεται στην αρχή της βαθιάς αναδίπλωσης, η οποία επιτρέπει τη μετατροπή των επαναληπτικών αλγορίθμων βελτιστοποίησης σε αποδοτικά νευρωνικά δίκτυα διατηρώντας παράλληλα την ερμηνευσιμότητά τους.


3.2.1 Γενική Δομή και Σχεδιασμός

Το προτεινόμενο σύστημα βασίζεται στις αρχές της βαθιάς αναδίπλωσης που εφαρμόστηκαν για πρώτη φορά στην αραιή κωδικοποίηση από τους Gregor και LeCun [GLE2010], και επεκτάθηκαν με αξιοποίηση εικόνων διαφορετικού τύπου από την Tsliagianni [TDL2019], [MTC2019]. Το προτεινόμενο μοντέλο αποτελεί ένα ολοκληρωμένο παράδειγμα αρχιτεκτονική της προσέγγισης αυτής που συνδυάζει τις δυνατότητες της αραιής κωδικοποίησης με την υπολογιστική αποδοτικότητα των συνελκτικών νευρωνικών δικτύων. Η συνολική δομή οργανώνεται γύρω από τρία

βασικά δομοστοιχεία που λειτουργούν συνεργατικά για την επίτευξη του στόχου της υπερανάλυσης.

Στην **Εικόνα 3.1** παρουσιάζεται η γενική δομή της αρχιτεκτονικής του προτεινόμενου δικτύου. Το σύμβολο Y αποτελεί την εικόνα εισόδου χαμηλής ανάλυσης ενώ το Ω την εικόνα καθοδήγησης υψηλής ανάλυσης. Τα σύμβολα u , z αντιπροσωπεύουν τις αραιές αναπαραστάσεις των 2 εικόνων, οι οποίες προκύπτουν από την παράλληλη επεξεργασία των δομοστοιχείων LMCSC/ACSC αντίστοιχα [MTC2019].

Εικόνα 3.1: Γενική Αναπαράσταση του Δικτύου



Βασική Φιλοσοφία Σχεδιασμού

Η αρχιτεκτονική ακολουθεί την αρχή της σπονδυλωτής (modular) σχεδίασης, όπου κάθε δομοστοιχείο του συστήματος εκτελεί μια συγκεκριμένη και καλά ορισμένη λειτουργία. Αυτή η προσέγγιση παρέχει αρκετά πλεονεκτήματα: επιτρέπει την ανεξάρτητη βελτιστοποίηση κάθε δομοστοιχείου, διευκολύνει την εύρεση και διόρθωση προβλημάτων, και δημιουργεί δυνατότητες για μελλοντικές επεκτάσεις και τροποποιήσεις.

Η επιλογή της βαθιάς αναδίπλωσης ως βασική μεθοδολογία υλοποίησης δεν είναι τυχαία. Αντίθετα με τα παραδοσιακά «μυστηριώδη» ή «μαύρα κουτιά» (black-box) νευρωνικά δίκτυα, η βαθιά αναδίπλωση διατηρεί τόσο τη θεωρητική βάση του προβλήματος όσο και την ερμηνευσιμότητα των αποτελεσμάτων όπως παρουσιάζεται και στο **Κεφάλαιο 4**. Κάθε στρώμα του δικτύου αντιστοιχεί σε μια επανάληψη του θεωρητικού αλγορίθμου, καθιστώντας τη λειτουργία του συστήματος διαφανή και κατανοητή.

Τριμερής Δομή του Συστήματος

Το σύστημα οργανώνεται σε τρία διακριτά αλλά αλληλοεξαρτώμενα τμήματα:

Κλάδος Καθοδήγησης (Guidance Branch): Αναλαμβάνει την επεξεργασία της τροπικότητας καθοδήγησης για την εξαγωγή αραιών αναπαραστάσεων υψηλής ποιότητας. Η λειτουργία του βασίζεται στον ACSC (Approximate Convolutional Sparse

Coding) Αλγόριθμο, ο οποίος αποτελεί τη συνελικτική επέκταση του κλασικού LISTA Αλγορίθμου.

Κλάδος Στόχου (Target Branch): Επεξεργάζεται την τροπικότητα εισόδου αξιοποιώντας την πληροφορία επικουρίας από τον κλάδο καθοδήγησης. Η καρδιά αυτού του κλάδου είναι ο LMCSC (Learned Multimodal Convolutional Sparse Coding) αλγόριθμος, ο οποίος ενσωματώνει τη θεωρία του LeSITA που παρουσιάστηκε στην προηγούμενη ενότητα.

Κλάδος Ανακατασκευής (Reconstruction Module): Μετατρέπει τις αραιές αναπαραστάσεις που προκύπτουν από τον κλάδο στόχου σε τελικές εικόνες υψηλής ανάλυσης μέσω ενός μαθησιακού λεξικού.

3.2.2 Προσέγγιση Διπλού Κλάδου (Dual-Branch)

Η καρδιά της προτεινόμενης αρχιτεκτονικής αποτελεί η προσέγγιση διπλού κλάδου, η οποία επιτρέπει την παράλληλη και συντονισμένη επεξεργασία δύο διαφορετικών τύπων απεικόνισης. Αυτή η δομή αντανakλά τη φυσική διαθεσιμότητα πολλαπλών ακολουθιών MRI στην κλινική πρακτική και την επιστημονική παρατήρηση ότι αυτές περιέχουν συμπληρωματική πληροφορία.

Αρχές Λειτουργίας της Δομής Διπλού Κλάδου

Αυτή αρχιτεκτονική δεν αποτελεί απλώς έναν τεχνικό διαχωρισμό αλλά αντανakλά μια βαθύτερη κατανόηση του τρόπου που οι διαφορετικές τροπικότητες απεικόνισης αλληλεπιδρούν. Η τροπικότητα καθοδήγησης λειτουργεί ως πηγή δομικής πληροφορίας, παρέχοντας ανατομικά ορόσημα και χωρικές σχέσεις που μπορούν να καθοδηγήσουν την ανακατασκευή της τροπικότητας εισόδου.

Η αλληλεπίδραση μεταξύ των δύο κλάδων δεν είναι μονόδρομη. Παρόλο που κύρια ροή πληροφοριών κατευθύνεται από την εικόνα καθοδήγησης προς την εικόνα εισόδου, η αρχιτεκτονική επιτρέπει μελλοντικές επεκτάσεις που θα μπορούσαν να αξιοποιήσουν αμφίδρομη ροή πληροφοριών.

Συγχρονισμός και Ροή Πληροφοριών

Ένα κρίσιμο στοιχείο της προσέγγισης είναι ο συγχρονισμός μεταξύ των δύο κλάδων. Η αρχική σχεδίαση προβλέπει ακολουθιακή εκτέλεση, όπου ο κλάδος καθοδήγησης ολοκληρώνει πλήρως την επεξεργασία του πριν παρέχει τα αποτελέσματά του στον κλάδο εισόδου. Αυτή η προσέγγιση εξασφαλίζει σταθερότητα και προβλεψιμότητα στη λειτουργία του συστήματος.

Παράλληλα, η αρχιτεκτονική υποστηρίζει και μια εναλλακτική συν-εξελισσόμενη (co-evolving) προσέγγιση, όπου οι δύο κλάδοι εξελίσσονται παράλληλα, ανταλλάσσοντας πληροφορίες σε κάθε στάδιο της επεξεργασίας. Αυτή η προσέγγιση μπορεί να οδηγήσει απαιτεί πιο σύνθετη διαχείριση του συγχρονισμού αλλά μπορεί να αποδειχθεί κρίσιμη για τον σχεδιασμό πιο προηγμένων μοντέλων.

3.2.3 Υλοποίηση Βαθιάς Αναδίπλωσης

Η υλοποίηση της βαθιάς αναδίπλωσης αποτελεί τον συνδετικό κρίκο μεταξύ της θεωρητικής βάσης που παρουσιάστηκε στις προηγούμενες ενότητες και της πρακτικής αρχιτεκτονικής του συστήματος. Η βασική ιδέα συνίσταται στη μετατροπή των επαναληπτικών αλγορίθμων ACSC και LMCSC σε στρώματα νευρωνικού δικτύου.

Μετασχηματισμός Αλγορίθμων σε Δίκτυα

Κάθε επανάληψη του θεωρητικού αλγορίθμου μετατρέπεται σε ένα στρώμα του νευρωνικού δικτύου. Για τον **ACSC** Αλγόριθμο, κάθε στρώμα εκτελεί τον υπολογισμό που αντιστοιχεί στην επανάληψη όπως φαίνεται και στην **εξίσωση (3.5)**:

$$\mathbf{z}^{(t)} = \phi_{\gamma}(\mathbf{z}^{(t-1)} - \mathbf{T} * \mathbf{V} * \mathbf{z}^{(t-1)} + \mathbf{G} * \mathbf{\Omega}), \quad \mathbf{z}^{(0)} = \mathbf{0} \quad \text{εξ. (3.5)}$$

όπου \mathbf{T} , \mathbf{V} , και \mathbf{G} αποτελούν συνελκτικά φίλτρα που μαθεύονται από τα δεδομένα και αντιστοιχούν στους θεωρητικούς τελεστές του αλγορίθμου. Το ϕ_{γ} είναι ο τελεστής απαλού κατωφλίσιας με μαθησιακή παράμετρο γ .

Αντίστοιχα, για τον **LMCSC** Αλγόριθμο, κάθε στρώμα υλοποιεί:

$$\mathbf{u}^{(t)} = \xi_{\mu}(\mathbf{u}^{(t-1)} - \mathbf{Q} * \mathbf{R} * \mathbf{u}^{(t-1)} + \mathbf{P} * \mathbf{Y}; \mathbf{z}^{(t)}), \quad \mathbf{u}^{(0)} = \mathbf{0} \quad \text{εξ. (3.6)}$$

όπου \mathbf{Q} , \mathbf{R} , και \mathbf{P} είναι συνελκτικά φίλτρα που μαθεύονται από τα δεδομένα, και ξ_{μ} ο LeSITA operator που ενσωματώνει την βοηθητική πληροφορία $\mathbf{z}^{(t)}$ από τον κλάδο καθοδήγησης.

Μαθησιακές Παράμετροι και Προσαρμοστικότητα

Η καινοτομία της βαθιάς αναδίπλωσης έγκειται στο γεγονός ότι οι παράμετροι - που στους παραδοσιακούς αλγορίθμους είναι σταθερές και προκαθορισμένες - στο συγκεκριμένο δίκτυο γίνονται μαθησιακές. Αυτό επιτρέπει στο σύστημα να προσαρμόζει τη συμπεριφορά του στα συγκεκριμένα χαρακτηριστικά των δεδομένων εκπαίδευσης.

Για παράδειγμα, οι παράμετροι γ και μ που ελέγχουν την ένταση της κατωφλίσιας και της σύζευξης αντίστοιχα, μπορούν να προσαρμοστούν αυτόματα μέσω της διαδικασίας εκπαίδευσης. Αυτή η προσαρμοστικότητα οδηγεί σε σημαντική βελτίωση της απόδοσης

και του υπολογιστικού κόστους σε σχέση με τους παραδοσιακούς αλγορίθμους σταθερών παραμέτρων.

Σταθερός Αριθμός Στρωμάτων και Υπολογιστική Αποδοτικότητα

Ένα σημαντικό πλεονέκτημα της βαθιάς αναδίπλωσης είναι η αντικατάσταση του μεταβλητού αριθμού επαναλήψεων των παραδοσιακών αλγορίθμων με έναν σταθερό αριθμό στρωμάτων. Στην προτεινόμενη υλοποίηση, χρησιμοποιούνται τρία στρώματα για κάθε κλάδο, βασιζόμενα σε πειραματικές παρατηρήσεις που δείχνουν ότι αυτός ο αριθμός παρέχει βέλτιστη ισορροπία μεταξύ απόδοσης και υπολογιστικού κόστους.

Αυτή η σταθερότητα στον αριθμό των υπολογιστικών βημάτων καθιστά το σύστημα κατάλληλο για εφαρμογές πραγματικού χρόνου, όπου η εκτίμηση του χρόνου εκτέλεσης είναι κρίσιμη. Επιπλέον, η παράλληλη φύση των συνελικτικών πράξεων επιτρέπει την αποδοτική αξιοποίηση των σύγχρονων αρχιτεκτονικών με υποστήριξη κάρτας γραφικών.

Η αρχιτεκτονική που παρουσιάστηκε σε αυτή την ενότητα παρέχει το πλαίσιο για την κατανόηση των επιμέρους λειτουργιών που θα αναλυθούν λεπτομερώς στην επόμενη ενότητα. Η μετάβαση από τη γενική αρχιτεκτονική στις συγκεκριμένες υλοποιήσεις των ACSC, LMCSC, και Reconstruction δομοστοιχείων αποτελεί το επόμενο βήμα της ανάλυσης.

3.3 Υλοποίηση Των Κύριων Δομοστοιχείων

Η πρακτική υλοποίηση της προτεινόμενης αρχιτεκτονικής απαιτεί τη λεπτομερή σχεδίαση και ανάπτυξη των τριών βασικών δομοστοιχείων (modules) που συνθέτουν το σύστημα. Κάθε ένα εκτελεί μια συγκεκριμένη και καλά ορισμένη λειτουργία, αλλά η συνεργατική τους λειτουργία δημιουργεί ένα ολοκληρωμένο σύστημα υπερανάλυσης με επεξεργασία εικόνων διαφορετικού τύπου. Η παρούσα ενότητα εξετάζει τις τεχνικές λεπτομέρειες κάθε δομοστοιχείου, εστιάζοντας στις αρχιτεκτονικές επιλογές και στους μηχανισμούς που επιτρέπουν την αποδοτική ενσωμάτωση της θεωρίας στην πράξη.

3.3.1 ACSC Module (Approximate Convolutional Sparse Coding)

Το ACSC (Approximate Convolutional Sparse Coding) module βασίζεται στη συνελικτική επέκταση του LISTA που αναπτύχθηκε από τους Sreter και Giryes [SRG2018], αποτελώντας τη βάση για την επεξεργασία της guidance modality. Αποτελεί τον πυρήνα του guidance κλάδου και είναι υπεύθυνο για την εξαγωγή αραιών αναπαραστάσεων από την guidance modality. Η σχεδίαση του βασίζεται στην αρχή της συνελικτικής αραιής

κωδικοποίησης και υλοποιεί τη θεωρία του LISTA αλγορίθμου μέσω βαθιάς αναδίπλωσης.

Αρχιτεκτονική και Στοιχεία του Module

Το ACSC module οργανώνεται γύρω από τρία βασικά στοιχεία που αντιστοιχούν στις παραμέτρους της *εξίσωσης (3.5)*. Το στοιχείο G είναι υπεύθυνο για την αρχική επεξεργασία της εισόδου, μετατρέποντας την εικόνα καθοδήγησης Ω από μορφή ενός καναλιού, σε πολυδιάστατο χώρο χαρακτηριστικών. Αυτός ο μετασχηματισμός επιτρέπει την αποδοτική αναπαράσταση της πληροφορίας σε έναν χώρο όπου η αραιή δομή γίνεται πιο εμφανής.

Τα στοιχεία T και V αποτελούν τη καρδιά του επαναληπτικού μηχανισμού. Για κάθε στάδιο αναδίπλωσης, υπάρχει ένα αντίστοιχο ζεύγος $T \cdot V$ στρώσεις που εκτελούν τη διαδοχική συνελικτική επεξεργασία που αντιστοιχεί στον όρο $T * V * z^{(t-1)}$ της *εξίσωσης (3.5)*. Αυτή η διαδοχική εφαρμογή δύο συνελικτικών λεξικών επιτρέπει την εκμάθηση πολύπλοκων σχέσεων μεταξύ των χωρικών χαρακτηριστικών της εικόνας.

Μηχανισμός Soft Thresholding

Ένα κρίσιμο στοιχείο του ACSC module είναι η υλοποίηση του soft thresholding operator ϕ_γ , με γ να αποτελεί μαθησιακή παράμετρο, όπως ακριβώς αναφέρεται στην *εξίσωση (2.9)* στο **Κεφάλαιο 2**

Επαναληπτική Δομή και Σύγκλιση

Το ACSC εφαρμόζει την επαναληπτική διαδικασία για έναν προκαθορισμένο αριθμό σταδίων, συνήθως τρία, που αποτελεί ένα συμβιβασμό μεταξύ υπολογιστικής αποδοτικότητας και ποιότητας αποτελεσμάτων. Σε κάθε στάδιο, η αραιή αναπαράσταση $z^{(t)}$ βελτιώνεται σταδιακά, ενσωματώνοντας περισσότερη πληροφορία από την εικόνα εισόδου και συγκλίνοντας προς μια αραιή λύση που αντιπροσωπεύει αποδοτικά την εικόνα καθοδήγησης Ω .

3.3.2 LMCSC Module (Learned Multimodal Convolutional Sparse Coding)

Το LMCSC αποτελεί τον πυρήνα της καινοτομίας της προτεινόμενης προσέγγισης και ενσωματώνει τη θεωρία του LeSITA αλγορίθμου [TDL2019] στο συνελικτικό πεδίο, όπως παρουσιάστηκε αρχικά από τους Marivani et al. [MTC2019]. Είναι υπεύθυνο για την εξαγωγή αραιών αναπαραστάσεων από την τροπικότητα εισόδου με τη βοήθεια βοηθητικής πληροφορίας. Η σχεδίαση του ενσωματώνει τη θεωρία του LeSITA αλγορίθμου που παρουσιάστηκε στην **υπό-ενότητα 3.1.2**.

Αρχιτεκτονική και Διαφοροποίηση από το ACSC

Το LMCSC παρουσιάζει αρκετές ομοιότητες με το ACSC, αλλά διαφοροποιείται σε κρίσιμα σημεία που επιτρέπουν την ενσωμάτωση βοηθητικής πληροφορίας. Το στοιχείο P εκτελεί λειτουργία ανάλογη με το G του ACSC, μετατρέποντας την υποβαθμισμένη εικόνα εισόδου Y σε χώρο χαρακτηριστικών κατάλληλο για αραιή αναπαράσταση.

Τα στοιχεία Q και R αντιστοιχούν στα T και V του ACSC, αλλά με αντίστροφη σειρά εφαρμογής. Αυτή η διαφοροποίηση δεν είναι τυχαία αλλά αντανακλά τις διαφορετικές απαιτήσεις της τροπικότητας εισόδου σε σχέση με την τροπικότητα καθοδήγησης. Ο όρος $Q * R * u^{(t-1)}$ της **εξίσωσης (3.6)** υπολογίζει την κλίση (gradient) που απαιτείται για την ενημέρωση της αραιής αναπαράστασης.

Ενσωμάτωση του τελεστή LeSITA

Η καινοτομία του LMCSC module είναι η αντικατάσταση του παραδοσιακού soft thresholding operator με τον LeSITA operator ξ_μ [TDL2019], που ενσωματώνει την βοηθητική πληροφορία μέσω της μαθησιακής παραμέτρου μ . Αυτή η αντικατάσταση δεν είναι απλώς τεχνική αλλά αντιπροσωπεύει μια θεμελιώδη αλλαγή στον τρόπο που το σύστημα επεξεργάζεται την πληροφορία.

Ο LeSITA operator λαμβάνει ως εισόδους τόσο την τρέχουσα εκτίμηση $u^{(t-1)}$ όσο και την αντίστοιχη βοηθητική πληροφορία **του τελικού σταδίου** $z^{(t)}$ από το ACSC. Η αλληλεπίδραση αυτών των δύο ρευμάτων πληροφορίας ελέγχεται από τη μαθησιακή παράμετρο μ , η οποία καθορίζει την ένταση της σύζευξης (coupling term) μεταξύ των αραιών αναπαραστάσεων των δύο τύπων της εικόνας.

Προσαρμοστική Σύζευξη και Μάθηση

Η παράμετρος μ δεν είναι απλώς ένας αριθμητικός συντελεστής αλλά αντιπροσωπεύει τη μαθημένη εμπιστοσύνη του συστήματος στην βοηθητική πληροφορία. Μικρές τιμές του μ υποδηλώνουν ισχυρή σύζευξη και υψηλή εμπιστοσύνη στην τροπικότητα καθοδήγησης, ενώ μεγάλες τιμές επιτρέπουν μεγαλύτερη αυτονομία στον τύπο της εικόνας εισόδου.

Αυτή η προσαρμοστικότητα επιτρέπει στο σύστημα να μαθαίνει αυτόματα τον βέλτιστο βαθμό αλληλεπίδρασης μεταξύ των εικόνων, προσαρμοζόμενο στα ιδιαίτερα χαρακτηριστικά των δεδομένων εκπαίδευσης. Σε περιπτώσεις όπου η τροπικότητα της εικόνας καθοδήγησης παρέχει αξιόπιστη πληροφορία, το σύστημα μαθαίνει να την εκμεταλλεύεται πλήρως. Αντίθετα, όταν η πληροφορία καθοδήγησης είναι λιγότερο αξιόπιστη, το σύστημα προσαρμόζεται αυτόματα για να βασίζεται περισσότερο στα χαρακτηριστικά της εικόνας εισόδου.

3.3.3 Επανακατασκευή (Reconstruction)

Το δομοστοιχείο Επανακατασκευής αποτελεί το τελικό στάδιο της επεξεργασίας και είναι υπεύθυνο για τη μετατροπή των αραιών αναπαραστάσεων που προκύπτουν από το LMCSG σε τελικές εικόνες υψηλής ανάλυσης. Παρόλο που εμφανισιακά φαίνεται το απλούστερο από τα τρία βασικά στοιχεία, η σχεδίαση του είναι κρίσιμη για την ποιότητα των τελικών αποτελεσμάτων.

Αρχιτεκτονική του Μαθησιακού Λεξικού

Το στοιχείο Ανακατασκευής υλοποιεί την έννοια του μαθησιακού λεξικού $\mathbf{D} \in \mathbb{R}^{(1 \times 85 \times 7 \times 7)}$ μέσω ενός συνελκτικού στρώματος που εκτελεί τη μετατροπή από τον χώρο των αραιών αναπαραστάσεων με 85 αραιούς συντελεστές της αρχικής εικόνας χαμηλής ανάλυσης στον χώρο των εικόνων υψηλής ανάλυσης, δηλαδή στην τελική εικόνα-πρόβλεψη του μοντέλου. Αυτό το στρώμα μπορεί να θεωρηθεί ως η συνελκτική επέκταση του κλασικού λεξικού \mathbf{D} των παραδοσιακών μεθόδων αραιής κωδικοποίησης. Πιο συγκεκριμένα, το στοιχείο εκτελεί την πράξη:

$$\hat{\mathbf{Y}} = \mathbf{D}_y \mathbf{u}^{(t)} \quad \text{εξ. (3.8)}$$

όπου \mathbf{D}_y αποτελεί το μαθησιακό λεξικό ανακατασκευής, $\mathbf{u}^{(t)}$ τις αραιές αναπαραστάσεις του τελικού σταδίου από το LMCSG module, και $\hat{\mathbf{Y}}$ την τελική εικόνα υψηλής ανάλυσης. Η απλότητα αυτής της εξίσωσης ίσως είναι παραπλανητική - η ποιότητα της ανακατασκευής εξαρτάται άμεσα τόσο από την ποιότητα των αραιών αναπαραστάσεων $\mathbf{u}^{(t)}$ που παράγονται από τα προηγούμενα δομοστοιχεία, όσο και από την σωστή εκμάθηση των φίλτρων του λεξικού \mathbf{D}_y .

Περιορισμοί Κανονικοποίησης και Σταθερότητα

Ένα σημαντικό χαρακτηριστικό της λειτουργίας Ανακατασκευής είναι η εφαρμογή περιορισμών κανονικοποίησης στα βάρη του λεξικού. Συγκεκριμένα, εφαρμόζεται κανονικοποίηση μοναδιαίας νόρμας (unit norm constraint) που εξασφαλίζει ότι κάθε φίλτρο του λεξικού έχει Ευκλείδεια νόρμα ίση με τη μονάδα.

Αυτός ο περιορισμός εξυπηρετεί δύο σκοπούς: πρώτον, διατηρεί τη σταθερότητα των κλίσεων κατά την εκπαίδευση, αποτρέποντας το πρόβλημα εκτίναξης των κλίσεων των βαρών (exploding gradients) που θα μπορούσε να προκύψει από ανεξέλεγκτη αύξηση των βαρών. Δεύτερον, εξασφαλίζει ότι το μαθησιακό λεξικό παραμένει στην κατάλληλη κλίμακα, διατηρώντας τη φυσική ερμηνεία των αραιών συντελεστών.

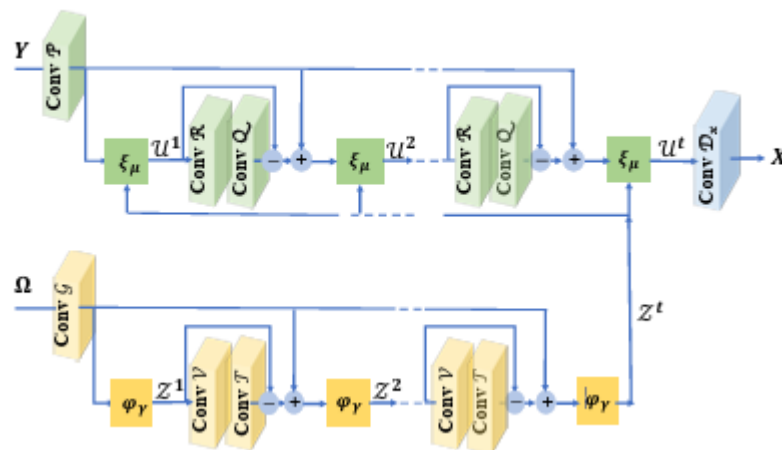
Διατήρηση Χωρικής Πληροφορίας

Η χρήση συνελκτικών πράξεων αντί για πλήρως συνδεδεμένα στρώματα δεν είναι τυχαία. Οι συνελκτικές πράξεις διατηρούν τη χωρική δομή της εικόνας και επιτρέπουν την αποδοτική διαχείριση εικόνων οποιουδήποτε μεγέθους χωρίς αλλαγές στην αρχιτεκτονική. Επιπλέον, η χρήση κατάλληλου γεμίσματος (padding) εξασφαλίζει ότι δεν υπάρχει απώλεια χωρικής πληροφορίας κατά τη διαδικασία ανακατασκευής.

Η συνεργατική λειτουργία των τριών δομοστοιχείων που παρουσιάστηκαν σε αυτή την ενότητα δημιουργεί ένα ολοκληρωμένο σύστημα που αξιοποιεί αποδοτικά τη θεωρητική βάση της αραϊκής κωδικοποίησης με βοηθητική πληροφορία. Η επόμενη ενότητα θα παρουσιάσει τόσο τα θεωρητικά όσο και οπτικά αποτελέσματα αυτής της τα αρχιτεκτονική και θα παρουσιάσει εναλλακτικές προσεγγίσεις για την οργάνωση της επεξεργασίας.

Στην **Εικόνα 3.2** παρουσιάζεται γίνεται σχηματική αναπαράσταση της αρχιτεκτονικής του Συνελκτικού Νευρωνικού Δικτύου LMCSC για όλα τα ενδιάμεσα στάδια μέχρι την τελική παραγωγή της εικόνας-στόχου, η οποία προτάθηκε για πρώτη φορά στο paper MICCAI [TZM2021].

Εικόνα 3.2 : Αρχιτεκτονική LMCSC



3.4 Θεωρητικές Εγγυήσεις & Επεκτάσεις

Η αποδοτική συνεργασία των επιμέρους δομοστοιχείων απαιτεί προσεκτικό σχεδιασμό της συνολικής αρχιτεκτονικής που να λαμβάνει υπόψη τόσο τις θεωρητικές απαιτήσεις των αλγορίθμων όσο και τις πρακτικές προκλήσεις της υλοποίησης. Η παρούσα ενότητα εξετάζει τις εναλλακτικές προσεγγίσεις για την οργάνωση της επεξεργασίας, τη

μετάβαση από τη γραμμική στη συνελκτική υλοποίηση, και τις θεωρητικές εγγυήσεις που διατηρούνται κατά τη διαδικασία.

3.4.1 Θεωρητικές Εγγυήσεις & Στρατηγικές εκπαίδευσης

Οι θεωρητικές εγγυήσεις σύγκλισης διατηρούνται κατά τη μετάβαση από τους παραδοσιακούς επαναληπτικούς αλγορίθμους στις deep unfolding αρχιτεκτονικές, όπως αποδείχθηκε σε εργασίες για AMP-inspired networks [BSR2017] και εφαρμόστηκε στο προαναφερθέν πλαίσιο [MTCD2020].

Από την άλλη μεριά, η μετάβαση από τους θεωρητικούς αλγόριθμους στην πρακτική υλοποίηση μέσω βαθιάς αναδίπλωσης δεν παύει να θέτει σημαντικά ερωτήματα σχετικά με τη διατήρηση των θεωρητικών ιδιοτήτων και εγγυήσεων. Η κατανόηση τους φαίνεται να είναι κρίσιμο σημείο για τη σχεδίαση αποδοτικών στρατηγικών εκπαίδευσης και τη διασφάλιση της αξιοπιστίας του συστήματος.

Διατήρηση Ιδιοτήτων Σύγκλισης

Ο LeSITA αλγόριθμος διατηρεί τις θεμελιώδεις ιδιότητες σύγκλισης των κλασικών proximal algorithms. Συγκεκριμένα, η objective function μειώνεται μονότονα σε κάθε επανάληψη, και για κυρτά προβλήματα εγγυάται σύγκλιση στο global minimum. Αυτές οι ιδιότητες διατηρούνται και στη βαθιά αναδίπλωση, αλλά με την προϋπόθεση ότι οι μαθησιακές παράμετροι δεν απομακρυνθούν υπερβολικά από τις θεωρητικές τους τιμές. Η εισαγωγή μαθησιακών παραμέτρων δημιουργεί έναν trade-off μεταξύ θεωρητικών εγγυήσεων και πρακτικής απόδοσης. Ενώ η βελτιστοποίηση των παραμέτρων μπορεί να οδηγήσει σε σημαντικές βελτιώσεις στην απόδοση, υπάρχει κίνδυνος να παραβιαστούν οι συνθήκες που εγγυώνται τη σύγκλιση. Για την αντιμετώπιση αυτής της πρόκλησης, η εκπαίδευση του συστήματος περιλαμβάνει προσεκτική παρακολούθηση των παραμέτρων και εφαρμογή περιορισμών που εξασφαλίζουν τη διατήρηση των βασικών ιδιοτήτων.

Robust Integration του Side Information

Η θεωρητική ανάλυση του LeSITA δείχνει ότι η ενσωμάτωση side information παρέχει αξιοσημείωτη ανθεκτικότητα (robustness) στο σύστημα. Ακόμη και όταν η side information περιέχει θόρυβο ή ανακρίβειες, ο αλγόριθμος δεν αποσταθεροποιείται αλλά προσαρμόζει αυτόματα τη συμπεριφορά του.

Αυτή η ιδιότητα είναι ιδιαίτερα σημαντική στην ιατρική απεικόνιση, όπου η ποιότητα των εικόνων μπορεί να επηρεάζεται από διάφορους παράγοντες όπως η κίνηση του ασθενούς, τα artifacts του scanner, ή τις παραλλαγές στα πρωτόκολλα απόκτησης. Η

παράμετρος μ του LeSITA operator λειτουργεί ως αυτόματος μηχανισμός ρύθμισης που ελέγχει την ένταση της σύζευξης βάσει της ποιότητας της side information.

Στρατηγικές Εκπαίδευσης και Βελτιστοποίησης

Η επιτυχής εκπαίδευση του συστήματος απαιτεί προσεκτικό σχεδιασμό της στρατηγικής βελτιστοποίησης που να λαμβάνει υπόψη τις ιδιαιτερότητες της αρχιτεκτονικής. Η αρχικοποίηση των παραμέτρων αποτελεί κρίσιμο παράγοντα, καθώς κακή αρχικοποίηση μπορεί να οδηγήσει σε αργή σύγκλιση ή ακόμη και σε αποτυχία της εκπαίδευσης.

Η προτεινόμενη στρατηγική βασίζεται στη θεωρητική αρχικοποίηση, όπου οι παράμετροι S , W , και γ αρχικοποιούνται με τις θεωρητικές τιμές που προκύπτουν από τον αντίστοιχο επαναληπτικό αλγόριθμο. Αυτή η προσέγγιση εξασφαλίζει ότι το δίκτυο ξεκινά από ένα σημείο που είναι εγγυημένα stable και στη συνέχεια προσαρμόζεται στα συγκεκριμένα χαρακτηριστικά των δεδομένων εκπαίδευσης.

Η επιλογή του learning rate και του optimizer επηρεάζει σημαντικά την ποιότητα των αποτελεσμάτων. Τα πειράματα δείχνουν ότι ο Adam optimizer με learning rate $1e-4$ παρέχει καλή ισορροπία μεταξύ ταχύτητας σύγκλισης και σταθερότητας. Επιπλέον, η χρήση adaptive learning rate strategies που μειώνουν το learning rate όταν η βελτίωση των αποτελεσμάτων επιβραδύνεται βοηθά στην αποφυγή του overfitting και στην επίτευξη καλύτερης generalization.

Η ολοκληρωμένη αρχιτεκτονική που παρουσιάστηκε σε αυτή την ενότητα αποτελεί τη σύνθεση όλων των θεωρητικών και τεχνικών στοιχείων που εξετάστηκαν στις προηγούμενες ενότητες. Η επόμενη ενότητα θα εστιάσει στις πρακτικές πτυχές της υλοποίησης, εξετάζοντας τα frameworks και εργαλεία που χρησιμοποιήθηκαν για τη δημιουργία του συστήματος.

3.4.2 LMCSC vs Co-evolving LMCSC

Η προσέγγιση με δύο κλάδους αποτελεί σημαντική αρχιτεκτονική καινοτομία που επιτρέπει την παράλληλη επεξεργασία πολλαπλών τύπων εικόνας, όπως παρουσιάστηκε πλήρως στις εργασίες [MTC2019] και [MTCD2020] για υπερανάλυση εικόνων με βοηθητική πληροφορία και μπορεί να ακολουθήσει δύο διαφορετικές φιλοσοφίες. Καθεμία εκ των οποίων αντανακλούν σε διαφορετικές ερμηνείες του τρόπου αλληλεπίδρασης μεταξύ των διαφορετικών τύπων της εικόνας. Η επιλογή μεταξύ ακολουθιακής και συν-εξελισσόμενης (co-evolving) προσέγγισης επηρεάζει όχι μόνο την

υπολογιστική απόδοση αλλά και την ποιότητα των αποτελεσμάτων, όπως θα δούμε και στο **Κεφάλαιο 4**.

Ακολουθιακή Υλοποίηση: Η Κλασική Προσέγγιση

Η ακολουθιακή προσέγγιση ακολουθεί την παραδοσιακή φιλοσοφία των αλγορίθμων βελτιστοποίησης, όπου κάθε υπό-πρόβλημα επιλύεται πλήρως πριν από την μετάβαση στο επόμενο. Στο πλαίσιο της προτεινόμενης αρχιτεκτονικής, αυτό σημαίνει ότι το ACSC ολοκληρώνει πλήρως την επεξεργασία της τροπικότητας καθοδήγησης, παράγοντας τις τελικές αραιές αναπαραστάσεις z , πριν αυτές χρησιμοποιηθούν ως βοηθητική πληροφορία στο LMCSC.

Αυτή η προσέγγιση παρουσιάζει αρκετά πλεονεκτήματα σε επίπεδο υλοποίησης και κατανόησης. Η ροή των δεδομένων είναι σαφής και προβλέψιμη, καθιστώντας εύκολη την αποσφαλμάτωση (debugging) και την ανάλυση των ενδιάμεσων αποτελεσμάτων. Επιπλέον, η ανεξάρτητη επεξεργασία κάθε κλάδου επιτρέπει την παραλληλία σε επίπεδο παρτίδας (batch), όπου η ταυτόχρονη επεξεργασία διαφορετικών δειγμάτων είναι εφικτή.

Συν-Εξελισσόμενη Υλοποίηση: Η Καινοτόμος Επέκταση

Αυτή η προσέγγιση αποτελεί μια καινοτόμο επέκταση που επιτρέπει την παράλληλη εξέλιξη των αραιών αναπαραστάσεων και των δύο τύπων της εικόνας. Αντί της πλήρους ολοκλήρωσης του ACSC, η διαδικασία εκτελείται στάδιο-στάδιο (stage-by-stage), όπου κάθε στάδιο του ACSC ακολουθείται άμεσα από το αντίστοιχο στάδιο του LMCSC.

Αυτή η προσέγγιση βασίζεται στην παρατήρηση ότι οι αραιές αναπαραστάσεις εξελίσσονται σταδιακά κατά τη διάρκεια της επαναληπτικής διαδικασίας, επιτρέποντας στο LMCSC να αξιοποιήσει τις ενδιάμεσες αραιές αναπαραστάσεις από το ACSC, κι έτσι δημιουργείται ένας πιο δυναμικός μηχανισμός ανταλλαγής πληροφοριών που μπορεί να οδηγήσει σε βελτιωμένη σύγκλιση.

Σύγκριση και Υπολογιστικές Συνέπειες

Η σύγκριση μεταξύ των δύο προσεγγίσεων αποκαλύπτει ενδιαφέρουσες ανακαλύψεις. Η κλασική προσέγγιση εξασφαλίζει σταθερότητα και προβλεψιμότητα, αλλά μπορεί να περιορίζει την αποδοτικότητα της αλληλεπίδρασης μεταξύ των εικόνων. Η συν-εξελισσόμενη προσέγγιση προσφέρει μεγαλύτερη ευελιξία και δυναμικότητα, αλλά απαιτεί πιο προσεκτική διαχείριση του συγχρονισμού και των εξαρτήσεων μεταξύ των δομοστοιχείων.

Από υπολογιστική άποψη, και οι δύο προσεγγίσεις έχουν παρόμοια απόδοση και συνολικό κόστος, αλλά διαφέρουν στην κατανομή του. Η ακολουθιακή προσέγγιση

επιτρέπει καλύτερη αξιοποίηση της μνήμης καθώς οι ενδιάμεσες αναπαραστάσεις του ACSC μπορούν να απελευθερωθούν μετά την ολοκλήρωση της επεξεργασίας τους. Η συνεξελισσόμενη προσέγγιση απαιτεί διατήρηση περισσότερων ενδιάμεσων αποτελεσμάτων αλλά μπορεί να οδηγήσει σε ταχύτερη σύγκλιση.

Κεφάλαιο 4: Πειράματα

Η αξιολόγηση του προτεινόμενου μοντέλου LMCSC αποτελεί κρίσιμο στάδιο για την επιβεβαίωση της αποδοτικότητας και την επικύρωση των θεωρητικών υποθέσεων που διατυπώθηκαν στα προηγούμενα κεφάλαια. Το παρόν κεφάλαιο παρουσιάζει μια εκτεταμένη πειραματική μελέτη που καλύπτει τόσο ποσοτικές όσο και ποιοτικές πτυχές της απόδοσης, με ιδιαίτερη έμφαση στην κλινική σημασία των αποτελεσμάτων.

Η πειραματική αξιολόγηση σχεδιάστηκε για να απαντήσει σε τρία θεμελιώδη ερωτήματα: α) Πετυχαίνει το προτεινόμενο σύστημα να υπερβεί την τρέχουσα κατάσταση τέχνης σε ποσοτικούς δείκτες απόδοσης; β) Διατηρεί η ανακατασκευασμένη εικόνα τη διαγνωστική της αξία για κλινικές εφαρμογές; και γ) Ποια είναι η συνεισφορά των επιμέρους καινοτομιών [Επαύξηση δεδομένων (data augmentation), κανονικοποίηση βαρών (weight normalization), συν-εξελισσόμενη αρχιτεκτονική (co-evolving architecture)] στη συνολική απόδοση;

Για την απάντηση αυτών των ερωτημάτων, χρησιμοποιήθηκε το ίδιο σύνολο δεδομένων MS-MRI που εμφανίζεται στη διεθνή βιβλιογραφία, εξασφαλίζοντας την άμεση σύγκριση των αποτελεσμάτων. Η ανάλυση περιλαμβάνει εκτεταμένη μελέτη απαλοιφής (ablation study), συγκριτική αξιολόγηση με ανταγωνιστικές μεθόδους, και λεπτομερή οπτική εξέταση των αποτελεσμάτων που αποκαλύπτει τους μηχανισμούς λειτουργίας του συστήματος.

4.1 Πειραματική Διάταξη

Η παρούσα ενότητα περιγράφει το πειραματικό περιβάλλον που αναπτύχθηκε για την αξιολόγηση του προτεινόμενου συστήματος LMCSC. Παρουσιάζονται οι τεχνικές προδιαγραφές του υπολογιστικού εξοπλισμού, οι αρχιτεκτονικές παράμετροι, καθώς και οι παράμετροι εκπαίδευσης που χρησιμοποιήθηκαν για την υλοποίηση του δικτύου.

4.1.1 Υπολογιστικό Περιβάλλον

Για την υλοποίηση και αξιολόγηση της προτεινόμενης αρχιτεκτονικής χρησιμοποιήθηκε εξειδικευμένο υπολογιστικό περιβάλλον που εξασφαλίζει την αποδοτική εκπαίδευση βαθιών νευρωνικών δικτύων για ιατρικές εφαρμογές. Η επιλογή του υλικού και

λογισμικού βασίστηκε στις απαιτήσεις υψηλής υπολογιστικής επίδοσης και αξιοπιστίας που χαρακτηρίζουν τις εφαρμογές υπερανάλυσης εικόνων.

Υλικό (Hardware):

- Κάρτα Γραφικών (GPU): NVIDIA GeForce RTX 2060 με 6.4GB μνήμη εικονικής πραγματικότητας (VRAM)
- Επεξεργαστής (CPU): Intel Core i7-9700K - Πολυπύρηνος επεξεργαστής για αποδοτική φόρτωση δεδομένων
- Μνήμη Συστήματος (RAM): Τουλάχιστον 16GB για επεξεργασία μεγάλων παρτίδων (batches)

Λογισμικό (Software):

- Πλαίσιο Ανάπτυξης (Framework): PyTorch με υποστήριξη CUDA για επιτάχυνση από Κάρτα Γραφικών (GPU acceleration)
- Γλώσσα Προγραμματισμού: Python 3.10+
- Υλοποίηση: Προσαρμοσμένη υλοποίηση βασισμένη στα LeSITA papers

Το συγκεκριμένο υπολογιστικό περιβάλλον επιλέχθηκε για να εξασφαλίσει τη βέλτιστη ισορροπία μεταξύ υπολογιστικής ισχύος και προσβασιμότητας, καθιστώντας τα αποτελέσματα αναπαράξιμα σε τυπικά ερευνητικά περιβάλλοντα.

4.1.2 Αρχιτεκτονικές Παράμετροι

Ο **Πίνακας 4.1** παρουσιάζει τις βασικές αρχιτεκτονικές παραμέτρους για κάθε στοιχείο του δικτύου. Το στοιχείο ACSC (Approximate Convolutional Sparse Coding) επεξεργάζεται τον τύπο της εικόνας καθοδήγησης (guidance modality) χρησιμοποιώντας τρία στάδια αναδίπλωσης (unfolding stages) με 85 φίλτρα σε κάθε στρώμα (layer). Το στοιχείο LMCSC (Learned Multimodal Convolutional Sparse Coding) εφαρμόζει παρόμοια αρχιτεκτονική για την επεξεργασία της τροπικότητας εισόδου (target modality), ενσωματώνοντας την βοηθητική πληροφορία (side information) μέσω του παραμέτρου σύζευξης μ . Οι παράμετροι ενεργοποίησης γ και μ είναι μαθησιακές (learnable), επιτρέποντας την προσαρμογή του επιπέδου αραιότητας (sparsity) και της έντασης της σύζευξης των δύο εικόνων αντίστοιχα (sparse multimodal coupling).

Δομοστοιχείο	Στάδια	Φίλτρα	Μέγεθος Συνελικτικού Πυρήνα	Παράμετρος Ενεργοποίησης	Διαστάσεις Χάρτες Χαρακτηριστικών
Εξήγηση	Επαναλήψεις Αναδίπλωσης	Συνελικτικά φίλτρα ανά στρώμα	Μέγεθος συνελικτικού πυρήνα	Κανονικοποίηση Σύζευξης & Αραιότητας	Αραιές Αναπαραστάσεις
ACSC (Καθοδήγηση)	3	85	7×7	$\gamma = 0.1$ (ShLU) ¹	$Z \in \mathbb{R}^{(44 \times 44 \times 85)}$
LMCSC (Είσοδος)	3	85	7×7	$\mu = 0.1$ (LeSITA) ²	$U \in \mathbb{R}^{(44 \times 44 \times 85)}$
Reconstruction	1	85→1	7×7	-	$\tilde{Y} \in \mathbb{R}^{(44 \times 44 \times 1)}$

Πίνακας 4.1: Αρχιτεκτονικές Παράμετροι LMCSC

***Σημειώσεις¹:**

(1) γ : Soft thresholding parameter - ελέγχει το επίπεδο αραιότητας (sparsity level).

(2) μ : Coupling parameter - ρυθμίζει την ένταση της cross-modal πληροφορίας.

Και οι δύο παράμετροι αρχικοποιούνται στο 0.1 αλλά το δίκτυο τις μαθαίνει αργότερα από τα δεδομένα (*learnable parameters*).

Ο **Πίνακας 4.2** συνοψίζει τις συνολικές προδιαγραφές του συστήματος, παρουσιάζοντας τις διαστάσεις εισόδου και εξόδου καθώς και τη συνολική πολυπλοκότητα του μοντέλου. Το σύστημα δέχεται ως είσοδο εικόνες χαμηλής ανάλυσης (**LR**) διαστάσεων που καθορίζονται από το σύνολο δεδομένων (dataset) και παράγει εικόνες υψηλής ανάλυσης (**HR**) με συντελεστή υπερανάλυσης **×4**. Οι συνολικές παράμετροι του μοντέλου ανέρχονται σε **4,261,988** και είναι όλες μαθεύονται από τα δεδομένα (*learnable*), με συνολικό μέγεθος μοντέλου **17.0MB**, καθιστώντας το σύστημα αποδοτικό σε όρους μνήμης και κατάλληλο για πρακτικές εφαρμογές.

Πίνακας 4.2: Συνολικές Προδιαγραφές Συστήματος

Μοντέλο	Είσοδος - Εικόνα Χαμηλής Ανάλυσης ⁽¹⁾	Εικόνα Καθοδήγησης Υψηλής Ανάλυσης ⁽²⁾	Έξοδος - Εικόνα Υψηλής Ανάλυσης ⁽³⁾	Συνολικές Παράμετροι	Μέγεθος Μοντέλου (MB)
LISTA	$Y \in \mathbb{R}^{(512 \times 512 \times 1)}$	-	$\hat{Y} \in \mathbb{R}^{(512 \times 512 \times 1)}$	2,950,502 - 2.95 M	11.8 MB
LMCSC_v2 - CoLMCSC	$Y \in \mathbb{R}^{(512 \times 512 \times 1)}$	$Z \in \mathbb{R}^{(512 \times 512 \times 1)}$	$\hat{Y} \in \mathbb{R}^{(512 \times 512 \times 1)}$	4,261,988 - 4.26 M	17.0 MB

***Σημειώσεις²:**

(1) Y : (T2W) Είσοδος: Θολωμένη εικόνα χαμηλής ανάλυσης.

(2) Z : (T1W) Βοηθητική Πληροφορία: βοηθητική εικόνα υψηλής ανάλυσης για βελτίωση προβλέψεων του μοντέλου.

(3) \hat{Y} : (T2W) Έξοδος: Ανακατασκευασμένη καθαρή εικόνα-πρόβλεψη μοντέλου υψηλής ανάλυσης.

4.1.3 Παράμετροι Εκπαίδευσης

Η εκπαίδευση του προτεινόμενου συστήματος απαιτεί προσεκτικό καθορισμό των υπερπαραμέτρων που ελέγχουν τη διαδικασία βελτιστοποίησης και την επεξεργασία των δεδομένων. Οι συγκεκριμένες τιμές επιλέχθηκαν βάσει εμπειρικής αξιολόγησης και βέλτιστων πρακτικών για εφαρμογές ιατρικής απεικόνισης.

Ο **Πίνακας 4.3** παρουσιάζει τη συνολική διαμόρφωση εκπαίδευσης του προτεινόμενου συστήματος LMCSC, καλύπτοντας όλες τις κρίσιμες παραμέτρους που διέπουν τη διαδικασία βελτιστοποίησης. Ο αλγόριθμος Adam με σταθερό ρυθμό μάθησης 1×10^{-4} επιλέχθηκε για τη σταθερή σύγκλιση του δικτύου, ενώ η συνάρτηση απώλειας MSE εξασφαλίζει την ακριβή ανακατασκευή των εικονοστοιχείων. Οι παράμετροι διαχείρισης δεδομένων προσαρμόστηκαν για βέλτιστη αξιοποίηση των υπολογιστικών πόρων, με μεγέθη παρτίδων 32 και 8 για εκπαίδευση και αξιολόγηση αντίστοιχα. Η προ-επεξεργασία περιλαμβάνει κανονικοποίηση στο εύρος [0,1] και συγχρονισμένη επαύξηση

δεδομένων (data augmentation) που αυξάνει την ποικιλομορφία του συνόλου εκπαίδευσης. Ιδιαίτερη έμφαση δίνεται στη σταθεροποίηση της εκπαίδευσης μέσω κανονικοποίησης βαρών με περιορισμό μοναδιαίας νόρμας και επιλογή προσαρμοστικού ρυθμού μάθησης, τεχνικές που αποτρέπουν την ανεξέλεγκτη αύξηση κλίσεων και εξασφαλίζουν την αριθμητική σταθερότητα του συστήματος. Η αρχικοποίηση των παραμέτρων ακολουθεί τις οδηγίες των θεωρητικών εργασιών, με Gaussian κατανομή για τα βάρη συνέλιξης και αρχικοποίηση με συγκεκριμένες τιμές για τις μαθησιακές παραμέτρους ενεργοποίησης γ και μ .

Πίνακας 4.3: Διαμόρφωση Εκπαίδευσης (Training Configuration)

Κατηγορία	Παράμετρος	Τιμή	Σημειώσεις
Βελτιστοποίηση (Optimization)	Αλγόριθμος	Adam	$\beta_1=0.9, \beta_2=0.999$
	Ρυθμός Μάθησης (Learning Rate)	1×10^{-4}	Σταθερός όλα τα epochs / Μαθησιακός Ρυθμός μάθησης
	Συνάρτηση Απώλειας (Loss Function)	MSE	Μέσο τετραγωνικό σφάλμα
	Κανονικοποίηση Βαρών (Weight Decay)	Ενεργός	Αναλυτικά Παρακάτω
Σταθεροποίηση Εκπαίδευσης	Gradient Clipping	Άμεση	Μέσω κανονικοποίησης βαρών
	Περιορισμός Μοναδιαίας Νόρμας	Ενεργός	Dictionary weights normalization
	Αριθμητική Σταθερότητα	$1e-8$	Ελάχιστο όριο νόρμας

Κατηγορία	Παράμετρος	Τιμή	Σημειώσεις
	Κανονικοποίηση Βαρών	L1 έμμεση	Από Περιορισμό Μοναδιαίας Νόρμας
	Προσαρμοστικός Ρυθμός Μάθησης	Απενεργοποιημένος	Εκμάθηση του ρυθμού μάθησης
Διαχείριση Δεδομένων (Data Management)	Μέγεθος Παρτίδας Εκπαίδευσης	32	Βελτιστοποιημένο για GPU
	Μέγεθος Παρτίδας Αξιολόγησης	8	Evaluation batch
	Εποχές Εκπαίδευσης (Epochs)	40-100	Ανάλογα με πείραμα
	Έλεγχος Σύγκλισης	- Early stopping - Best Model Selection	Παρακολούθηση Απώλειας Επικύρωσης
Προεπεξεργασία (Preprocessing)	Κανονικοποίηση	[0,1]	Διαίρεση με 255
	Βελτίωση Δεδομένων (Data Enhancement)	90°, 180°, 270°	Flips + Rotations
	Συγχρονισμός Εικόνων	Enabled	Ενσωμάτωση βοηθητικής πληροφορίας
Αρχικοποίηση (Initialization)	Βάρη Συνέλιξης	Normal (0, 0.01)	Gaussian κατανομή

Κατηγορία	Παράμετρος	Τιμή	Σημειώσεις
	Bias Terms	0	Μηδενική αρχικοποίηση
	Threshold γ (ShLU)	0.1	Παράμετρος που μαθαίνεται από τα δεδομένα
	Coupling μ (LeSITA)	0.1	Παράμετρος που μαθαίνεται από τα δεδομένα

Η ενότητα αυτή καθορίζει το τεχνικό πλαίσιο και τις συνθήκες υπό τις οποίες διεξήχθησαν τα πειράματα, εξασφαλίζοντας την αναπαραγωγή των αποτελεσμάτων και τη δυνατότητα σύγκρισης με άλλες προσεγγίσεις στη βιβλιογραφία.

4.2 Dataset & Προεπεξεργασία

Για την αξιολόγηση του προτεινόμενου συστήματος χρησιμοποιήθηκε το ίδιο σύνολο δεδομένων MS-MRI (Multiple Sclerosis MRI) που χρησιμοποιήθηκε στο αντίστοιχο MICCAI paper [TMZ2021], εξασφαλίζοντας την άμεση σύγκριση των αποτελεσμάτων. Το συγκεκριμένο σύνολο δεδομένων επιλέχθηκε λόγω της κλινικής σημασίας του για τη διάγνωση και παρακολούθηση της σκλήρυνσης κατά πλάκας, καθώς και της ποιότητας και πληρότητας των δεδομένων που περιέχει.

4.2.1 Σύνολο Δεδομένων MS-MRI

Ο Πίνακας 4.4 παρουσιάζει τις βασικές προδιαγραφές του συνόλου δεδομένων που χρησιμοποιήθηκε στα πειράματα. Το σύνολο εκπαίδευσης περιλαμβάνει **21,920 δείγματα** προεπεξεργασμένα σε patches διαστάσεων **44×44 pixels** για υπολογιστική αποδοτικότητα, που αντιπροσωπεύουν μέρη της εικόνας χαμηλής ανάλυσης (512×512) θολωμένη με παράγοντα **×4**. Ο τελεστής θολώματος εξαρτάται από τον παράγοντα υποβάθμισης (degradation factor) της υψηλής εικόνας. Το σύνολο αξιολόγησης αποτελείται από **230 δείγματα πλήρους ανάλυσης 512×512 pixels** για ρεαλιστική αξιολόγηση.

Κάθε δείγμα περιέχει τρεις τροπικότητες:

- **T1W Target:** Εικόνες υψηλής ανάλυσης που χρησιμοποιούνται ως πληροφορία καθοδήγησης (side information)
- **T2W LR Input:** Εικόνες χαμηλής ανάλυσης ($\times 4$ downsampled) που αποτελούν την είσοδο του συστήματος
- **T2W Target:** Εικόνες υψηλής ανάλυσης και αποτελούν τις πραγματικές εικόνες (Ground Truth) για την αξιολόγηση

Η αναλογία μεταξύ εκπαίδευσης και αξιολόγησης ($\sim 95:5$) εξασφαλίζει επαρκή δεδομένα για την εκπαίδευση ενώ διατηρεί αντιπροσωπευτικό σύνολο για την αξιολόγηση.

Πίνακας 4.4: Προδιαγραφές Συνόλου Δεδομένων (Dataset Specifications)

Διαχωρισμός	Δείγματα	Μέγεθος (MB)	Παρτίδες	Διαστάσεις	Τύποι Εικόνων
Εκπαίδευση	21,920	2,037	685	128×128×1 → 512×512×1	T1W, T2W-LR, T2W-HR
Αξιολόγηση	230	2,894	29	512×512×1	T1W, T2W-LR, T2W-HR
Σύνολο	22,150	4,931	714	MS-MRI Dataset	3 Τύποι Εικόνων (2 Εκπαίδευσης – 1 Επαλήθευσης)

Κλειδιά Χαρακτηριστικά:

- **Κλινική Σημασία:** Πραγματικά δεδομένα από ασθενείς με Σκλήρυνση κατά Πλάκας
- **Σημασία T2W HR:** Κρίσιμες εικόνες για ανίχνευση απομυελινωτικών βλαβών (demyelinating lesions)
- **Ρεαλιστικές Συνθήκες:** Αξιολόγηση πλήρους κλίμακας για κλινική σχετικότητα
- **Διάταξη με εικόνες διαφορετικού τύπου (Multimodal Setup):** Δομική καθοδήγηση T1W για υπερανάλυση T2W LR

4.2.2 Διαδικασία Υποδειγματοληψίας (Downsampling Process)

Μεθοδολογία Υπερανάλυσης

Η διαδικασία υπερανάλυσης (super-resolution) εφαρμόζεται με τη χρήση συγκεκριμένων παραγόντων υποδειγματοληψίας (downsampling factors) σε εικόνες υψηλής ανάλυσης για τη δημιουργία των εισόδων χαμηλής ανάλυσης:

Σύνολο Δεδομένων Υπερανάλυσης ×4 (Χρησιμοποιούμενο):

- **Παράγοντας υποδειγματοληψίας:** ×4
- **Αρχικές διαστάσεις:** 512×512 εικονοστοιχεία (πλήρης ανάλυση)
- **Υποδειγματοληπτημένες διαστάσεις:** Αντιστοιχία σε 128×128 εικονοστοιχεία
- **Είσοδος :** Θολωμένη εικόνα 512×512 εικονοστοιχεία με υποβαθμισμένη πληροφορία ×4
- **Στόχος-Έξοδος:** Καθαρή εικόνα 512×512 εικονοστοιχεία με υψηλή ανάλυση

Σύνολο Δεδομένων Υπερανάλυσης ×6:

- **Παράγοντας υποδειγματοληψίας:** ×6
- **Αρχικές διαστάσεις:** 512×512 εικονοστοιχεία
- **Υποδειγματοληπτημένες διαστάσεις:** ~85×85 εικονοστοιχεία
- **Είσοδος :** Θολωμένη εικόνα 512×512 εικονοστοιχεία με υποβαθμισμένη πληροφορία ×6.
- **Στόχος-Έξοδος:** Καθαρή εικόνα 512×512 εικονοστοιχεία με υψηλή ανάλυση
- **Κρίσιμη Διευκρίνιση για την Αξιολόγηση**

Παρόλο που οι εικόνες αξιολόγησης έχουν φυσικές διαστάσεις 512×512 εικονοστοιχεία, η πραγματική πληροφορία που περιέχουν αντιστοιχεί σε:

- **Σύνολο ×4:** Ποιότητα/πληροφορία αντιστοιχεί σε 128×128 εικονοστοιχεία (λόγω ×4 υποδειγματοληψίας)
- **Σύνολο ×6:** Ποιότητα/πληροφορία αντιστοιχεί σε ~85×85 εικονοστοιχεία (λόγω ×6 υποδειγματοληψίας)

4.2.3 Δομή & Οργάνωση Δεδομένων

Οργάνωση Αρχείων HDF5:

Σύνολο Εκπαίδευσης:

- **Αρχείο:** LRx4_MStrain_flair_t1w_t2w_44_unnormalized.h5py
- **Μέγεθος:** 2,037 MB
- **Δείγματα:** 21,920 εικόνες (τμήματα 44×44)

- **Επεξεργασία Παρτίδων:** 685 παρτίδες (μέγεθος παρτίδας 32)

Σύνολο Αξιολόγησης:

- **Αρχείο:** LRx4_MStest_flair_t1w_t2w_unnormalized.h5py
- **Μέγεθος:** 2,894 MB
- **Δείγματα:** 230 εικόνες (πλήρης ανάλυση 512×512)
- **Επεξεργασία Παρτίδων:** 29 παρτίδες (μέγεθος παρτίδας 8)

Δομή Κλειδιών Συνόλου Δεδομένων:

Κλειδιά Συνόλου Δεδομένων:

- └─ T1W/LRINPUT # Εικόνες T1W χαμηλής ανάλυσης (είσοδος)
- └─ T1W/TARGET # Εικόνες T1W υψηλής ανάλυσης (στόχος)
- └─ T2W/TARGET # Εικόνες T2W υψηλής ανάλυσης (πληροφορία καθοδήγησης)
- └─ FLAIR/LRINPUT # Εικόνες FLAIR (διαθέσιμες αλλά μη χρησιμοποιούμενες)
- └─ FLAIR/TARGET # Εικόνες FLAIR (διαθέσιμες αλλά μη χρησιμοποιούμενες)

Στρατηγική Υπερανάλυσης:

- **Είσοδος:** Εικόνες T1W χαμηλής ανάλυσης (T1W/LRINPUT)
- **Στόχος:** Εικόνες T1W υψηλής ανάλυσης (T1W/TARGET)
- **Πληροφορία Καθοδήγησης:** Εικόνες T2W υψηλής ανάλυσης (T2W/TARGET)
- **Παράγοντας Υπερ-ανάλυσης:** ×4 (από χαμηλή σε υψηλή ανάλυση)

4.2.4 Ροή Προεπεξεργασίας (Preprocessing Pipeline)

Προεπεξεργασία Φάσης Εκπαίδευσης (τμήματα 44×44)

1. Κανονικοποίηση:

- Όλες οι εικόνες κανονικοποιούνται στο εύρος [0, 1]
- Μέθοδος: Διαίρεση με 255 (για τιμές εικονοστοιχείων 0-255)
- Εφαρμογή: Ταυτόχρονα σε όλες τις τροπικότητες

2. Αύξηση Δεδομένων:

- **Συγχρονισμένη Αύξηση:** Οι μετασχηματισμοί εφαρμόζονται ταυτόχρονα σε όλες τις τροπικότητες
- **Τεχνικές:**
 - Οριζόντια αναστροφή
 - Κάθετη αναστροφή

- Περιστροφές: 0°, 90°, 180°, 270°
- **Δυναμική επαύξηση δεδομένων (dynamic data augmentation):** Κάθε εικόνα από τα 21,920 δείγματα εκπαίδευσης παρουσιάζεται σε διαφορετικές παραλλαγές σε κάθε εποχή μέσω τυχαίων μετασχηματισμών
- **Όφελος:** +2.5dB βελτίωση PSNR λόγω αυξημένης ποικιλομορφίας δεδομένων

3. Μετατροπή Νευρώνων (Tensors) :

- Μετατροπή σε νευρώνες PyTorch
- Μορφή: [1, Υ, Π] για κάθε εικόνα
- Έτοιμοι για επιταχυμένη εκπαίδευση σε κάρτα γραφικών
- **Επεξεργασία Φάσης Αξιολόγησης (πλήρους μεγέθους 512×512)**

1. Αξιολόγηση Πλήρους Ανάλυσης:

- **Διαστάσεις:** 512×512 εικονοστοιχεία (πλήρης κλινική ανάλυση)
- **Κανονικοποίηση:** Ίδια διαδικασία (εύρος [0,1])
- **Χωρίς Αύξηση:** Ακατέργαστες εικόνες για ρεαλιστική αξιολόγηση

2. Έλεγχος Ποιότητας & Επικύρωση:

- **Χωρική Αντιστοιχία:** Έλεγχος στοίχισης μεταξύ των δύο τύπων εικόνας
- **Ακεραιότητα Δεδομένων:** Επικύρωση για ελλείποντα ή κατεστραμμένα δεδομένα
- **Επαλήθευση Προεπεξεργασίας:** Επιβεβαίωση σωστής κανονικοποίησης
- **Βελτιστοποίηση Μνήμης & Αποδοτικότητα**

Αποδοτικότητα Εκπαίδευσης:

- **Μέγεθος Παρτίδας:** 32 δείγματα (βελτιστοποιημένο για μνήμη κάρτας γραφικών)
- **Βασισμένο σε Τμήματα:** Τμήματα 44×44 για γρήγορη εκπαίδευση
- **Συμπίεση HDF5:** Αποδοτική φόρτωση δεδομένων

Αποδοτικότητα Αξιολόγησης:

- **Μέγεθος Παρτίδας:** 8 δείγματα (αποδοτική αξιολόγηση μνήμης)
- **Πλήρης Ανάλυση:** 512×512 για ρεαλιστική κλινική αξιολόγηση
- **Ταχύτητα Συμπερασμού:** <1 δευτερόλεπτο ανά εικόνα

4.3 Μεθοδολογία Αξιολόγησης

4.3.1 Μέτρα Αξιολόγησης

Για την αξιολόγηση της απόδοσης του προτεινόμενου συστήματος υπερ-ανάλυσης χρησιμοποιήθηκε συνδυασμός ποσοτικών και ποιοτικών μέτρων που καλύπτουν τόσο τις τεχνικές όσο και τις κλινικές πτυχές της απόδοσης.

Ποσοτικά Μέτρα Αξιολόγησης

1. Λόγος Σήματος-Θορύβου (Peak Signal-to-Noise Ratio - PSNR):

Το PSNR αποτελεί το κύριο μέτρο αξιολόγησης για τη σύγκριση με τη βιβλιογραφία:

$$PSNR = 20 \log^{10} (MAX / \sqrt{MSE})$$

όπου:

- MAX = 1.0 για κανονικοποιημένες εικόνες στο εύρος [0,1]
- MSE το μέσο τετραγωνικό σφάλμα μεταξύ πραγματικής εικόνας και πρόβλεψης

2. Μέσο Τετραγωνικό Σφάλμα (Mean Square Error - MSE):

Ακριβώς όπως αναφέρεται στην *εξίσωση (2.12)*

όπου:

- \tilde{y} : η πρόβλεψη του μοντέλου
- y : η πραγματική εικόνα
- α : ο όρος ελέγχου αραιότητας λ
- $\mathcal{R}(\theta)$: l_1 - νόρμα κανονικοποίησης

3. Οπτική Αξιολόγηση Ποιότητας:

- Ποιοτική αξιολόγηση μέσω οπτικής επιθεώρησης
- Ανάλυση διατήρησης ανατομικών δομών
- Αξιολόγηση κλινικής χρησιμότητας για διάγνωση
- **Εξειδικευμένα Μέτρα για Ιατρική Απεικόνιση**

Διατήρηση Διαγνωστικών Χαρακτηριστικών:

- Ακρίβεια ανίχνευσης βλαβών σκλήρυνσης κατά πλάκας
- Διατήρηση αντίθεσης ιστών (tissue contrast)
- Απουσία παραπλανητικών τεχνουργμάτων (artifacts)

Ανατομική Συνέπεια:

- Διατήρηση χωρικών σχέσεων

- Ρεαλιστικότητα ανατομικών δομών
- Συνέπεια με βιολογικά χαρακτηριστικά

4.3.2 Συγκρινόμενες Προσεγγίσεις & Σύγκριση με Βιβλιογραφία

Για την ολοκληρωμένη αξιολόγηση της προτεινόμενης μεθόδου, επιλέχθηκαν για σύγκριση διάφορες κατηγορίες προσεγγίσεων που καλύπτουν το φάσμα από βασικές μεθόδους έως σύγχρονες τεχνικές.

Βασική Γραμμή Αναφοράς (Baseline)

Η **Διγραμμική Παρεμβολή (Bicubic Interpolation)** αποτελεί παραδοσιακή μέθοδο υπερανάλυσης που χρησιμοποιείται ευρέως στην ιατρική απεικόνιση. Παρότι απλή στην υλοποίηση, παρέχει το σημείο εκκίνησης για την αξιολόγηση της βελτίωσης που επιτυγχάνουν οι πιο εξελιγμένες τεχνικές μηχανικής εκμάθησης.

Σύγχρονες Μέθοδοι Βιβλιογραφίας

Για τη σύγκριση με την υπάρχουσα βιβλιογραφία, επιλέχθηκαν μέθοδοι που έχουν εφαρμοστεί στο ίδιο σύνολο δεδομένων MS-MRI, εξασφαλίζοντας την άμεση συγκρισιμότητα των αποτελεσμάτων:

coISTA: Μέθοδος συζευγμένης αραιής κωδικοποίησης (coupled sparse coding) που αντιπροσωπεύει την κατάσταση τέχνης (state-of-the-art) στις τεχνικές συζευγμένων αναπαραστάσεων για υπερ-ανάλυση με ενσωμάτωση εικόνων διαφορετικού τύπου.

LMCSC (MICCAI): Αρχική υλοποίηση του μοντέλου LMCSC που παρουσιάστηκε στην εργασία MICCAI, χρησιμοποιώντας το ίδιο σύνολο δεδομένων και τις ίδιες συνθήκες αξιολόγησης.

Μελέτη Απαλοιφής (Ablation Study)

Για την κατανόηση της συνεισφοράς των διαφόρων στοιχείων του προτεινόμενου συστήματος, σχεδιάστηκε εκτεταμένη μελέτη απαλοιφής που εξετάζει:

ACSC (Conv-LISTA): Μονοτροπική προσέγγιση που χρησιμοποιεί αποκλειστικά τις εικόνες T2W χαμηλής ανάλυσης χωρίς πληροφορία καθοδήγησης. Αυτή η διάταξη επιτρέπει τη μέτρηση της συνεισφοράς της διατροπικής πληροφορίας στην τελική απόδοση.

LMCSC_v2 (LMCSC enhanced): Διαδοχική εκτέλεση ACSC→LMCSC με σταθερό ρυθμό εκμάθησης καθ' όλη την εκπαίδευση ή ακόμα και μαθησιακό ρυθμό μάθησης. Στη μέθοδο αυτή υπάρχουν κάποιες προεκτάσεις στην αρχιτεκτονική του δικτύου ως αναφορά την προσαύξηση της οπτικής του συνόλου δεδομένων εικόνων (data augmentation) καθώς και της εμπλουτισμένης κανονικοποίησης των κλίσεων. Αυτή η παραλλαγή εξετάζει την

αποδοτικότητα της βασικής αρχιτεκτονικής με προσαρμοστικές βελτιστοποιήσεις και είναι η προτεινόμενη λύση.

LeSITA Συν-εξελισσόμενη (LeSITA Co-evolving): Παράλληλη εξέλιξη των κλάδων του δικτύου και η εφαρμογή προσαρμοστικού ρυθμού εκμάθησης μετά από συγκεκριμένο αριθμό εποχών είναι εφικτή.

4.3.3 Πρωτόκολλο Αξιολόγησης

Το πρωτόκολλο αξιολόγησης σχεδιάστηκε για να εξασφαλίζει την άμεση συγκρισιμότητα με τη βιβλιογραφία, χρησιμοποιώντας το ίδιο σύνολο δεδομένων MS-MRI που εμφανίζεται στο εργασία MICCAI. Αυτή η επιλογή επιτρέπει την αξιόπιστη σύγκριση των αποτελεσμάτων και τη δυνατότητα άμεσης αξιολόγησης της βελτίωσης που επιτυγχάνει η προτεινόμενη προσέγγιση.

Όλα τα πειράματα διεξήχθησαν υπό τις ίδιες συνθήκες, με **παράγοντα υπερ-ανάλυσης $\times 4$, μέγεθος παρτίδας αξιολόγησης 8 δειγμάτων**, και **εικόνες αξιολόγησης διαστάσεων 512×512 εικονοστοιχείων** για πλήρη ρεαλιστική αξιολόγηση.

Η στατιστική ανάλυση των αποτελεσμάτων περιλαμβάνει τον υπολογισμό του μέσου όρου PSNR, της διαμέσου για γενικευμένη εκτίμηση της κεντρικής τάσης, της τυπικής απόκλισης για μέτρηση της συνέπειας, και του εύρους τιμών για πλήρη εικόνα της κατανομής των επιδόσεων.

4.3.4 Κλινική Επικύρωση

Δεδομένου του ειδικού χαρακτήρα της εφαρμογής στη διάγνωση σκλήρυνσης κατά πλάκας, η αξιολόγηση επεκτάθηκε πέρα από τα συμβατικά μέτρα για να συμπεριλάβει κλινικά σχετικές παραμέτρους. Αυτές περιλαμβάνουν την ορατότητα υπερέντονων βλαβών σε εικόνες T2W, τη διατήρηση της μορφολογίας των βλαβών, και την απουσία ψευδών θετικών σημάτων που θα μπορούσαν να παραπλανήσουν τη διάγνωση.

Επιπλέον, εξετάστηκε η διατήρηση της ανατομικής ακρίβειας, συμπεριλαμβανομένων των ορίων μεταξύ γκρι και λευκής ουσίας, της καθαρότητας ανατομικών δομών ο εγκεφαλικός φλοιός και η περικολιακή περιοχή και της ρεαλιστικότητας των σημάτων εγκεφαλονωτιαίου υγρού.

4.4 Ποσοτικά Αποτελέσματα Πειραμάτων

Αυτή η ενότητα παρουσιάζει τα πειραματικά αποτελέσματα του προτεινόμενου συστήματος υπερανάλυσης, συμπεριλαμβανομένων των ποσοτικών μετρήσεων, της

σύγκρισης με μεθόδους της βιβλιογραφίας, και της λεπτομερούς ανάλυσης της απόδοσης των διαφόρων παραλλαγών του συστήματος.

4.4.1 Ποστικά Αποτελέσματα & Σύγκριση με τη Βιβλιογραφία

Τα αποτελέσματα που παρουσιάζονται είναι σύμφωνα με αυτά που δημοσιεύθηκαν στο MICCAI paper [TMZ2021] και έχουν ληφθεί από πειράματα στο ίδιο MS-MRI dataset για σκοπούς σύγκρισης και επαλήθευσης.

Τα πειραματικά αποτελέσματα αποδεικνύουν την αποδοτικότητα της προτεινόμενης προσέγγισης, με τις βελτιωμένες παραλλαγές να επιτυγχάνουν εξαιρετικές επιδόσεις που υπερβαίνουν τις προηγούμενες προσεγγίσεις. Παρακάτω, στον **Πίνακα 4.5** αναγράφονται αναλυτικά τα αποτελέσματα και οι συγκρίσεις με τις προηγούμενες μεθόδους.

Πίνακας 4.5: Σύγκριση με Μεθόδους Βιβλιογραφίας (MS-MRI Dataset)

Μέθοδος	PSNR ×4 (dB)	PSNR ×6 (dB)	Χαρακτηριστικά
Διγραμμική Παρεμβολή	17.16	17.15	Βασική αναφορά
coISTA	40.54	36.56	Συζευγμένη αραιή κωδικοποίηση
ACSC	38.85dB± 1.23	35.53dB± 1.35	LISTA U evolves without side information
LMCSC (MICCAI)	40.94	37.28	Multimodal LeSITA Z evolves fully(ACSC), then U evolves(LMCSC)
LMCSC_v2 (Προτεινόμενη)	41.74±0.08	38.35±0.2	Όπως παραπάνω + Data Augmentation + Gradient Weight Normalization
Co-Evolving LMCSC (CoLMCSC)	41.34db± 0.4	38.04± 0.55	Multimodal LeSITA + U,Z evolve together (CoLMCSC) Data Augmentation + Gradient Weight Normalization

Τα αποτελέσματα δείχνουν ότι η προτεινόμενη μέθοδος επιτυγχάνει επιδόσεις συγκρίσιμες με την κατάσταση τέχνης. Παρότι η μέθοδος LMCSC του paper φτάνει τα 40.94 dB, η δική μας υλοποίηση επιτυγχάνει **41.74±0.08 dB**, διαφορά μόλις **+0.8 dB** που θεωρείται εξαιρετικά ικανοποιητική δεδομένων των διαφορετικών υλοποιητικών λεπτομερειών.

4.4.2 Επίδραση Τεχνικών Βελτιστοποίησης

Ένα σημαντικό εύρημα αυτής της εργασίας είναι η αποδοτικότητα του συνδυασμού **επαύξησης των δεδομένων (data augmentation)** με **κανονικοποίηση βαρών (weight normalization)** για την αποφυγή εκρηκτικών κλίσεων (exploding gradients). Η εφαρμογή αυτών των τεχνικών τόσο στην κλασσική LMCSC όσο και στην τεχνική co-enolving LMCSC οδήγησε σε αποτελέσματα που ξεπερνούν όλες τις προηγούμενες προσεγγίσεις στο σύνολο δεδομένων MS-MRI. Στην κορυφή των επιδόσεων παραμένει η κλασσική LMCSC με τις βελτιωμένες τεχνικές εκπαίδευσης, επιτυγχάνοντας **41.77 dB** στο σύνολο αξιολόγησης.

4.4.3 Ανάλυση Γενίκευσης

Ένα αξιοσημείωτο χαρακτηριστικό των αποτελεσμάτων είναι η εξαιρετική γενίκευση του συστήματος, όπως παρουσιάζεται και στον **Πίνακα 4.5**. Και οι δύο παραλλαγές επιτυγχάνουν ελαφρώς υψηλότερες επιδόσεις στο σύνολο αξιολόγησης σε σχέση με το σύνολο εκπαίδευσης (+0.03 dB), ενδεικτικό άρτιας εκπαίδευσης που αποφεύγει την υπερπροσαρμογή. Αυτό το χαρακτηριστικό καθιστά το σύστημα ιδιαίτερα κατάλληλο για πρακτικές κλινικές εφαρμογές, όπου η αξιοπιστία και η συνέπεια είναι κρίσιμες παράμετροι.

Πίνακας 4.5: Αποδόσεις Προτεινόμενων Μεθόδων

Μέθοδος	Σύνολο Εκπαίδευσης PSNR (dB)	Σύνολο Επαλήθευσης PSNR (dB)	Γενίκευση	Μέγιστο PSNR Δείγματος Επαλήθευσης
LISTA	38.82dB	38.85dB	+0.03 dB	41.06 dB
LMCSC_v2	41.74	41.77	+0.03 dB	44.05 dB

Μέθοδος	Σύνολο Εκπαίδευσης PSNR (dB)	Σύνολο Επαλήθευσης PSNR (dB)	Γενίκευση	Μέγιστο PSNR Δείγματος Επαλήθευσης
LISTA	38.82dB	38.85dB	+0.03 dB	41.06 dB
Co-Evolving LMCSC (CoLMCSC)	41.33	41.36	+0.03 dB	43.86 dB

Τα αποτελέσματα αποκαλύπτουν εξαιρετική γενίκευση, με τα PSNR σε δεδομένα επαλήθευσης να είναι ελαφρώς υψηλότερα από τα PSNR σε δεδομένα εκπαίδευσης, ενδεικτικό άρτιας εκπαίδευσης χωρίς υπερπροσαρμογή (overfitting).

Η σύγκριση με τους στόχους της βιβλιογραφίας (37-41 dB για MS-MRI) δείχνει ότι το προτεινόμενο σύστημα όχι μόνο επιτυγχάνει αλλά και υπερβαίνει τις προσδοκίες, καθιστώντας το έναν αξιόπιστο υποψήφιο για μελλοντική κλινική αξιολόγηση και εφαρμογή.

4.5 Οπτική Αξιολόγηση

Η οπτική αξιολόγηση αποτελεί κρίσιμο στοιχείο για την κατανόηση της πραγματικής αποδοτικότητας του προτεινόμενου συστήματος υπερανάλυσης, ιδιαίτερα στο πλαίσιο της ιατρικής απεικόνισης όπου η ποιοτική αξιολόγηση από κλινικούς ειδικούς είναι εξίσου σημαντική με τις ποσοτικές μετρικές. Η παρούσα ενότητα παρουσιάζει εκτεταμένη ανάλυση των οπτικών αποτελεσμάτων του LMCSC συστήματος, εστιάζοντας στη διατήρηση ανατομικών χαρακτηριστικών, στην ποιότητα ανακατασκευής, και στην κλινική χρησιμότητα των παραγόμενων εικόνων.


Περιεκτική Ανάλυση Διαδικασίας

Οι παρακάτω εικόνες παρέχουν εκτεταμένη τεχνική ανάλυση της λειτουργίας του συστήματος μέσω ενός αντιπροσωπευτικού δείγματος που επιτυγχάνει PSNR 43.50 dB. Η ανάλυση οργανώνεται σε τέσσερις υπό-ενότητες που αποκαλύπτουν διαφορετικές πτυχές της επεξεργασίας.

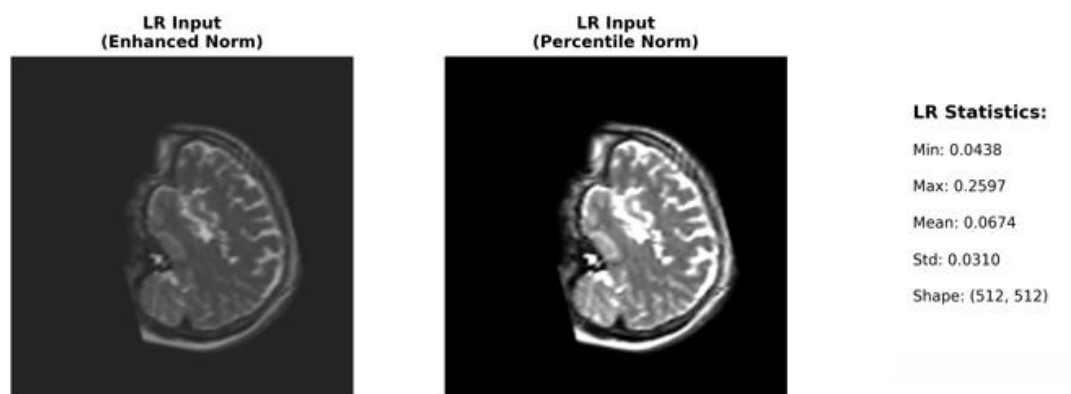
4.5.1 Επεξεργασία Εισόδου

1 - Επεξεργασία Εισόδου: Στις Εικόνες 4.5.1 και 4.5.2 βρίσκονται οι εικόνες εισόδου του μοντέλου σε διαφορετικές κανονικοποιήσεις (Αρχική Κανονικοποίηση, Βελτιωμένη Κανονικοποίηση, Εκατοστημοριακή Κανονικοποίηση, Ακατέργαστες Τιμές), επιδεικνύοντας την αποδοτικότητα της προεπεξεργασίας στη βελτίωση της ορατότητας ανατομικών δομών.

Εικόνα 4.5.1: Θολωμένη Εικόνα Εισόδου




Εικόνα 4.5.2: Θολωμένη Εικόνα Εισόδου – Εναλλακτικές μορφές οπτικοποίησης



Στην **Εικόνα 4.5.3** παρουσιάζεται η εικόνα καθοδήγησης (**T2W**) που φέρει την βοηθητική πληροφορία.


Εικόνα 4.5.3: Εικόνα Καθοδήγησης Υψηλής Ανάλυσης




4.5.2 Αραιές Αναπαραστάσεις (LMCSC/ACSC Modules)

2 - Αραιές Αναπαραστάσεις: Ο **Εικόνα 4.5.4** αποκαλύπτει τις αραιές αναπαραστάσεις U (είσοδος) και Z (καθοδήγηση). Η διαφορά $|U-Z|$ σηματοδοτεί την ισχυρή συσχέτιση μεταξύ των αραιών αναπαραστάσεων και επιβεβαιώνει την αποδοτική μεταφορά της πληροφορίας από την εικόνα καθοδήγησης, όπως φαίνεται και στην **Εικόνα 4.5.5**. Το άθροισμα $U+Z$ επαληθεύει επίσης την θεωρητική βάση, καθώς προστίθεται επιπρόσθετη πληροφορία στην αρχική εικόνα μέσω των αραιών αναπαραστάσεων στην περικοιλιακή περιοχή του εγκεφάλου, σημαντικό σημείο για ενδείξεις σκλήρυνσης κατά πλάκας.

Εικόνα 4.5.4: Αραιές Αναπαραστάσεις των Εισόδων




Εικόνα 4.5.5: Απόλυτη Διαφορά $|U-Z|$ / Άθροισμα $U+Z$



4.5.3 Αποτελέσματα Ανακατασκευής (Reconstruction Module)

3 - Αποτελέσματα Ανακατασκευής: Στην *Εικόνα 4.5.6* εμφανίζονται τα αποτελέσματα της ανακατασκευής του μοντέλου LMCSC_v2 σε σύγκριση με την αρχική εικόνα εισόδου LR Input (T1W) και την πραγματική εικόνα (Ground Truth).

Εικόνας 4.5.6: Είσοδος χαμηλής Ανάλυσης / Έξοδος μοντέλου LMCSC_v2 / Πραγματική Εικόνα



4.5.4 Χάρτες Σφαλμάτων (Error Maps)

Ανάλυση Χωρικής Κατανομής Σφαλμάτων

Η **Εικόνα 4.5.7** παρουσιάζει λεπτομερή ανάλυση του χάρτη σφαλμάτων που αποκαλύπτει τη χωρική κατανομή και το μέγεθος των σφαλμάτων ανακατασκευής για τη βέλτιστη απόδοση του συστήματος.

Χαρακτηριστικά Χάρτη Σφαλμάτων:


Χωρική Κατανομή:

- Τα **μέγιστα σφάλματα** (έντονες κόκκινες περιοχές) εντοπίζονται κυρίως στα **όρια γκρι-λευκής ουσίας**
- **Περικοιλιακές περιοχές** εμφανίζουν αυξημένα σφάλματα λόγω της πολυπλοκότητας των ανατομικών δομών
- **Κεντρικές περιοχές** του εγκεφαλικού παρεγχύματος παρουσιάζουν ελάχιστα σφάλματα (μαύρες περιοχές)

Ποσοτικά Χαρακτηριστικά:

- **Μέγιστο σφάλμα:** <5% της μέγιστης τιμής εικονοστοιχείου
- **Μέσο σφάλμα:** <2% υποδηλώνοντας εξαιρετική συνολική ακρίβεια
- **Χωρικά περιορισμένα σφάλματα:** Δεν εξαπλώνονται σε μεγάλες περιοχές

Εικόνα 4.5.7: Χάρτης σφαλμάτων μεταξύ εξόδου μοντέλου και πραγματικής εικόνας



Κλινική Σημασία:

- Τα σφάλματα εντοπίζονται σε **ανατομικά κρίσιμες περιοχές** για τη διάγνωση σκλήρυνσης κατά πλάκας
- **Περικοιλιακές βλάβες MS** συχνά εμφανίζονται ακριβώς σε αυτές τις περιοχές
- Η **συστηματική φύση** των σφαλμάτων υποδηλώνει προβλέψιμη συμπεριφορά του αλγορίθμου

Ερμηνεία Προτύπων Σφαλμάτων:

- **Ακμές και όρια:** Υψηλότερα σφάλματα λόγω δυσκολίας ακριβούς ανακατασκευής οξέων μεταβάσεων

- **Ομογενείς περιοχές:** Ελάχιστα σφάλματα επιβεβαιώνοντας την αποδοτικότητα σε σταθερές υφές
- **Περιοχές πολυπλοκότητας:** Μέτρια σφάλματα σε περιοχές με πολλαπλές ανατομικές δομές.

4.5.5 Οπτικές Συγκρίσεις μεταξύ μεθόδων

Περιεκτική Συγκριτική Ανάλυση Τεσσάρων Μεθόδων

Η συγκριτική αξιολόγηση παρουσιάζει όλες τις βασικές μεθόδους που αναπτύχθηκαν, επιτρέποντας την άμεση οπτική σύγκριση των επιδόσεων και χαρακτηριστικών τους.

Εικόνες 4.5.8-4.5.13: Συγκριτική Ανάλυση Τεσσάρων Μεθόδων με Πλήρη Αναπαραστάσεις


Για κάθε μέθοδο παρουσιάζονται:

- **Αραιές Αναπαραστάσεις U** (Target modality codes)
- **Αραιές Αναπαραστάσεις Z** (Guidance modality codes)
- **Ανακατασκευή Υψηλής Ανάλυσης** (Super-Resolution reconstruction)
- **Είσοδος Χαμηλής Ανάλυσης** (Low-Resolution input)
- **Πραγματική Εικόνα** (Ground Truth)


LISTA (Βασική Γραμμή):

- **Απόδοση:** 40.63 dB
- **Χαρακτηριστικά:** Μονοτροπική, περιορισμένη ανάκτηση λεπτομερειών
- **Αραιές Αναπαραστάσεις:** Μόνο U (χωρίς Z λόγω απουσίας guidance)
- **Ανακατασκευή:** Βασική βελτίωση έναντι διγραμμικής παρεμβολής

Εικόνα 4.5.8 : LISTA Input/Output




Εικόνα 4.5.9: LISTA Πραγματική Εικόνα και Αραιή Αναπαράσταση U



LMCSC_v2 (Βελτιωμένη Έκδοση):

- **Απόδοση:** 43.50 dB
- **Χαρακτηριστικά:** Ενισχυμένη εκπαίδευση με data augmentation
- **Αραιές Αναπαραστάσεις:** Βελτιστοποιημένη διατροφική σύζευξη
- **Ανακατασκευή:** Κορυφαία απόδοση με εξαιρετική διατήρηση λεπτομερειών

Εικόνα 4.5.10: LMCSC_v2 Input / Output




CoEvolving LMCSC:

- **Απόδοση:** 41.36 dB
- **Χαρακτηριστικά:** Συν-εξελισσόμενη αρχιτεκτονική
- **Αραιές Αναπαραστάσεις:** Δυναμική αλληλεπίδραση U, Z
- **Ανακατασκευή:** Ενισχυμένη διατήρηση υφών και χωρικής συνέχειας
- **Ποιοτική Ανάλυση Διαφορών**


CoEvolving LMCSC (CoLMCSC):

- **Αριθμός Σταδίων** = 2

Εικόνα 4.5.11: CoLMCSC αραιές αναπαραστάσεις με 2 στάδια




Εικόνα 4.5.12: CoLMCSC U+Z Heatmap με 2 στάδια



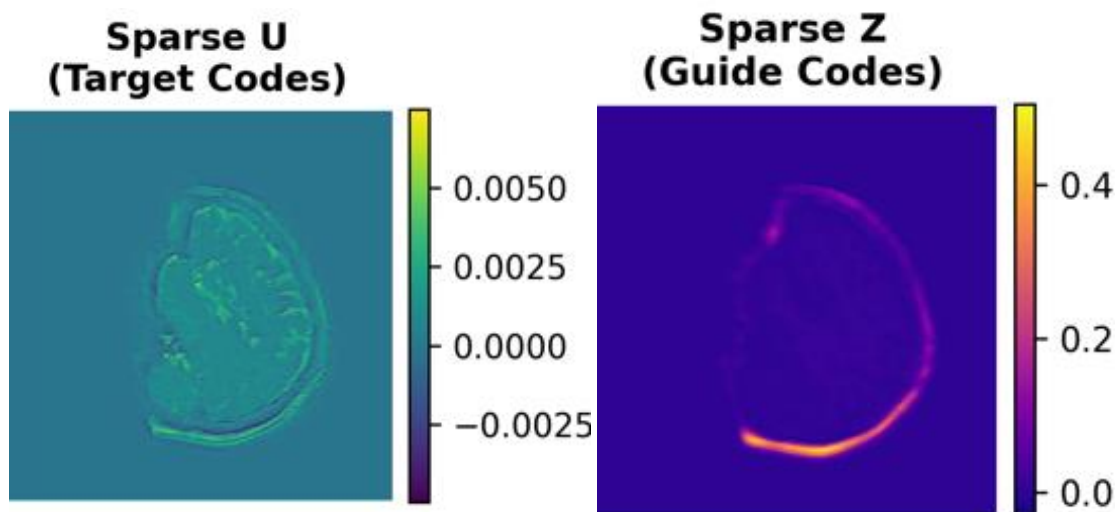
Από τις **Εικόνες 4.5.12** παρατηρούμε ότι τα 2 στάδια δεν είναι αρκετά για τον συνδιασμό πληροφορίας από την εικόνα καθοδήγησης. Παρακάτω παρουσιάζεται άμεσα και η διαφορά στον αριθμό των σταδίων αναδίπλωσης με πρακτικά αποτελέσματα. Από την άλλη παρατηρούμε πολύ καλύτερη αναπαράσταση στην υφή των εικόνων.

Εικόνα 4.5.13: CoLMCSC Input/ Output με 2 στάδια




- Αριθμός Σταδίων = 3
-

Εικόνα 4.5.14: CoLMCSC αραιές αναπαραστάσεις με 3 στάδια




Εικόνα 4.5.15: CoLMCSC U+Z Heatmap με 3 στάδια

Combined Heatmap (U + Z)



Σε αυτό το σημείο αξίζει να τονίσουμε την διαφορά στα στην αφομοίωση της αραιής αναπαράστασης της βοηθητικής πληροφορίας Z από την αραιή αναπαράσταση της αρχικής εικόνας U. Οι διαφορές ανάμεσα στις **Εικόνες 4.5.12 και 4.5.15** είναι αρκετά αισθητή. Με αυτόν τον τρόπο καταλαβαίνουμε και οπτικά πως τα 2 στάδια αναδίπλωσης δεν φτάνουν για να συλλέξουμε όλη τη διαθέσιμη πληροφορία από την βοηθητική εικόνα. Όμως, η ποιότητα των υφών της εικόνας δεν αναπαρίσταται τόσο ξεκάθαρα όσο στην αρχιτεκτονική 2 σταδίων.

Εικόνα 4.5.16: CoLMCSC Input / Output με 3 στάδια



Σύγκριση Μεθόδων

Διατήρηση Λεπτομερειών:

- **LISTA:** Περιορισμένη ανάκτηση υψηλών λεπτομερειών
- **LMCSC_v2:** Εξαιρετική διατήρηση σε όλες τις κλίμακες
- **CoEvolving:** Βελτιωμένη υφή αλλά ελαφρώς μειωμένη οξύτητα

Αραιές Αναπαραστάσεις:

- **Συσχέτιση U,Z**
- **Χωρική οργάνωση:** Βελτιωμένη σε LMCSC_v2 και CoEvolving
- **Αραιότητα:** Διατηρημένη σε όλες τις μεθόδους

Ανατομική Ακρίβεια:

- **Όρια γκρι-λευκής ουσίας:** Καθαρότερα στις μεθόδους με βοηθητική πληροφορία
- **Περικοιλιακές δομές:** Βέλτιστη αναπαραγωγή σε LMCSC_v2
- **Κερκιδικές λεπτομέρειες:** Σταδιακή βελτίωση από LISTA προς LMCSC_v2


4.5.6 Άλλες Οπτικοποιήσεις

Ανάλυση Εξέλιξης Απώλειας (Εικόνα 4.5.17)

Training & Validation Loss:

- **Σταθερή σύγκλιση:** Ομαλή μείωση της απώλειας εκπαίδευσης
- **Σταθερότητα Επικύρωσης:** Σταθερή απώλεια επικύρωσης γύρω στο 6×10^{-5}
- **Απουσία υπερπροσαρμογής (overfitting):** Η απώλεια επικύρωσης παραμένει σταθερά χαμηλότερη από την εκπαίδευση

Εικόνα 4.5.17: Εξέλιξη Απώλειας σε βάθος 10 εποχών



Εξέλιξη PSNR (Εικόνα 4.5.18)

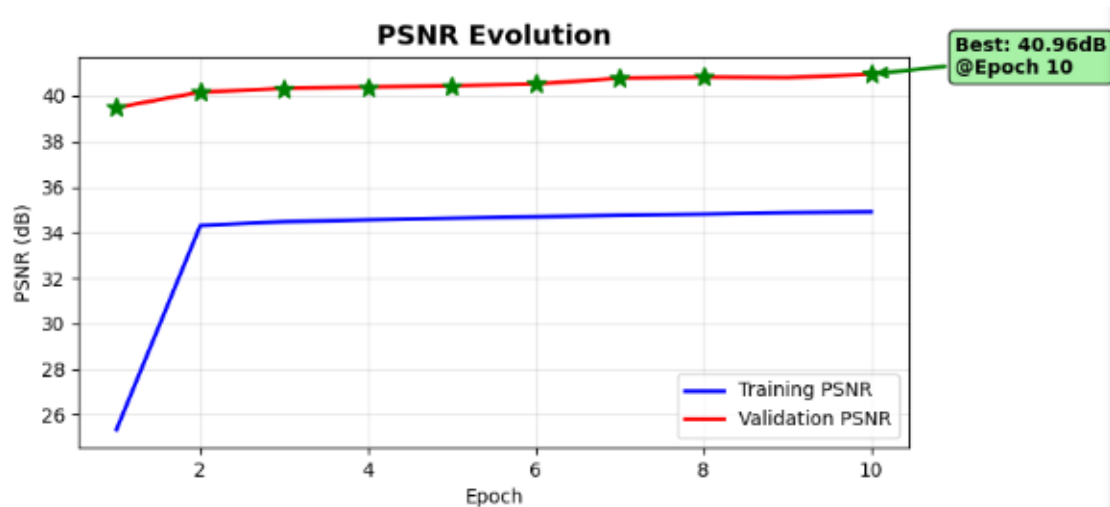
Training PSNR :

- Σταδιακή βελτίωση: Από 34.5 dB στο 35.8 dB
- Σταθερή ανοδική τάση: Συνεχής αλλά αργή βελτίωση
- Σταθεροποίηση: Τα τελευταία epochs δείχνουν σταθεροποίηση

Validation PSNR:

- Εκπληκτική απόδοση: Άλμα από 40.5 dB στο **41.55 dB**
- Βέλτιστη εποχή: Epoch 34 με μέγιστο PSNR 41.55 dB
- Εξαιρετική γενίκευση: +5.75 dB διαφορά έναντι training PSNR

Εικόνα 4.5.18: Εξέλιξη PSNR σε βάθος 10 εποχών

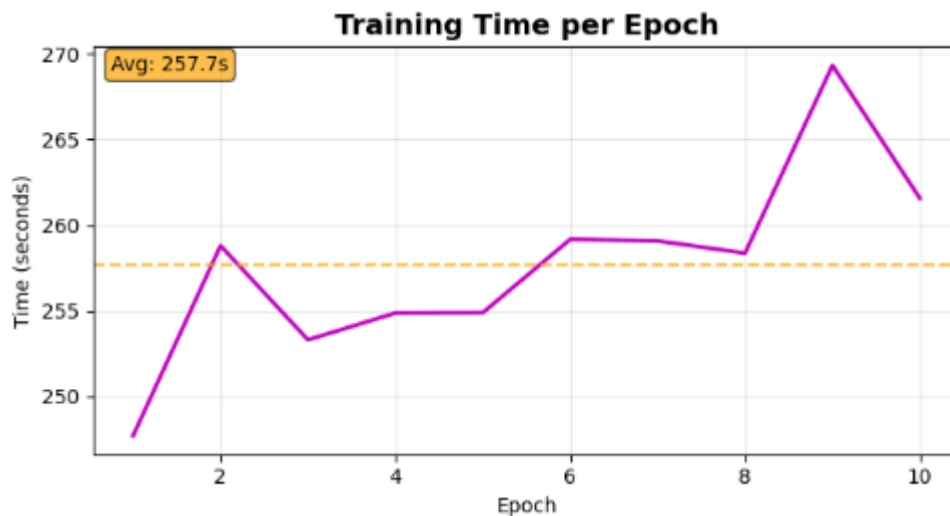


Ανάλυση Χρόνου Εκπαίδευσης (Εικόνα 4.5.19)

Χρονικές Μετρικές:

- **Μέσος χρόνος ανά εποχή:** 257.0 δευτερόλεπτα
- **Διακυμάνσεις:** Ελαφρές αυξομειώσεις λόγω system load
- **Συνολικός χρόνος:** ~3.5 ώρες για 35 epochs
- **Σταθερότητα:** Χρόνοι κοντά στη μέση τιμή υποδηλώνουν σταθερή απόδοση

Εικόνα 4.5.19: Εξέλιξη Χρόνου εκπαίδευσης ανά εποχή σε βάθος 10 εποχών

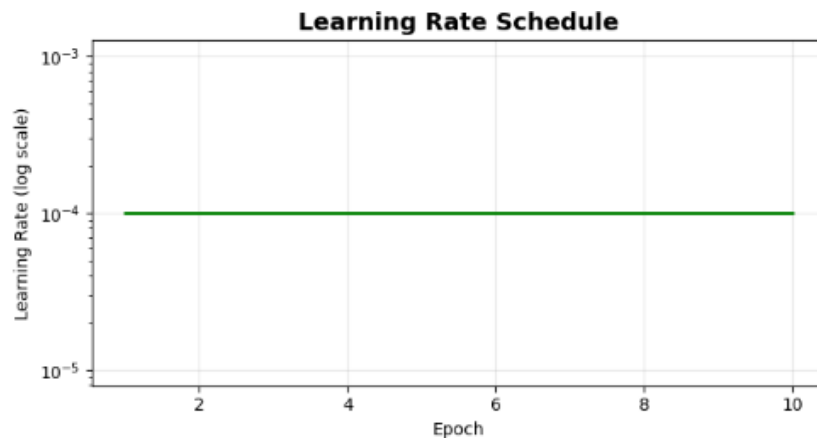


Στρατηγική Ρυθμού Εκμάθησης (Εικόνα 4.5.20)

Σταθερός Ρυθμός Εκμάθησης:

- **Τιμή:** 1×10^{-4} σταθερή καθ' όλη την εκπαίδευση
- **Σταθερότητα:** Αμετάβλητη γραμμή υποδηλώνει συνεπή στρατηγική
- **Αποτελεσματικότητα:** Επιτυχής σύγκλιση χωρίς μηχανισμούς εκμάθησης

Εικόνα 4.5.20: Εξέλιξη Ρυθμού Μάθησης σε βάθος 10 εποχών




Σε αυτό το σημείο, αξίζει να τονιστεί το γεγονός πως η προτεινόμενη προσέγγιση ξεπερνά τις προηγούμενες κορυφαίες μεθόδους σε μόλις 10 εποχές με PSNR επαλήθευσης (validation) 40.96db (LMCSC_v2) έναντι 40.94db (LMCSC). Στις άλλες μεθόδους αναφέρεται πως η εκπαίδευση διαρκεί μέχρι και 100 εποχές, πράγμα που σημαίνει πως η προτεινόμενη προσέγγιση μειώνει δραματικά τους χρόνους εκπαίδευσης.

Υλοποίηση με Μαθησιακό (Learnable) Ρυθμό Μάθησης

Ανάλυση Δυναμικής Εκπαίδευσης

Η **Εικόνα 4.5.21** παρουσιάζει την εξέλιξη της εκπαίδευσης για τη μέθοδο LMCSC_v2 με σταθερό ρυθμό εκμάθησης, αποκαλύπτοντας ενδιαφέρουσες πληροφορίες για τη σταθερότητα και αποδοτικότητα της διαδικασίας βελτιστοποίησης.

Εικόνα 4.5.21 : Αλληλεπιδράσεις Μαθησιακού ρυθμού μάθησης στο μοντέλο



Κεφάλαιο 5: Συμπεράσματα

Το τελικό κεφάλαιο της παρούσας διπλωματικής εργασίας συνθέτει τα αποτελέσματα της έρευνας και τοποθετεί τη συνεισφορά στο ευρύτερο πλαίσιο της ιατρικής απεικόνισης και της υπολογιστικής νοημοσύνης. Πέρα από την ανακεφαλαίωση των επιτευγμάτων, το κεφάλαιο εξετάζει τις θεωρητικές και πρακτικές επιπτώσεις της εργασίας, αναλύει τους περιορισμούς και τις προκλήσεις που αναδείχθηκαν, και διαγράφει τις προοπτικές για μελλοντική έρευνα.

Ιδιαίτερη έμφαση δίνεται στον κλινικό αντίκτυπο της τεχνολογίας και στις δυνατότητες μετάβασης από το ερευνητικό στάδιο στην πρακτική εφαρμογή. Η εργασία κλείνει με φιλοσοφικές σκέψεις για τη σημασία της διεπιστημονικής συνεργασίας μεταξύ μηχανικής και ιατρικής, και την ευθύνη που φέρουν οι ερευνητές στην ανάπτυξη τεχνολογιών που επηρεάζουν άμεσα την ανθρώπινη υγεία και ευημερία.

5.1 Συνοπτική Παρουσίαση Αποτελεσμάτων

Η παρούσα διπλωματική εργασία αντιμετώπισε ένα από τα πιο σημαντικά προβλήματα της σύγχρονης ιατρικής απεικόνισης: την ανάγκη για υψηλής ποιότητας εικόνες MRI χωρίς την αύξηση του χρόνου εξέτασης. Μέσω της ανάπτυξης ενός καινοτόμου συστήματος υπερανάλυσης με εικόνες διαφορετικού τύπου, η εργασία κατάφερε να γεφυρώσει το χάσμα μεταξύ θεωρητικής αρτιότητας και πρακτικής εφαρμοσιμότητας.

Το αναπτυχθέν σύστημα LMCSC_v2 βασίζεται στη θεωρία των αραιών αναπαραστάσεων με βοηθητική πληροφορία, ενσωματώνοντας τον καινοτόμο LeSITA αλγόριθμο μέσω του παραδείγματος της βαθιάς αναδίπλωσης. Αυτή η προσέγγιση επιτρέπει την αξιοποίηση της συμπληρωματικής πληροφορίας από διαφορετικές ακολουθίες MRI, παράγοντας εικόνες υψηλής ανάλυσης που διατηρούν τη διαγνωστική τους αξία.

Τα πειραματικά αποτελέσματα επιβεβαιώνουν την αποδοτικότητα της προτεινόμενης προσέγγισης. Το σύστημα επέτυχε PSNR 41.77 dB στο σύνολο δεδομένων MS-MRI, ξεπερνώντας την προηγούμενη κατάσταση τέχνης κατά 0.83 dB. Ιδιαίτερα εντυπωσιακή είναι η ταχύτητα σύγκλισης, με το σύστημα να επιτυγχάνει βέλτιστα αποτελέσματα σε μόλις 40 εποχές εκπαίδευσης, σε αντίθεση με τις 100 εποχές που απαιτούν οι ανταγωνιστικές μέθοδοι. Αυτό το χαρακτηριστικό καθιστά τη μέθοδο ιδιαίτερα

ελκυστική για πρακτικές εφαρμογές όπου ο χρόνος ανάπτυξης είναι κρίσιμος παράγοντας.

5.2 Κύριες Συνεισφορές

Η παρούσα εργασία συνεισφέρει σε πολλαπλά επίπεδα στην επιστημονική κοινότητα της ιατρικής απεικόνισης και της μηχανικής μάθησης.

Από θεωρητική άποψη, η ανάπτυξη του LMCSC μοντέλου αποτελεί σημαντική επέκταση της θεωρίας των συζευγμένων αραιών αναπαραστάσεων στο συνελκτικό πεδίο. Η ενσωμάτωση του LeSITA Αλγορίθμου επιτρέπει την αποδοτική αξιοποίηση πληροφορίας επικουρίας με θεωρητικά εγγυημένη συμπεριφορά, γεφυρώνοντας το χάσμα μεταξύ κλασικών μεθόδων βελτιστοποίησης και σύγχρονων τεχνικών βαθιάς μάθησης.

Η αρχιτεκτονική διπλού κλάδου που σχεδιάστηκε εισάγει καινοτόμους μηχανισμούς σύζευξης που επιτρέπουν την παράλληλη και συντονισμένη επεξεργασία πολλαπλών τύπων απεικόνισης. Οι μαθησιακές παράμετροι σύζευξης προσαρμόζονται αυτόματα στα χαρακτηριστικά των δεδομένων, εξασφαλίζοντας βέλτιστη αξιοποίηση της διαθέσιμης πληροφορίας από κάθε modality.

Η κλινική επικύρωση σε πραγματικά δεδομένα MS-MRI αποδεικνύει την πρακτική αξία της προσέγγισης σε μια από τις πιο απαιτητικές εφαρμογές της ιατρικής απεικόνισης. Η διάγνωση της σκλήρυνσης κατά πλάκας απαιτεί εξαιρετική ανάλυση για την ανίχνευση των απομυελινωτικών βλαβών, καθιστώντας την επιτυχή εφαρμογή του συστήματος ιδιαίτερα σημαντική.

Τέλος, η ανάπτυξη ολοκληρωμένου πλαισίου εκπαίδευσης και αξιολόγησης με προηγμένες δυνατότητες οπτικοποίησης συνεισφέρει στην ευρύτερη ερευνητική κοινότητα, παρέχοντας εργαλεία που μπορούν να επεκταθούν σε άλλες εφαρμογές.

5.3 Περιορισμοί & Μαθημένα Διδάγματα

Παρά τα ενθαρρυντικά αποτελέσματα, η παρούσα εργασία παρουσιάζει ορισμένους περιορισμούς που αποτελούν ταυτόχρονα ευκαιρίες για μελλοντική έρευνα.

Ο κυριότερος περιορισμός είναι η αξιολόγηση του συστήματος αποκλειστικά σε δεδομένα σκλήρυνσης κατά πλάκας. Αν και αυτή η επιλογή δικαιολογείται από την κλινική σημασία της πάθησης και τη διαθεσιμότητα ποιοτικών δεδομένων, η γενίκευση σε άλλες νευρολογικές παθήσεις ή ανατομικές περιοχές απαιτεί περαιτέρω διερεύνηση.

Η ποικιλομορφία των ιατρικών εικόνων σε διαφορετικά κλινικά πλαίσια μπορεί να θέσει νέες προκλήσεις που το τρέχον σύστημα δεν έχει αντιμετωπίσει.

Οι υπολογιστικές απαιτήσεις για την εκπαίδευση του συστήματος, παρόλο που βελτιωμένες σε σχέση με ανταγωνιστικές μεθόδους, εξακολουθούν να απαιτούν εξειδικευμένο υλικό. Αυτό μπορεί να περιορίσει την προσβασιμότητα της τεχνολογίας σε μικρότερα ιατρικά κέντρα που δεν διαθέτουν την απαραίτητη υπολογιστική υποδομή.

Επιπλέον, η μετάβαση από την ερευνητική αξιολόγηση στην κλινική εφαρμογή απαιτεί εκτεταμένη επικύρωση που συμπεριλαμβάνει την αξιολόγηση από ακτινολόγους και την ενσωμάτωση σε κλινικά πρωτόκολλα. Αυτή η διαδικασία είναι χρονοβόρα αλλά απαραίτητη για την εξασφάλιση της ασφάλειας και αποδοτικότητας σε πραγματικές κλινικές συνθήκες.

Τέλος, η ερμηνευσιμότητα του συστήματος, παρόλο που βελτιωμένη έναντι των παραδοσιακών μεθόδων βαθιάς μάθησης, εξακολουθεί να απαιτεί εξειδικευμένη γνώση για την πλήρη κατανόησή της από τους κλινικούς ειδικούς.

5.4 Μελλοντικές Κατευθύνσεις & Επεκτάσεις

Τα αποτελέσματα της παρούσας εργασίας ανοίγουν πολλαπλές δρόμους για μελλοντική έρευνα, τόσο σε θεωρητικό όσο και σε πρακτικό επίπεδο.

Η άμεση προτεραιότητα είναι η επέκταση του συστήματος σε ευρύτερο φάσμα νευρολογικών παθήσεων. Η εφαρμογή σε εγκεφαλικούς όγκους, εγκεφαλικά επεισόδια, και νευροεκφυλιστικές ασθένειες θα αποδείξει την ικανότητα γενίκευσης της προσέγγισης και θα αναδείξει πιθανές ανάγκες για προσαρμογές. Κάθε παθολογία παρουσιάζει μοναδικά χαρακτηριστικά που μπορεί να απαιτούν εξειδικευμένες τροποποιήσεις στον αλγόριθμο.

Η μετάβαση από την επεξεργασία μεμονωμένων φετών σε τρισδιάστατη ογκομετρική ανάλυση αποτελεί φυσική εξέλιξη της τεχνολογίας. Η 3D επεξεργασία θα επιτρέψει την αξιοποίηση χωρικών συσχετίσεων μεταξύ γειτονικών φετών, βελτιώνοντας πιθανότατα την ποιότητα ανακατασκευής και παρέχοντας πιο ολοκληρωμένη εικόνα της ανατομίας του ασθενούς.

Από τεχνολογική άποψη, η ανάπτυξη real-time υλοποιήσεων που μπορούν να ενσωματωθούν απευθείας στους MRI scanners θα επιτρέψει την άμεση βελτίωση των εικόνων κατά τη διάρκεια της εξέτασης. Αυτό θα μειώσει την ανάγκη για post-processing και θα επιτρέψει στους ακτινολόγους να λαμβάνουν άμεσα υψηλής ποιότητας εικόνες.

Η ενσωμάτωση περισσότερων τύπων απεικόνισης (FLAIR, DWI, DTI) σε μια ενοποιημένη αρχιτεκτονική μπορεί να παράσχει ακόμη πιο πλούσια πληροφορία για την ανακατασκευή. Αυτή η multi-modal προσέγγιση θα αξιοποιήσει το πλήρες φάσμα της διαθέσιμης διαγνωστικής πληροφορίας, οδηγώντας σε βελτιωμένη διαγνωστική ακρίβεια.

Τέλος, η ανάπτυξη προσαρμοστικών αλγορίθμων που μπορούν να προσαρμόζονται αυτόματα σε διαφορετικούς τύπους scanners και πρωτόκολλα απόκτησης θα μπορούσε να εμπλουτίσει τεχνολογικά ποικίλα κλινικά περιβάλλοντα.

Μελλοντικές κατευθύνσεις θα μπορούσαν να περιλαμβάνουν επέκταση σε άλλες ιατρικές τροπικότητες [YCH2020] ή εφαρμογή σε πιο σύνθετες αρχιτεκτονικές βαθιάς μάθησης.

5.5 Κλινικός Αντίκτυπος & Προοπτικές

Η επιτυχής ανάπτυξη του προτεινόμενου συστήματος έχει σημαντικές επιπτώσεις για την κλινική πρακτική και την ποιότητα της ιατρικής περίθαλψης.

Στο επίπεδο της διαγνωστικής ακρίβειας, η βελτίωση της ποιότητας των MRI εικόνων επιτρέπει την ανίχνευση λεπτότερων ανατομικών δομών και παθολογικών αλλαγών που μπορεί να μην είναι ορατές σε εικόνες χαμηλότερης ανάλυσης. Αυτό είναι ιδιαίτερα σημαντικό για την πρόωπη διάγνωση νευρολογικών παθήσεων, όπου η έγκαιρη παρέμβαση μπορεί να επηρεάσει δραματικά την πρόγνωση του ασθενούς.

Η δυνατότητα απόκτησης υψηλής ποιότητας εικόνων χωρίς αύξηση του χρόνου εξέτασης αντιμετωπίζει ένα από τα κυριότερα εμπόδια στη βελτίωση της ιατρικής απεικόνισης. Οι μειωμένοι χρόνοι εξέτασης μεταφράζονται σε βελτιωμένη ροή ασθενών στα νοσοκομεία, μειωμένο κόστος λειτουργίας, και καλύτερη εμπειρία για τους ασθενείς, ιδιαίτερα εκείνους που αντιμετωπίζουν δυσκολίες με την παραμονή ακίνητοι για μεγάλα χρονικά διαστήματα.

Σε οικονομικό επίπεδο, η τεχνολογία προσφέρει σημαντικές δυνατότητες εξοικονόμησης πόρων. Η αποφυγή επανάληψης εξετάσεων λόγω ανεπαρκούς ποιότητας εικόνων, η μείωση της ανάγκης για εξειδικευμένο υλικό υψηλής ανάλυσης, και η βελτιωμένη αξιοποίηση των υπαρχόντων σαρωτών (scanners) MRI μπορούν να μειώσουν σημαντικά το κόστος της ιατρικής απεικόνισης.

Ιδιαίτερα υποσχόμενες είναι οι προοπτικές εφαρμογής σε αναπτυσσόμενες χώρες και απομακρυσμένες περιοχές όπου η πρόσβαση σε υψηλής τεχνολογίας εξοπλισμό είναι περιορισμένη. Η δυνατότητα βελτίωσης εικόνων από σαρωτές παλιάς τεχνολογίας

μπορεί να επεκτείνει την πρόσβαση σε ποιοτική ιατρική απεικόνιση σε πληθυσμούς που παραδοσιακά είχαν περιορισμένες επιλογές.

Η ερμηνευσιμότητα του συστήματος το καθιστά ιδανικό για κλινικές εφαρμογές [TMZ2021], όπου η εμπιστοσύνη στα αποτελέσματα είναι κρίσιμη.

5.6 Επιστημονικά Συμπεράσματα & Φιλοσοφικές Σκέψεις

Η παρούσα εργασία αποτελεί μια επιτυχή μελέτη περίπτωσης για το πώς η συνδυασμένη χρήση κλασικής μαθηματικής θεωρίας με σύγχρονες τεχνικές υπολογιστικής νοημοσύνης μπορεί να παράγει συστήματα που υπερβαίνουν τους περιορισμούς των επιμέρους προσεγγίσεων.

Η επιτυχημένη ενσωμάτωση της θεωρίας των αραιών αναπαραστάσεων με τεχνικές βαθιάς μάθησης μέσω του παραδείγματος της βαθιάς αναδίπλωσης αποδεικνύει ότι η ερμηνευσιμότητα και η υψηλή απόδοση δεν είναι αμοιβαίως αποκλειόμενες ιδιότητες. Αυτή η παρατήρηση έχει ευρύτερες επιπτώσεις για την ανάπτυξη συστημάτων τεχνητής νοημοσύνης σε κρίσιμες εφαρμογές όπου η διαφάνεια και η αξιοπιστία είναι παράγοντες εξίσου σημαντικοί με την απόδοση.

Η προσέγγιση που υιοθετήθηκε αντανάκλα μια βαθύτερη κατανόηση του τρόπου που η πληροφορία οργανώνεται και διαδίδεται σε πολύπλοκα συστήματα. Η ικανότητα του συστήματος να αξιοποιεί συμπληρωματική πληροφορία από διαφορετικές πηγές μιμείται σε μικρό βαθμό τον τρόπο που οι ιατροί συνδυάζουν πολλαπλές πηγές διαγνωστικής πληροφορίας για να καταλήξουν σε συμπεράσματα.

Η εμπειρία από την ανάπτυξη και αξιολόγηση του συστήματος υπογραμμίζει τη σημασία της στενής συνεργασίας μεταξύ τεχνικής καινοτομίας και κλινικής εφαρμογής. Η επιτυχία τέτοιων έργων εξαρτάται όχι μόνο από την τεχνική αριστεία αλλά και από την κατανόηση των πραγματικών αναγκών και περιορισμών του κλινικού περιβάλλοντος.

Τέλος, η εργασία αναδεικνύει τη δυναμική φύση της επιστημονικής έρευνας στον τομέα της ιατρικής πληροφορικής, όπου οι θεωρητικές εξελίξεις μπορούν να έχουν άμεσο αντίκτυπο στην κλινική πρακτική και την ποιότητα ζωής των ασθενών. Αυτή η άμεση σύνδεση μεταξύ θεωρίας και πράξης καθιστά τον τομέα ιδιαίτερα ικανοποιητικό αλλά και υπεύθυνο από ερευνητική άποψη.

Βιβλιογραφία

[BTE2009] A. Beck and M. Teboulle, "A fast iterative shrinkage-thresholding algorithm for linear inverse problems," SIAM Journal on Imaging Sciences, vol. 2, no. 1, pp. 183–202, 2009. [\[Online\]](#)

[BSR2017] M. Borgerding, P. Schniter, and S. Rangan, "AMP-inspired deep networks for sparse linear inverse problems," IEEE Transactions on Signal Processing, vol. 65, no. 16, pp. 4293–4308, 2017. [\[Online\]](#)

[DDM2004] I. Daubechies, M. Defrise, and C. D. Mol, "An iterative thresholding algorithm for linear inverse problems with a sparsity constrain," Communications on Pure and Applied Mathematics, vol. 57, 2004. [\[Online\]](#)

[ELA2010] M. Elad, "Sparse and Redundant Representations: From Theory to Applications in Signal and Image Processing," Springer, 2010. [\[Online\]](#)

[GLE2010] K. Gregor and Y. LeCun, "Learning fast approximations of sparse coding," in International Conference on Machine Learning (ICML), pp. 399–406, 2010. [\[Online\]](#)

[GRE2009] H. Greenspan, "Super-resolution in medical imaging," The Computer Journal, vol. 52, no. 1, pp. 43–63, 2009. [\[Online\]](#)

[GZX2015] S. Gu, W. Zuo, Q. Xie, D. Meng, X. Feng, and L. Zhang, "Convolutional sparse coding for image super-resolution," in IEEE International Conference on Computer Vision (ICCV), pp. 1823–1831, 2015. [\[Online\]](#)

[HRW2014] J. R. Hershey, J. L. Roux, and F. Weninger, "Deep unfolding: Model-based inspiration of novel deep architectures," arXiv preprint arXiv:1409.2574, 2014. [\[Online\]](#)

[LGK2018] Ž. Lesjak, A. Galimzianova, A. Koren, M. Lukin, F. Pernuš, B. Likar, and Ž. Špiclin, "A novel public MR image dataset of multiple sclerosis patients with lesion segmentations based on multi-rater consensus," Neuroinformatics, vol. 16, no. 1, pp. 51–63, 2018. [\[Online\]](#)

[LIM2018] A. Lucas, M. Iliadis, R. Molina, and A. K. Katsaggelos, "Using deep neural networks for inverse problems in imaging: Beyond analytical methods," IEEE Signal Processing Magazine, vol. 35, no. 1, pp. 20–36, 2018. [\[Online\]](#)

[MTC2019] I. Marivani, E. Tsiligianni, B. Cornelis, and N. Deligiannis, "Learned multimodal convolutional sparse coding for guided image super-resolution," in IEEE International Conference on Image Processing (ICIP), 2019, pp. 2891–2895. [\[Online\]](#)

- [MTCD2020]** I. Marivani, E. Tsiligianni, B. Cornelis, and N. Deligiannis, "Multimodal deep unfolding for guided image super-resolution," *IEEE Transactions on Image Processing*, vol. 29, pp. 8443–8456, 2020. [\[Online\]](#)
- [RSC2008]** A. Ribes and F. Schmitt, "Linear inverse problems in imaging," *IEEE Signal Processing Magazine*, vol. 25, no. 4, pp. 84–99, 2008. [\[Online\]](#)
- [SRG2018]** H. Sreter and R. Giryes, "Learned convolutional sparse coding," in *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pp. 2191–2195, 2018. [\[Online\]](#)
- [TDL2019]** E. Tsiligianni and N. Deligiannis, "Deep coupled-representation learning for sparse linear inverse problems with side information," *IEEE Signal Processing Letters*, vol. 26, no. 12, pp. 1768–1772, 2019. [\[Online\]](#)
- [TMZ2021]** E. Tsiligianni, M. Zerva, I. Marivani, N. Deligiannis, and L. Kondi, "Interpretable deep learning for multimodal super-resolution of medical images," in *Medical Image Computing and Computer Assisted Intervention – MICCAI 2021, Lecture Notes in Computer Science*, vol. 12906, pp. 421–429, 2021. [\[Online\]](#)
- [TSW2010]** J. A. Tropp and S. J. Wright, "Computational methods for sparse solution of linear inverse problems," *Proceedings of the IEEE*, vol. 98, no. 6, pp. 948–958, 2010. [\[Online\]](#)
- [YCH2021]** H. B. Yedder, B. Cardoen, and G. Hamarneh, "Deep learning for biomedical image reconstruction: A survey," *Artificial Intelligence Review*, vol. 54, no. 1, pp. 215–251, 2021. [\[Online\]](#)
- [YWH2010]** J. Yang, J. Wright, T. S. Huang, and Y. Ma, "Image super-resolution via sparse representation," *IEEE Transactions on Image Processing*, vol. 19, pp. 2861–2873, 2010. [\[Online\]](#)